Condiciones cumplidas

Auditoría técnica y metodológica del proyecto de clasificación automática de expresiones faciales en equinos, contrastada con el plan de trabajo corregido (mayo de 2026), con experimento comparativo de features de pose «tipo SimBA»

Proyecto	Detección Automática de Expresiones Faciales en Equinos mediante Aprendizaje Profundo en Secuencias de Video
Integrantes	Héctor R. Liceaga · Sergio M. Yañez
Referencia	docs/plan_de_trabajo_corregido.pdf
Estado auditado	rama main, commit caf5564 (07/10/2026), artefactos de datos_equinos/ y experimentos/simba/
Fecha	07 de octubre de 2026

Todas las cifras provienen de scripts reproducibles en auditoria/scripts/ (solo lectura sobre los datos).

Índice

Resumen ejecutivo y veredicto 5

1. Plan de trabajo: requisitos y matriz de cumplimiento 7

1.1 Qué dice el plan 7
1.2 Requisitos verificables derivados (R1–R18) 7
1.3 Matriz de cumplimiento 8
1.4 Conteo y cambios respecto de la auditoría del 25/09 9
1.5 Atención a la devolución docente 10

2. Objetivo general frente a hipótesis 12

2.1 Objetivo general: «construir un sistema informático para la detección automatizada de expresiones faciales en caballos mediante el procesamiento de secuencias espacio-temporales» 12
2.2 Comparación con baselines triviales (mismos folds) 12
2.3 Hipótesis: «es factible desarrollar un modelo basado en aprendizaje profundo capaz de identificar y clasificar automáticamente expresiones faciales en equinos a partir de secuencias de video cortas, logrando un nivel de precisión útil para la asistencia de expertos humanos» 13
2.4 Hipótesis implícita del problema («las expresiones son eventos dinámicos») 13

3. Dataset 14

3.1 Del video al clip válido 14
3.2 Caballos 14
3.3 Distribución por fold (test de cada fold) 15
3.4 Características técnicas que difieren entre clases 15
3.5 Duplicados 16
3.6 Consistencia de nombres y etiquetas 16

4. Balance de clases 17

4.1 Criterio (declarado antes de calcular) 17
4.2 Resultado global 17
4.3 Balance dentro de los folds 17

5. Folds, entrenamiento interno, validación interna y test 19

5.1 Cómo se construyen 19
5.2 Composición de cada subconjunto 19
5.3 Hallazgo: la validación interna son los caballos con más clips 19

6. Fuga de información (data leakage) 21

6.1 Qué variable agrupa y por qué 21
6.2 Verificaciones ejecutadas (con aserciones) 21
6.3 Estadísticas de normalización, selección de épocas e hiperparámetros 22
6.4 Riesgos residuales (no detectados como fuga, pero a declarar) 22
6.5 Veredicto 22

7. Validación cruzada, validación interna y early stopping 23

7.1 Protocolo 23
7.2 Resultado por fold 23
7.3 Qué no se puede afirmar 24

8. Sobreajuste 25

8.1 Evidencia disponible 25
8.2 Brechas 25
8.3 Clasificación 26

9. Rendimiento: métricas, estabilidad entre folds, confusiones y cifras históricas 28

9.1 El valor vigente (único) 28
9.2 Estabilidad entre folds 28
9.3 Precision, recall y F1 por clase 29
9.4 Matrices de confusión 29

9.5 Cifras históricas y su estatus ... 30
10. Baselines y valor agregado del modelo ... 32
10.1 Baselines que existen en el repositorio ... 32
10.2 El modelo frente a cada línea de base (mismos 4 folds) ... 32
10.3 Confusores de filmación: lo que se puede predecir sin mirar la cara ... 33
11. Arquitectura, dimensionalidad, regularización y data augmentation ... 35
11.1 Arquitectura vigente (instanciada y contada por la auditoría) ... 35
11.2 Dimensionalidad frente a muestras ... 35
11.3 Regularización implementada de verdad ... 36
11.4 Calibración de lo que se muestra al usuario ... 36
11.5 Data augmentation ... 36
11.6 Hallazgo: el canal geométrico del MIL es casi vacío ... 37
12. Preprocesamiento, selección de frames y coherencia entrenamiento–inferencia ... 38
12.1 Cadena de preprocesamiento ... 38
12.2 Selección de los 16 frames ... 38
12.3 ¿Entrenamiento e inferencia ven la misma entrada? ... 39
12.4 Documentación desactualizada que contradice al código (menor) ... 40
12.5 Prueba de la interfaz sobre videos del propio dataset ... 40
13. Independencia de las muestras, generalización y calidad de las etiquetas ... 42
13.1 Independencia ... 42
13.2 Generalización a caballos no vistos (interna) ... 42
13.3 Generalización externa ... 42
13.4 Calidad de las etiquetas ... 43
14. Reproducibilidad y trazabilidad ... 44
14.1 Se reproduce lo publicado ... 44
14.2 Repetibilidad con otras semillas y otras particiones ... 44
14.3 Entorno, semillas y configuración ... 45
14.4 Trazabilidad de experimentos ... 45
15. Buenas prácticas y condiciones de un buen modelo de clasificación ... 46
15.1 Checklist de buenas prácticas para datasets pequeños ... 46
15.2 Condiciones de un buen modelo de clasificación ... 46
16. Confiabilidad, puntos fuertes y débiles, mejoras y veredicto ... 48
16.1 Confiabilidad por dimensión ... 48
16.2 Puntos fuertes ... 48
16.3 Puntos débiles ... 48
16.4 Mejoras recomendadas ... 49
16.5 Veredicto cuantificado ... 50
17. Experimento comparativo con features de pose «tipo SimBA» ... 51
17.1 Roles: DeepLabCut y SimBA ... 51
17.2 Compatibilidad e importación DLC → SimBA ... 51
17.3 Inventario anatómico: qué se puede y qué no se puede observar ... 52
17.4 Comparación con las 9 variables geométricas vigentes (hallazgo de esta auditoría) ... 53
17.5 Dataset tabular y trazabilidad ... 53
17.6 Mismos folds, mismos clips, mismo denominador ... 53
17.7 Tres enfoques, por fold y por clase ... 54
17.8 Ablación (variantes A–F) ... 55
17.9 Original frente a limpio (el confusor de filmación) ... 56
17.10 Sobreajuste frente al MIL ... 57
17.11 SHAP (SimBA-RF) ... 58
17.12 Lo que SimBA no resuelve ... 61
17.13 Matriz de parsimonia ... 62
17.14 Revisión adversarial del F1 0,851 ... 62

17.15 Las 12 preguntas del experimento (con las cifras corregidas) 62
17.16 Efecto del experimento sobre esta auditoría 63

18. Anexo: archivos analizados y producidos 64

18.1 Documentos de entrada 64
18.2 Código revisado (rama main @ caf5564) 64
18.3 Experimento SimBA (rama feat/auditoria-y-experimento-simba, sólo lectura) 64
18.4 Artefactos de datos leídos (solo lectura, datos_equinos/) 64
18.5 Scripts de la auditoría (auditoria/scripts/) 64
18.6 Limitaciones de esta auditoría 65

Auditoría técnica y metodológica — Tesina «Detección automática de expresiones faciales en equinos»

Fecha: 07 de octubre de 2026 · **Estado auditado:** rama `main`, commit `caf5564`, más las fusiones `feat/mejoras-prioridad-alta` y `chore/deuda-menor-y-observador-unico` · **Referencia:** `docs/plan_de_trabajo_corregido.pdf` · **Antecedente:** auditoría del 25/09/2026 y devolución docente.

Naturaleza. Auditoría crítica. Cada cifra sale de un script de `auditoria/scripts/` que lee los artefactos del repositorio (sólo lectura) y escribe en `auditoria/datos/`; lo que no pudo comprobarse se declara como tal. Nada se copió de la auditoría anterior sin recalcularlo.

Resumen ejecutivo

Ítem	Resultado
Modelo vigente	MIL multimodal (`MILFusionModel`): ResNet-18 congelada + 9 variables geométricas + atención; 132 355 parámetros entrenables
Datos	**133 caballos · 359 clips** · 244 videos de origen (393 clips candidatos, 91,3 % válidos)
Distribución por clase	`Disgustado` 103 (28,7 %) · `Interesado` 118 (32,9 %) · `Sereno` 138 (38,4 %)
F1 macro (vigente)	**0,740 ± 0,052** (media ± DE de 4 folds por caballo; IC 95 % [0,677; 0,797]); folds 0,718 / 0,769 / 0,677 / 0,795
Accuracy	0,744 (267/359) · balanced accuracy 0,740
Baselines (mismos folds)	azar 0,327 · mayoritaria 0,183 · metadatos 0,618 · **media de 16 frames + LogReg 0,741 ± 0,020** (MIL − estática −0,005, IC [−0,068; +0,058])
Plan de trabajo	18 requisitos: **10 cumplidos · 6 parciales · 2 no verificables · 0 no cumplidos** (25/09: 9 / 4 / 4 / 2 de 19)
Sobreajuste	**MODERADO**: F1 train 0,979 / val 0,712 / test 0,740; el test no está inflado, las probabilidades sí están sobreconfiadas
Balance	RAZONABLEMENTE BALANCEADO (clips 1,34:1); BALANCEADO (caballos 1,15:1); folds y validaciones internas más desbalanceados
Fuga de información	No se observan evidencias (0 cruces de caballo, video, clip ni frame; test verificado como independiente); riesgo residual de sesión/lugar
Repetibilidad	Semilla 42 bit a bit; 6 semillas 0,739 ± 0,015
Experimento SimBA	RF sobre 160 «features tipo SimBA» (código propio, no SimBA real): **F1 macro 0,841 ± 0,003** (5 semillas) frente al MIL 0,740 (+0,11 [0,04; 0,18]); en el subconjunto limpio 0,750 frente a 0,705 (no concluyente); deconfundido por filmación 0,777; alerta de confusor (R^2 0,53 con la duración). SimBA real sólo da movimiento (0,720). Cap. 17
Fortalezas	(1) Separación por caballo verificada por código; (2) test intacto y reproducibilidad exacta; (3) reporte riguroso con IC por caballo y baselines
Debilidades	(1) El MIL no supera a un promedio lineal y no es temporal; (2) confusores de captura (duración, contenedor, rotación, sesión); (3) eslabón entrenamiento–inferencia y etiquetas de un único observador
Mejoras de prioridad alta	Reformular la contribución; corregir el eslabón entrenamiento–inferencia; controlar sesión y filmación; repetir la CV (≥ 5 particiones); rehacer la validación interna; incorporar SimBA-RF como complemento; arreglar las 9 geométricas; declarar limitaciones de etiquetado
Veredicto	Metodología de confiabilidad ALTA; estadística MEDIA; generalización externa no evaluada; hipótesis **parcialmente sustentada**

Hallazgos principales

1. **La metodología de evaluación es sólida y verificable**; el 0,74 es una estimación creíble del rendimiento sobre **caballos nuevos de esta población y este tipo de captura**, con ±0,06 de IC y ±0,015 entre semillas.
2. **La arquitectura no demuestra valor agregado**: la media lineal de las características de 16 frames rinde igual (0,741), con 2,6 veces menos dispersión entre folds. En 4 particiones alternativas el MIL es 0,003–0,021 mejor (media +0,015); no alcanza para afirmar una ventaja.
3. **El contexto de captura contiene señal**: sin mirar la cara, la duración sola da 0,544, los metadatos 0,618 y la fecha de sesión 0,535 (0,605 combinando técnicos y fecha). La duración del clip determina la ventana de los 16 frames (0,19 s entre frames en `Disgustado`, 0,39 s en las otras). Sobre el subconjunto 1080×1920 y ≥ 5 s el MIL conserva 0,705.
4. **Hallazgos nuevos respecto de la auditoría anterior** (no estaban en ella): (a) la **validación interna son los 7 caballos con más clips** (≈ 10 clips c/u frente a 2,1 en el train interno); (b) los **clips se recodifican en** `mp4v` y la interfaz decodifica el video original: en la muestra medida cambia la predicción en 2 de 28 clips, y al correr la interfaz sobre 16 videos del propio dataset (con el modelo ya entrenado sobre ellos) la predicción coincidió con la etiqueta sólo en 8; (c) **la inferencia no activa la orientación del video** que sí se aplicó al crear el dataset: 69 de 274 videos (25 %) declaran rotación y originan el 35 % de los clips, y esa rotación está asociada a la clase (1/110 de `Disgustado`, 47/93 de `Sereno`); (d) la partición **no coincide con** `sklearn.GroupKFold` aunque el docstring dice «réplica»; (e) la **calibración**: ECE 0,081.
5. **Las etiquetas** tienen ahora criterio documentado (EquiFACS, etogramas) pero **un único observador no ciego**; el acuerdo sobre el dataset no se midió y el techo de rendimiento se desconoce.
6. **El canal geométrico del MIL es casi vacío**: las 9 variables llevan un solo grado de libertad (inclinación de la cabeza) y sus máscaras de validez valen 1 siempre (confianza > 0, no ≥ 0,50).
7. **Debilidades abiertas**: validación externa, utilidad para veterinarios (R15, R16), ramas de variantes sin fusionar, documentación con cifras viejas.

Cómo se atendió la devolución docente

Observación	Atención
«¿Cómo está la repetibilidad?»	Medida: bit a bit con la semilla 42; ±0,015 entre semillas; 0,740–0,758 entre 5 particiones de caballos (DE 0,008; cap. 14)
«¿Espacio temporal o sólo procesamiento del video?»	Confirmado: no es temporal; R7 parcial (cap. 2, 11)
«No lo estamos haciendo, sacar»	Antiguo R8 retirado de la matriz (cap. 1)
«¿DeepLabCut con Horse-30?»	No; modelo generalista, sin ajuste (cap. 12)

Veredicto

El proyecto **cumple su objetivo central** (un sistema que clasifica expresiones de caballos en video con evaluación honesta por individuo) y su metodología es de **confiabilidad ALTA**; la **confiabilidad estadística es MEDIA**, la **generalización externa no está evaluada**, y **la hipótesis queda parcialmente sustentada**: factibilidad de clasificar, sí; valor del aprendizaje profundo y de la modelización temporal, no demostrado; utilidad para expertos, no verificable. Las mejoras de prioridad alta (cap. 16) son: reformular la contribución, corregir el eslabón entrenamiento–inferencia, controlar la sesión como confusor, repetir la validación cruzada, rehacer la validación interna y llevar las limitaciones de etiquetado al informe.

Experimento SimBA. Con la misma pose, los mismos 16 frames y los mismos folds, un Random Forest sobre features geométricas y de movimiento calculadas con código propio supera al MIL en el conjunto original (0,841 frente a 0,740), pero la ventaja se reduce y deja de ser concluyente al controlar la filmación. Conviene incorporarlo como **modelo complementario e interpretable**, no como sustituto, y **controlar la sesión y la filmación** antes de atribuir el rendimiento a la expresión. Ninguno de los dos enfoques resuelve EquiFACS, el acuerdo interobservador ni la validación veterinaria. Los conteos de requisitos no cambian.

1. Plan de trabajo: requisitos y matriz de cumplimiento

Documento de referencia: `docs/plan_de_trabajo_corregido.pdf` (mayo de 2026), leído completo. Estado auditado: rama `main`, commit `caf5564` (07/10/2026), incluidas las fusiones `feat/mejoras-prioridad-alta` y `chore/deuda-menor-y-observador-unico`, y los artefactos de `datos_equinos/resultados/`. Todo lo que sigue se **re-verificó contra el estado actual**; no se copió ningún número de la auditoría del 25/09.

1.1 Qué dice el plan

Elemento	Contenido (fiel al plan)
Problema	La evaluación del estado emocional depende de la observación humana (subjetiva, lenta); las imágenes estáticas «pierden información crucial» porque las expresiones son «eventos dinámicos»
Objetivo general	«Construir un sistema informático para la detección automatizada de expresiones faciales en caballos mediante el procesamiento de secuencias espacio-temporales»
Objetivos específicos	(1) Base de datos de videos cortos (5–7 s) de rostros de equinos. (2) Pipeline de preprocesamiento: extracción de fotogramas clave y detección de la ROI. (3) Técnicas de clasificación de aprendizaje automático orientadas a video. (4) Aplicación o interfaz para usar el modelo
Hipótesis	Es factible desarrollar un modelo de aprendizaje profundo que clasifique expresiones faciales asociadas a estados emocionales a partir de secuencias de video cortas, «logrando un nivel de precisión útil para la asistencia de expertos humanos»
Metodología	(1) Investigación tecnológica (estado del arte espacio-temporal). (2) Preprocesamiento: limpieza, extracción y procesamiento de fotogramas, rostros alineados a lo largo de los clips. (3) Entrenamiento y selección: pruebas de concepto con modelos candidatos, selección por métricas. (4) Validación final con validación cruzada y análisis de resultados para evitar el sobreajuste
Datos y técnicas	Bases de video propias e institucionales; Colab, Python, PyTorch, TensorFlow, OpenCV, DeepLabCut
Evaluación	«Métricas de rendimiento» y validación cruzada; **el plan no fija una métrica ni un umbral numérico**
Resultados esperados / impacto	Herramienta no invasiva y objetiva que asista a veterinarios y cuidadores; metodología extrapolable a otras especies
Cronograma e índice	Entrega final proyectada para septiembre; índice: Introducción, Etología, Técnicas, Desarrollo experimental, Resultados y discusión, Conclusiones, Bibliografía, Anexos

1.2 Requisitos verificables derivados (R1–R18)

Se conserva la lista de la auditoría del 25/09 **menos el antiguo R8** («la evolución temporal aporta robustez»), que se **retira** por indicación de la devolución docente (§1.5, punto 3). La numeración de esta tabla es consecutiva; el cruce con la numeración anterior está en §1.4.

#	Requisito	Origen en el plan
R1	Base de datos de videos cortos (5–7 s) de rostros de equinos	OE1, Resumen
R2	Pipeline de preprocesamiento con extracción de fotogramas y detección de ROI	OE2
R3	Rostros alineados a lo largo de los clips	Metodología 2
R4	Clasificación con técnicas de aprendizaje automático orientadas a video	OE3
R5	Aplicación o interfaz para usar el modelo	OE4
R6	Sistema informático de detección automatizada de punta a punta	Objetivo general
R7	Procesamiento de secuencias espacio-temporales / análisis de la dinámica	Objetivo general, Resumen
R8	Analizar diversas arquitecturas candidatas (pruebas de concepto)	Resumen, Metodología 3
R9	Identificar la arquitectura óptima para características espacio-temporales	Resumen
R10	Seleccionar la arquitectura en base a métricas de rendimiento	Metodología 3
R11	Validación final con validación cruzada	Metodología 4
R12	Análisis de resultados para evitar el sobreajuste	Metodología 4
R13	Relevamiento del estado del arte	Metodología 1
R14	Nutrirse de EquiFACS / metodologías etológicas (criterio de etiquetado)	Antecedentes
R15	Precisión «útil para la asistencia de expertos»	Hipótesis

#	Requisito	Origen en el plan
R16	Herramienta objetiva que asista a veterinarios y cuidadores	Resumen, Impacto
R17	Uso de los recursos previstos (PyTorch, OpenCV, DeepLabCut, Colab, Python)	Recursos
R18	Informe final según el índice propuesto, con entrega proyectada para septiembre	Cronograma, Índice

1.3 Matriz de cumplimiento

#	Requisito	Evidencia (archivo concreto)	Estado	Justificación
R1	Base de datos de videos cortos (5–7 s)	`resultados/inventario_videos.csv` (274 videos), `inventario_clips.csv` (393 clips), `particion_clips.json` (359 válidos, 133 caballos)	CUMPLIDO PARCIALMENTE	La base existe, es propia y se amplió. Pero el 33,4 % de los clips válidos (120/359) dura menos de 5 s: `Disgustado` tiene mediana 3,2 s (§3.4). El piso de 1 s para videos cortos es una decisión del proyecto, no del plan
R2	Pipeline de preprocesamiento (fotogramas y ROI)	`equinos/pose.py`, `secuencia.py`, `alineado.py`, `encuadre.py`; notebooks 01–02; `resultados/dataset_rechazos_v2.json` (91,3 % de clips aprovechados)	CUMPLIDO	DeepLabCut sobre todos los frames, ventana temporal con anclaje, ROI alineada por el eje ojo–hocico con orejas; rechazos clasificados por motivo; 15/15 archivos de prueba pasan
R3	Rostros alineados a lo largo de los clips	`resultados/dataset_frames_alineados_v2.csv` (5 744/5 744 frames `alineado = True`, `origen = keypoints`); `equinos/alineado.py`; `tests/test_equivalencia.py`	CUMPLIDO	Transformada de similitud por frame a una pose canónica; los 359 clips tienen los 16 frames medidos por el detector (ninguno interpolado)
R4	Clasificación orientada a video	`equinos/clasificacion.py::MILFusionModel`; `resultados/objetivo3_evaluacion_v2.json`	CUMPLIDO	La unidad de decisión es el clip (16 frames) con atención sobre los frames. Es orientada a video en su unidad, no en el orden temporal (R7)
R5	Aplicación o interfaz	`app_inferencia.py`; `equinos/inferencia.py`; `datos/app_streamlit.json`; `datos/orientacion_inferencia.json`	CUMPLIDO	La interfaz arranca sin excepciones, lee sus métricas del JSON vigente y la cadena completa produjo 16 predicciones y 0 negativas explicadas sobre 16 videos del dataset. Debilidades de robustez en §12.3 y §12.5
R6	Sistema de punta a punta	`equinos/inferencia.py::clasificar_video`; `datos_equinos/modelos/objetivo3_v2/mil_multimodal_produccion.pt` y su `.json` de procedencia	CUMPLIDO	Existe la cadena video → pose → ventana → alineado → ResNet-18 → MIL → clase y confiabilidad medida; la huella de las características del modelo de producción coincide con la caché vigente
R7	Procesamiento espacio-temporal	`clasificacion.MILFusionModel.forward`; `datos/arquitectura.json` (prueba de permutación)	CUMPLIDO PARCIALMENTE	Procesa secuencias de 16 frames, pero es invariante al orden: barajar o invertir los frames no cambió ninguna de las 359 predicciones. Es espacial + agregación de conjunto, no temporal
R8	Analizar diversas arquitecturas candidatas	`docs/registro_de_experimentos.md`; `resultados/objetivo3_*.json` (12 evaluaciones); `openspec/changes/archive/2026-08-28-clasificacion-orientada-a-video/`	CUMPLIDO	Al menos 10 variantes bajo partición por caballo (un frame con voto, promedio, atención, GRU, MIL, MIL visual, canal enriquecido, *fine-tuning*, reentrenado, CV anidada) con resultados y conclusión de cada una
R9	Arquitectura óptima para características espacio-temporales	`resultados/objetivo3_lineas_de_base.json`; `datos/metricas.json`; `datos/particiones_alternativas.json`	CUMPLIDO PARCIALMENTE	Las diferencias entre las mejores variantes (0,740–0,755) caen dentro del desvío entre folds y de las semillas (±0,015); la media lineal de 16 frames iguala al MIL (0,741; dif. −0,005, IC [−0,068; +0,058]). No se puede afirmar que el MIL sea «óptimo»; tampoco que una arquitectura espacio-temporal lo sea. Un RF sobre features de pose rinde 0,841 en el original (0,750 frente a 0,705 en el limpio, no concluyente): ver cap. 17

#	Requisito	Evidencia (archivo concreto)	Estado	Justificación
R10	Selección por métricas	`docs/informe_mejora_pipeline_mil.md` §2.6; `equinos/clasificacion.py`	CUMPLIDO	La regla de decisión está declarada y usa la validación interna, no el test. Salvedad: la selección de variantes se hizo sobre los mismos folds (§6.4)
R11	Validación cruzada final	`equinos/particion.py`; `resultados/particion_clips.json`; `objetivo3_evaluacion_v2.json`	CUMPLIDO	4 folds agrupados por caballo con predicciones fuera de muestra para los 359 clips; 0 cruces verificados por código
R12	Análisis para evitar el sobreajuste	`docs/analisis_sobreajuste.md`; `objetivo3_evaluacion_v2.json` (`curva`, `sobreajuste`); `datos/early_stopping_sobreajuste.json`	CUMPLIDO	Hay controles (*early stopping*, dropout, *weight decay*, backbone congelado) y análisis explícito del gap con las curvas de train y validación, desde el 25/09 (antes PARCIAL). El análisis encuentra sobreajuste MODERADO y lo documenta; no se afirma su ausencia
R13	Relevamiento del estado del arte	`../material para presentar/informe/informe_final_tesina_equinos.tex` y `referencias.bib` (39 referencias); `openspec/project.md`	CUMPLIDO PARCIALMENTE	El borrador del informe (fuera del repositorio versionado) contiene un marco con EquiFACS, MIL, DeepLabCut, transferencia y reconocimiento de dolor equino. No hay un relevamiento formal comparativo de modelos espacio-temporales en el repositorio
R14	Criterio etológico (EquiFACS)	`docs/protocolo_de_etiquetado.md` §3–§5; `docs/formulario_etiquetado_2026-09-28.docx`	CUMPLIDO PARCIALMENTE	Antes NO CUMPLIDO. Ahora hay autoría (veterinaria codificadora certificada de EquiFACS), criterio por clase con unidades de acción y etogramas, y exclusiones. Resta: **un único observador no ciego**, sin acuerdo medido sobre el dataset (kappa 0,99 sólo en un piloto con imágenes), sin codificación EquiFACS por video
R15	Precisión «útil para expertos»	`clasificacion.CRITERIO_ACEPTACION` (0,691); `objetivo3_evaluacion_v2.json`	NO VERIFICABLE	El plan no define «útil». El proyecto declaró un criterio interno (0,691 antes de entrenar; 0,761 re-declarado después, y así consta); ninguno es un umbral clínico. No hubo validación con veterinarios
R16	Herramienta objetiva que asista a veterinarios y cuidadores	`app_inferencia.py`; `openspec/changes/archive/*/prueba_con_persona_ajena.md`	NO VERIFICABLE	La herramienta existe y declara que no es un diagnóstico; su utilidad para el público objetivo no se midió (n = 1 en la prueba de usabilidad del proyecto)
R17	Recursos previstos	`requirements-local.txt` (torch 2.5.1, opencv 4.11, deeplabcut 3.0.1); notebooks con celdas de Colab	CUMPLIDO	Se usan PyTorch, OpenCV, DeepLabCut, Python y Colab/GPU local. TensorFlow figura en el plan como alternativa y no se usó
R18	Informe final según el índice, entrega en septiembre	`../material para presentar/informe/informe_final_tesina_equinos.tex` y `.pdf` (borrador del 07/10); `openspec/project.md` («entrega: 29/10/2026»)	CUMPLIDO PARCIALMENTE	Hay un borrador con la estructura del índice (Introducción, Etología, Técnicas, Desarrollo, Resultados, Conclusiones, Bibliografía, Anexos) y cifras coherentes con esta auditoría; la entrega se reprogramó del plan (septiembre) al 29/10/2026

1.4 Conteo y cambios respecto de la auditoría del 25/09

Estado	Requisitos
CUMPLIDO	10
CUMPLIDO PARCIALMENTE	6
NO VERIFICABLE	2
NO CUMPLIDO	0
Total	18

Auditoría	Requisitos	Cumplidos	Parciales	No verificables	No cumplidos
25/09/2026 (estado anterior)	19	9	4	4	2
Esta auditoría (07/10/2026)	**18**	**10**	**6**	**2**	**0**

Cambios, uno por uno:

Requisito (nuevo ← antiguo)	Antes	Ahora	Motivo del cambio
(retirado) ← R8 «la evolución temporal aporta robustez»	NO CUMPLIDO	—	Retirado a pedido del docente: no es un requisito del plan sino una motivación del problema
R12 ← R13 sobreajuste	PARCIAL	CUMPLIDO	Se registra el gap y las curvas por época; hay análisis específico
R14 ← R15 EquiFACS	NO CUMPLIDO	PARCIAL	Protocolo de etiquetado y formulario (28/09)
R13 ← R14 estado del arte	NO VERIFICABLE	PARCIAL	El borrador del informe y su bibliografía son verificables aunque estén fuera del repositorio
R18 ← R19 informe final	NO VERIFICABLE	PARCIAL	Borrador con el índice del plan; entrega reprogramada
R8 ← R9, R9 ← R10, R10 ← R11, R11 ← R12	iguales	iguales	Re-verificados
R1, R2, R3, R4, R5, R6, R7, R15, R16, R17	iguales	iguales	Re-verificados (R3: ya no hay comprobación fallida en `test_equivalencia.py`)

Lectura: el estado mejoró por trabajo real (sobreajuste, etiquetado, líneas de base, trazabilidad) y por la reformulación docente de un requisito (R8). Los dos requisitos que siguen sin poder verificarse (R15, R16) dependen de una validación con expertos que el proyecto no tiene prevista.

Efecto del experimento SimBA (capítulo 17). Se reconsideró cada requisito: **R9** se mantiene CUMPLIDO PARCIALMENTE (el experimento agrega evidencia de que el MIL no es la mejor opción disponible —0,841 frente a 0,740 en el original, no concluyente en el limpio—, lo que refuerza que no hay arquitectura demostrada óptima); R7 no cambia (las features resumen la dinámica, no modelan el tiempo); R14, R15 y R16 no cambian (SimBA no aporta unidades de acción, acuerdo interobservador ni validación veterinaria). El plan no tiene un requisito de interpretabilidad. **Los conteos permanecen en 10 / 6 / 2 / 0.**

1.5 Atención a la devolución docente

Las observaciones del docente sobre la auditoría del 25/09 son cuatro, intercaladas en el PDF `Devolucion_Juan_resumen_de_condiciones_cumplidas_o_no .pdf`. Se identificaron por diferencia de texto contra el PDF original y por su posición en la página. Cómo se atiende cada una:

#	Observación del docente (textual)	Dónde se apuntaba	Cómo se atiende en esta auditoría
1	«¿Cómo está la repetibilidad?»	Resumen ejecutivo, fortalezas («reproducible bit a bit»)	Se **midió** en lugar de afirmarse: (a) misma partición y semilla: 359/359 predicciones, curvas y pesos idénticos; (b) 6 semillas: F1 macro 0,739 ± 0,015 (rango 0,726–0,763), con la mejor época entre 13 y 50; (c) 4 asignaciones alternativas de caballos a folds: MIL 0,744–0,758. Capítulo 14, tablas 14.1–14.2
2	«Me queda la duda si es espacio temporal o no porque es invariante al orden que se procesan los frames. Tal vez sea solo procesamiento del video»	R7	**Tiene razón.** Se verificó numéricamente (0/359 predicciones cambian al barajar o invertir los frames; diferencia máxima de logits $3{,}8 \cdot 10^{-6}$). El sistema procesa video (16 frames de un clip) pero **no modela la dinámica temporal**. R7 queda CUMPLIDO PARCIALMENTE y el texto del informe debe decir «agregación espacial de varios fotogramas», no «espacio-temporal». §2.1, §11.1
3	«No lo estamos haciendo, sacar»	Antiguo R8 («la evolución temporal aporta robustez»)	**Se retira** de la matriz y del conteo (18 requisitos en lugar de 19). La observación empírica se conserva en §2.4 como hallazgo, no como requisito
4	«¿Usaron el DeepLabCut con Horse-30? subconjunto experto específico para caballos»	Fila «Detección / pose» de la tabla entrenamiento–inferencia	**No.** Se usa el modelo preentrenado generalista `superanimal_quadruped` (red `hrnet_w32`, detector `fasterrcnn_resnet50_fpn_v2`) sin ajuste con datos de caballos; no hay referencias a Horse-10/Horse-30 en el repositorio. Cuánto de ese modelo se entrenó con caballos no pudo verificarse con los archivos disponibles. Se corrigió además la fila de la tabla: ya no dice «Detector/pose: SÍ igual» sin matices (§12.1, §12.3)

Además de las cuatro observaciones puntuales, el PDF del docente es la **primera versión** del informe del 25/09 (antes de la corrección de misma fecha sobre las ramas laterales y del intervalo MIL − metadatos). Esta auditoría

usa los valores corregidos: diferencia MIL − metadatos **+0,121, IC 95 % [+0,031; +0,211]**, calculada contra la regresión logística de metadatos (0,618) y no contra el Random Forest, que era la comparación del texto que leyó el docente ([+0,098; +0,276]).

2. Objetivo general frente a hipótesis

El plan separa dos cosas que suelen confundirse: un **objetivo** (construir algo) y una **hipótesis** (afirmar algo que puede ser falso). Se evalúan por separado, con los datos vigentes (359 clips, 133 caballos, 4 folds agrupados por caballo).

2.1 Objetivo general: «construir un sistema informático para la detección automatizada de expresiones faciales en caballos mediante el procesamiento de secuencias espacio-temporales»

Verificación	Resultado	Evidencia
Existe una cadena completa video → clase	**Sí**	`equinos/inferencia.py::clasificar_video` (pose DeepLabCut → selección de ventana → alineado → ResNet-18 → MIL); `app_inferencia.py` renderiza sin excepciones (`datos/app_streamlit.json`)
La cadena se ejecuta sobre videos reales	**Sí, con salvedades**	16 predicciones y 0 negativas sobre 16 videos del propio dataset (§12.5)
Entrenamiento real (no simulado)	**Sí**	4 modelos por fold + modelo de producción; re-entrenados con el código vigente: 359/359 predicciones y pesos idénticos bit a bit con la semilla 42 (`datos/reentrenamiento_semillas.json`)
Evaluación real fuera de muestra	**Sí**	Cada uno de los 359 clips se predice con un modelo que no vio a su caballo; el test se evalúa una sola vez (§6, §7)
Clases bien definidas y consistentes	**Sí**	`CLASES = (Disgustado, Interesado, Sereno)` idénticas en CSV, JSON y código; criterio por clase documentado en `docs/protocolo_de_etiquetado.md` (un único observador)
«Secuencias espacio-temporales»	**Parcial**	El modelo recibe 16 frames pero es **invariante al orden**: barajar o invertir los frames no cambió ninguna de las 359 predicciones (diferencia máxima de logits $3{,}8 \cdot 10^{-6}$; `datos/arquitectura.json`). Procesa una *secuencia de video* como un conjunto de imágenes; no modela dinámica temporal

Conclusión sobre el objetivo. Un sistema que clasifica video en tres clases existe, se entrenó y se evaluó con una metodología de separación por individuo. El adjetivo «espacio-temporales» del objetivo no se cumple en sentido estricto, y así debe redactarse (respuesta a la duda del docente; §1.5, punto 2).

2.2 Comparación con baselines triviales (mismos folds)

Valores recalculados por esta auditoría sobre los **mismos 4 folds** que usa el modelo (`datos/metricas.json`).

Modelo / línea de base	F1 macro (media ± DE entre folds)	Nota	Accuracy
Azar uniforme (1/3 por clase), esperanza	0,327	P95 sim. 0,367	≈ 0,333
Azar estratificado (proporciones del train), esperanza	0,326	P95 sim. 0,366	—
Clase mayoritaria (Sereno en los 4 folds)	0,183 ± 0,033		0,384
Solo duración del clip (LogReg)	0,544 ± 0,035		0,532
Metadatos de filmación (LogReg)	0,618 ± 0,034		0,635
Geometría sola, media y desvío (LogReg)	0,607 ± 0,033		0,618
Un frame central (LogReg)	0,679 ± 0,024		0,688
Media de los 16 frames (LogReg)	**0,741 ± 0,020**		0,749
MIL multimodal (vigente)	**0,740 ± 0,052**		0,744

- El F1 macro esperado de una clasificación **aleatoria uniforme** es 0,327 (simulación de 4 000 repeticiones sobre los folds reales; percentil 95: 0,367), próximo al 1/3 teórico; no es exactamente 1/3 porque el F1 macro de una clase no predicha o muy rara se trunca a 0 en los folds pequeños.
- La **mayoritaria** predice `Sereno` en los 4 folds: accuracy 0,384 y F1 macro 0,183. La accuracy sola es engañosa con este reparto (38 % de `Sereno`), por eso la métrica principal es el F1 macro.
- El modelo (0,740) supera ampliamente a ambas. **Superarlas es una condición necesaria y débil**: la comparación informativa es con las líneas que miran la imagen (capítulo 10).

2.3 Hipótesis: «es factible desarrollar un modelo basado en aprendizaje profundo capaz de identificar y clasificar automáticamente expresiones faciales en equinos a partir de secuencias de video cortas, logrando un nivel de precisión útil para la asistencia de expertos humanos»

La hipótesis tiene cuatro componentes que no tienen la misma evidencia:

Componente	Evidencia	Veredicto
Factibilidad de clasificar tres expresiones en caballos no vistos	F1 macro 0,740 (IC 95 % por caballo [0,677; 0,797]) contra 0,327 del azar y 0,183 de la mayoritaria; por encima de los metadatos de filmación (0,618; diferencia IC 95 % [+0,031; +0,211])	**Respaldada** para este conjunto, con un tope por contexto de filmación (0,556–0,605 sin mirar la cara, §10.3)
«Aprendizaje profundo» como medio necesario	Una regresión logística sobre la media de las 16 características de ResNet-18 obtiene 0,741 ± 0,020; diferencia MIL − estática −0,005, IC 95 % [−0,068; +0,058]	**No demostrada**: lo que aporta es el *extractor preentrenado*; la cabeza profunda (atención + geometría) no mejora a un modelo lineal en la partición vigente
«A partir de secuencias de video cortas»	16 frames superan a 1 frame (+0,059, IC 95 % [+0,001; +0,116]); el orden de los frames no influye (0/359 cambios)	**Parcial**: la *información de varios instantes* ayuda, la *dinámica* no está demostrada ni modelada
«Precisión útil para la asistencia de expertos»	El plan no define «útil»; precisión por clase 0,73–0,76 (1 de cada 4 predicciones erra); no hubo validación con veterinarios; la probabilidad que ve el usuario está sobreconfiada (confianza media 0,824 frente a acierto 0,744)	**No verificable** con los archivos disponibles

Conclusión sobre la hipótesis. *Parcialmente sustentada*: no se observan evidencias en contra de la factibilidad de una clasificación automática por encima del azar y de los metadatos; sí se observa que el valor agregado de la arquitectura profunda y de la modelización temporal no está respaldado, y que la utilidad para expertos no fue evaluada. Un efecto de contexto de filmación (duración, contenedor, sesión, rotación) explica una parte del rendimiento que no se puede cuantificar con precisión (§10.3).

2.4 Hipótesis implícita del problema («las expresiones son eventos dinámicos»)

La frase de la *Problemática observada* del plan («capturar la evolución temporal … resulta fundamental para obtener una clasificación robusta») es una **motivación**, no un requisito del plan. En respuesta a la devolución docente se la retira de la matriz de cumplimiento (§1.5, punto 3). Se conserva como **observación empírica**: con los datos de este proyecto, el orden temporal no aportó en ninguna de las variantes medidas (atención con frames barajados da predicciones idénticas; GRU rinde peor con el orden real; `docs/registro_de_experimentos.md`, `openspec/project.md`).

3. Dataset

Fuente de todas las cifras: `datos_equinos/resultados/inventario_videos.csv`, `inventario_clips.csv`, `dataset_rechazos_v2.json`, `dataset_frames_alineados_v2.csv`, `particion_clips.json`, procesados por `scripts/a01_dataset.py` y `scripts/a02_duplicados.py` (salidas en `datos/dataset.json`, `datos/duplicados.json`).

3.1 Del video al clip válido

Etapa	Cantidad	Detalle
Videos inventariados	274	138 identificadores de caballo
Videos que generaron al menos un clip	265	9 sin clips (demasiado cortos)
Clips candidatos	393	136 caballos
Clips descartados	34	VENTANA_CORTA: 31, SIN_KEYPOINTS: 3
Clips válidos (dataset de modelado)	**359**	244 videos, **133 caballos**, 5744 frames (16 por clip)
% clips válidos / % videos aprovechados / % caballos	91,3 % / 89,1 % / 96,4 %	sobre candidatos / inventariados / identificados

Clase	Videos inventariados	Clips candidatos	Descartados	Clips válidos	% válidos	Videos con clips válidos	Caballos
Disgustado	110	113	10	103	91,2 %	91	57
Interesado	71	120	2	118	98,3 %	69	60
Sereno	93	160	22	138	86,2 %	84	52
Total	274	393	34	359	91,3 %	244	133

- **Unidad de análisis**: el *clip* (ventana de 5–7 s de un video, ya recodificada) del que se eligen 16 frames. La **etiqueta se asigna al video entero** y se hereda a sus clips (`docs/protocolo_de_etiquetado.md` §1); el recorte de tramos por la etiquetadora sostiene el supuesto de que la expresión dura toda la toma.
- **Inválidos / descartados**: 34 de 393 clips (8,7 %): 31 por `VENTANA_CORTA` (ninguna ventana con 16 mediciones válidas del par ojo–hocico) y 3 por `SIN_KEYPOINTS`. Además, 9 de 274 videos no generaron ningún clip (duración menor al piso de 1 s). **El descarte no es parejo entre clases**: `Sereno` pierde 13,8 % de sus clips, `Disgustado` 8,8 % e `Interesado` 1,7 %. Quedan fuera los clips donde DeepLabCut no mide bien la cara; la población de «caras bien medibles» es la que se evalúa (sesgo de selección documentado, no cuantificable aquí).
- **Frames**: 5 744 = 359 × 16; los 5 744 con `alineado = True` y `origen_alineacion = keypoints` (ninguno interpolado ni anotado a mano en el conjunto vigente).

3.2 Caballos

Medida	Valor
Caballos con clips válidos	133
Clips por caballo (media / mediana / mín–máx)	2,70 / 2 / 1–14
Caballos con un único clip	58 (43,6 %)
Caballos con 5 o más clips	16
10 caballos con más clips acumulan	27,6 % de los clips
Caballos en una sola clase	104
Caballos en dos clases	22
Caballos en las tres clases	7
Caballos en más de una clase	29 (21,8 %), con 145 clips (40,4 %)

Qué significa: el tamaño muestral efectivo está más cerca de los 133 caballos que de los 359 clips (§13). 58 caballos (43,6 %) aportan un único clip, y 10 caballos reúnen el 27,6 % de los clips (el máximo es 14 clips del caballo `037`).

3.3 Distribución por fold (test de cada fold)

Fold (test)	Caballos	Clips	Disgustado	Interesado	Sereno	Caballos D / I / S
0	33	90	36	29	25	13 / 15 / 16
1	33	90	20	28	42	16 / 12 / 14
2	34	90	29	31	30	15 / 19 / 11
3	33	89	18	30	41	13 / 14 / 11

Cada caballo está en exactamente un fold (verificado, §6). La composición dentro de cada fold —train interno, validación interna y test— está en el capítulo 5.

3.4 Características técnicas que difieren entre clases

Clase	Duración P25 (s)	Mediana (s)	P75 (s)	% en 5–7 s	Resoluciones (clips)
Disgustado	2,3	3,2	5,7	27 %	1080x1920 (93), 2560x1440 (8), 640x480 (2)
Interesado	6,0	6,0	7,0	76 %	1080x1920 (91), 640x480 (26), 720x1280 (1)
Sereno	6,0	6,0	7,0	88 %	1080x1920 (138)

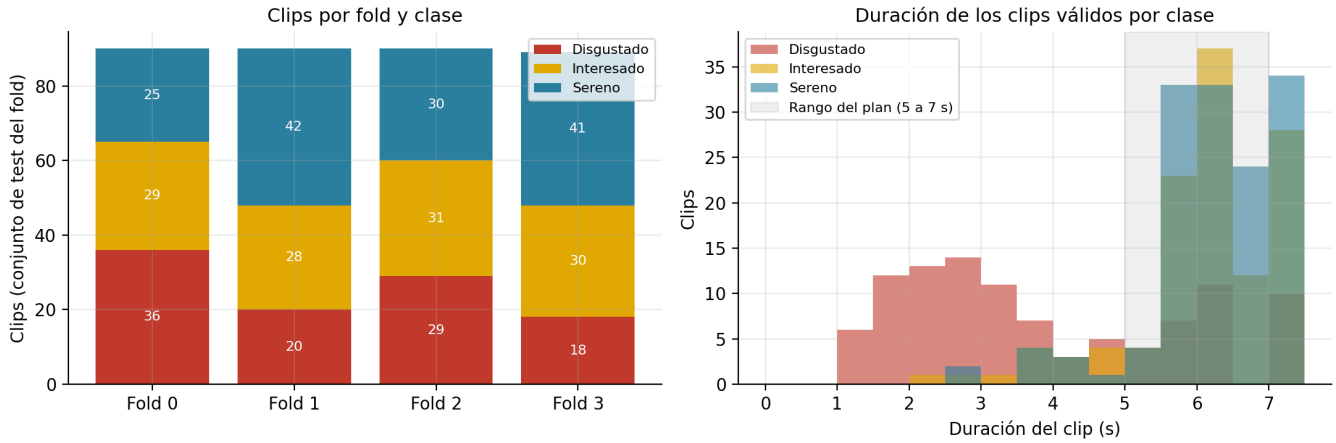


Figura 3.1. Clips por fold y clase (izquierda) y duración de los clips por clase (derecha). La banda gris es el rango de 5 a 7 s que fija el plan.

- **El 33,4 % de los clips válidos (120 de 359) dura menos de 5 s** y 85 menos de 4,5 s. La duración mediana de `Disgustado` es 3,2 s (P25: 2,3 s); la de `Sereno` e `Interesado`, 6,0 s. La clase minoritaria es, sistemáticamente, la de tomas más cortas (son interacciones breves; `docs/protocolo_de_etiquetado.md` §3).
- Las resoluciones atípicas son de una sola clase: 640×480 sólo en `Interesado` (26 clips) y `Disgustado` (2); 2560×1440 sólo en `Disgustado` (8). `Sereno` es 100 % 1080×1920.
- Consecuencia medida en el capítulo 10: **la duración sola predice la clase con F1 macro 0,544 y los metadatos de filmación con 0,618**, sin mirar la cara.

3.5 Duplicados

Prueba	Resultado
SHA-256 de los 274 archivos de video fuente	**0 pares idénticos** (todos los archivos existen y se leyeron)
MD5 de los 5 744 recortes alineados	**0 grupos** de recortes idénticos entre clips distintos
Hash perceptual (dHash 256 bits) de los 5 744 recortes	**0 grupos** de recortes visualmente idénticos entre clips distintos; ninguno cruza folds ni clases
Frames repetidos dentro de un mismo clip	0
Solapamiento temporal entre clips de un mismo video	0 (clips contiguos, sin solape)
Videos con clips en más de un fold	0
Firma perceptual de video (8 frames, Hamming ≤ 6 de 64 bits)	10 pares de videos con escena parecida, **todos** `Disgustado`; 6 de ellos entre identificadores de caballo distintos (`709`, `710`, `711`, `712`, `705`, `707`). Tienen distinta duración y contenido: son **tomas de la misma sesión y lugar (27/08/2026), no copias**
Posible mismo caballo con dos identificadores (`123` y `169`)	**No pudo verificarse con los archivos disponibles.** Ambos son `Interesado`, filmados con 34 s de diferencia en el mismo box (04/10/2025), están en folds 3 y 0, y el cribado por características los ubica 2.º de todos los pares entre folds (`datos/identidades.json`). Afecta a 5 clips (1,4 %)

No se observan evidencias de duplicación de material. El riesgo remanente es **de sesión y de lugar**, no de copia (§6.4).

3.6 Consistencia de nombres y etiquetas

- El `id_caballo` sale del prefijo numérico del nombre de archivo (`obtener_id_caballo`); coincide en los 393 clips con el prefijo del clip y del video de origen; 3 dígitos en todos los casos.
- Las tres clases se escriben igual en todos los CSV/JSON; 0 videos con la misma clase asignada de dos formas; 0 nombres que colapsen al normalizarlos.
- Hay 7 nombres con espacios y 6 con «Copia de…» (resto de ediciones manuales); 246 `.mp4`, 15 `.mkv`, 13 `.avi`. **La carpeta (clase) condiciona el contenedor**: `Sereno` es 100 % `.mp4`/H.264, mientras que `.mkv` aparece sólo en `Disgustado` y `.avi` casi sólo en `Interesado` (§10.3).
- 40 videos viven en subcarpetas de trabajo (`Seleccionar cabeza?` y `Se tapa una parte de la cara`); se suman a su clase por declaración explícita en `equinos/catalogo.py`, y `Separar cabeza?` ya no existe (verificado en `docs/protocolo_de_etiquetado.md` §4).

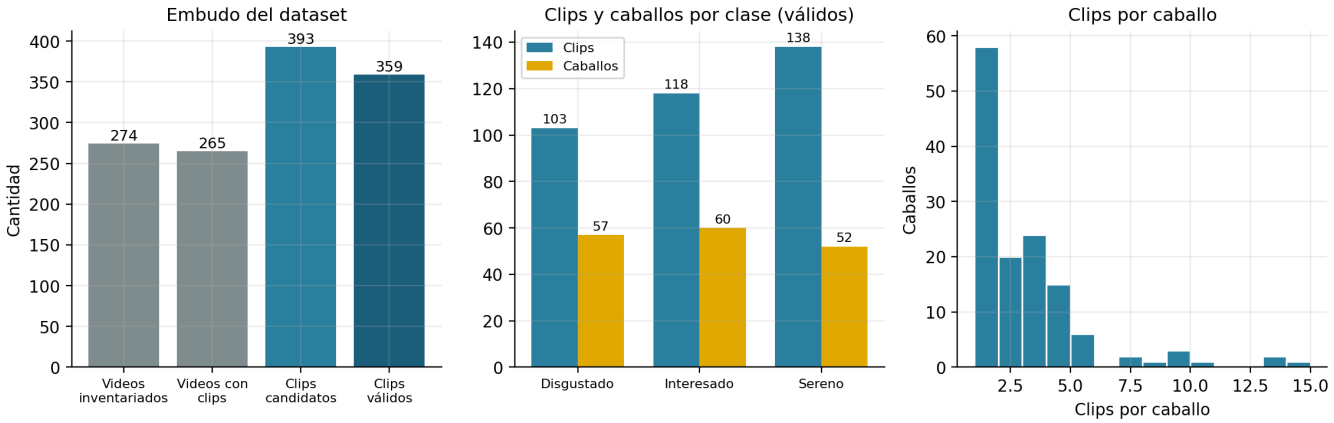


Figura 3.2. Embudo del dataset, clips y caballos por clase, y distribución de clips por caballo.

4. Balance de clases

4.1 Criterio (declarado antes de calcular)

Se usa el *imbalance ratio* (IR = n de la clase mayor / n de la clase menor), la medida habitual en la literatura de datos desbalanceados (p. ej., Fernández et al., 2018, *Learning from Imbalanced Data Sets*, Springer). **No existe un umbral normativo universal**; los cortes siguientes son una convención de esta auditoría, fijada en `scripts/a03_balance_folds_leakage.py` antes de calcular y sometida a un análisis de sensibilidad:

IR	Clasificación
≤ 1,2	BALANCEADO
> 1,2 y ≤ 1,5	RAZONABLEMENTE BALANCEADO
> 1,5 y ≤ 3	MODERADAMENTE DESBALANCEADO
> 3	FUERTEMENTE DESBALANCEADO

Se aplica por separado a clips y a caballos, porque la unidad que importa estadísticamente es el caballo (capítulo 13).

4.2 Resultado global

Clase	Clips	% clips	Caballos	% caballos
Disgustado	103	28,7 %	57	42,9 %
Interesado	118	32,9 %	60	45,1 %
Sereno	138	38,4 %	52	39,1 %
Total	359	100 %	133 (distintos)	—

Los % de caballos se calculan sobre los 133 caballos distintos y suman más de 100 % porque 29 caballos tienen clips en más de una clase.

Unidad	Ratio mayor : menor	Clasificación (criterio declarado)
Clips	1,34 : 1	RAZONABLEMENTE BALANCEADO
Caballos	1,15 : 1	BALANCEADO

Sensibilidad al criterio

Cortes del ratio (balanceado / razonable / moderado)	Clips	Caballos
1,20 / 1,50 / 3,00	RAZONABLEMENTE BALANCEADO	BALANCEADO
1,10 / 1,30 / 2,00	MODERADAMENTE DESBALANCEADO	RAZONABLEMENTE BALANCEADO
1,25 / 2,00 / 4,00	RAZONABLEMENTE BALANCEADO	BALANCEADO

- Con el criterio declarado: **RAZONABLEMENTE BALANCEADO en clips** (IR 1,34) y **BALANCEADO en caballos** (IR 1,15). La entropía normalizada del reparto de clips es 0,993 (1 = reparto uniforme).
- **Evidencia que matiza el veredicto.** (a) Con cortes más estrictos (1,1 / 1,3 / 2), los clips pasan a MODERADAMENTE DESBALANCEADO: la categoría depende del criterio, aunque la diferencia real (38,4 % frente a 28,7 %) es pequeña. (b) `Sereno` tiene *menos* caballos (52) pero *más* clips (138) que las otras clases: 2,65 clips por caballo contra 1,81 de `Disgustado`; el desbalance por caballos es menor que el de clips, lo que favorece al modelo (más variedad de individuos en la clase minoritaria de lo que sugieren los clips).
- Efecto práctico: la accuracy mayoritaria es 0,384, por lo que la métrica correcta es F1 macro; los pesos de clase de la pérdida usan la raíz cuadrada de la frecuencia inversa (`estrategia_pesos = "raiz"`).

4.3 Balance dentro de los folds

El balance **global** no se transmite a cada subconjunto. Las particiones se arman por caballo y **no se estratifican por clase** (`particion.construir`). El detalle de cada subconjunto está en el capítulo 5; en resumen,

7 de 12 subconjuntos (test, train interno y validación interna de 4 folds) son BALANCEADOS o RAZONABLEMENTE BALANCEADOS y **5 son MODERADA o FUERTEMENTE desbalanceados**: los tests de los folds 1 y 3 (IR 2,10 y 2,28, con 20–22 % de `Disgustado`) y las validaciones internas de los folds 0 (IR 4,18: 65,7 % `Sereno`), 1 (2,83) y 2 (2,57).

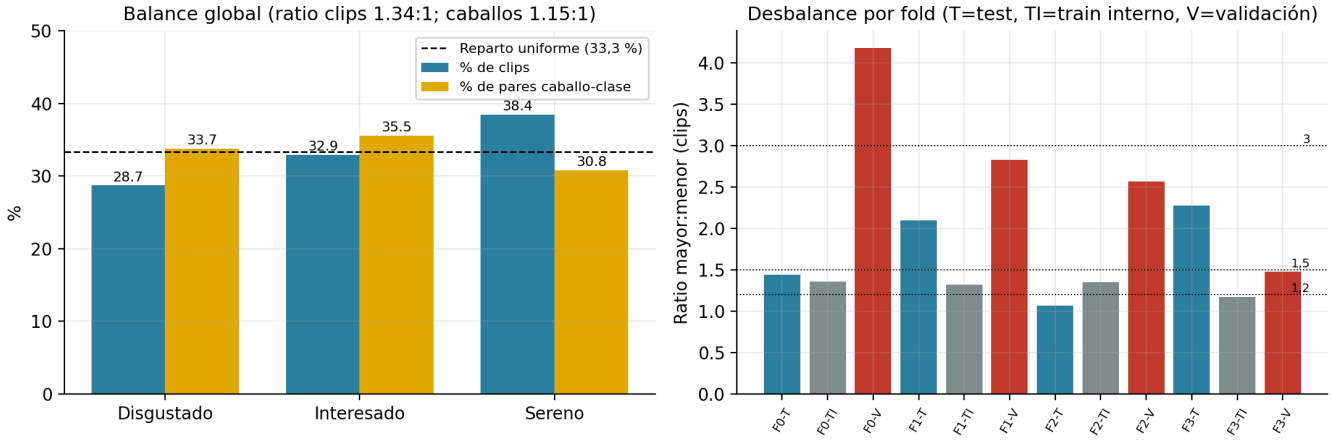


Figura 4.1. Balance global (izquierda) y ratio mayor:menor por fold y conjunto (derecha), con los cortes del criterio.

Lectura. El balance global es aceptable; la variabilidad de composición entre folds (el recall y el F1 de `Disgustado` por fold se mueven en consecuencia) contribuye a la dispersión del F1 macro entre folds (0,677–0,795) y justifica informar la media ± desvío en lugar de un único número.

5. Folds, entrenamiento interno, validación interna y test

5.1 Cómo se construyen

1. **Folds externos (test).** `particion.construir`: los 133 caballos se ordenan por cantidad de clips (descendente, desempate por id) y se asignan, uno a uno, al fold con menos clips acumulados. Es una *réplica del reparto voraz de* `GroupKFold`, **sin semilla y sin estratificar por clase**. **No coincide con** `sklearn.model_selection.GroupKFold`: comparadas, las dos particiones asignan el mismo fold al 0,382 de los clips (los tamaños de fold sí son los mismos: 90/90/90/89). El docstring del módulo habla de «réplica determinista de `GroupKFold`»: es cierto en el algoritmo general, pero no en el reparto exacto. No afecta la validez, sí la afirmación de equivalencia.
2. **Corte interno.** Dentro de cada fold, `dividir_por_ejemplar(train_val, 0,25)` separa **train interno** y **validación interna** por caballo, también de forma determinista.
3. El test se usa **una sola vez**, tras cargar el mejor checkpoint (§7).

5.2 Composición de cada subconjunto

Fold	Conjunto	Caballos	Clips	Disgustado	Interesado	Sereno	Ratio	Categoría
0	Test	33	90	36 (40,0 %)	29 (32,2 %)	25 (27,8 %)	1,44 : 1	Razonablemente balanceado
0	Train interno	93	199	56 (28,1 %)	76 (38,2 %)	67 (33,7 %)	1,36 : 1	Razonablemente balanceado
0	Validación interna	7	70	11 (15,7 %)	13 (18,6 %)	46 (65,7 %)	4,18 : 1	Fuertemente desbalanceado
1	Test	33	90	20 (22,2 %)	28 (31,1 %)	42 (46,7 %)	2,1 : 1	Moderadamente desbalanceado
1	Train interno	93	199	59 (29,6 %)	78 (39,2 %)	62 (31,2 %)	1,32 : 1	Razonablemente balanceado
1	Validación interna	7	70	24 (34,3 %)	12 (17,1 %)	34 (48,6 %)	2,83 : 1	Moderadamente desbalanceado
2	Test	34	90	29 (32,2 %)	31 (34,4 %)	30 (33,3 %)	1,07 : 1	Balanceado
2	Train interno	92	199	54 (27,1 %)	73 (36,7 %)	72 (36,2 %)	1,35 : 1	Razonablemente balanceado
2	Validación interna	7	70	20 (28,6 %)	14 (20,0 %)	36 (51,4 %)	2,57 : 1	Moderadamente desbalanceado
3	Test	33	89	18 (20,2 %)	30 (33,7 %)	41 (46,1 %)	2,28 : 1	Moderadamente desbalanceado
3	Train interno	93	197	59 (29,9 %)	69 (35,0 %)	69 (35,0 %)	1,17 : 1	Balanceado
3	Validación interna	7	73	26 (35,6 %)	19 (26,0 %)	28 (38,4 %)	1,47 : 1	Razonablemente balanceado

Proporción de cada subconjunto sobre los 359 clips: test ≈ 25 % (89–90 clips), validación interna ≈ 19–20 % (70–73 clips), train interno ≈ 55 % (197–199 clips); en caballos, ≈ 33 de test, 7 de validación y ≈ 93 de train interno por fold.

5.3 Hallazgo: la validación interna son los caballos con más clips

`dividir_por_ejemplar` ordena los caballos del `train_val` por cantidad de clips y **asigna a validación los primeros hasta cubrir el 25 % de los clips**. El resultado (`datos/validacion_interna_composicion.json`):

- La validación interna son **los 7 caballos con más clips** de cada fold, con **10 clips por caballo en promedio** (7 a 14), frente a 2,1 clips por caballo en el train interno y 2,7 en el conjunto completo.
- Por eso el train interno **pierde justamente a los caballos más representados** y la validación pesa por igual a esos 7 individuos, mientras que el test sí es una muestra de todos los caballos del fold (≈ 33).

- Cinco o seis de los 7 caballos de validación de cada fold tienen clips en más de una clase.
- La validación interna de cada fold queda **desbalanceada** (IR de 1,47 a 4,18; 65,7 % `Sereno` en el fold 0).

Es la base sobre la que se elige la época y los hiperparámetros (dropout 0,3, pesos `raiz`). **Es una debilidad real del diseño**, no una fuga: el test no interviene (§7). Sus efectos medibles son la elección de época ruidosa (20 a 40 entre folds con la misma semilla; 13 a 50 entre semillas) y una métrica de validación que no es un buen proxy: el test fue **igual o mayor** que la validación en los 4 folds (diferencia media +0,027).

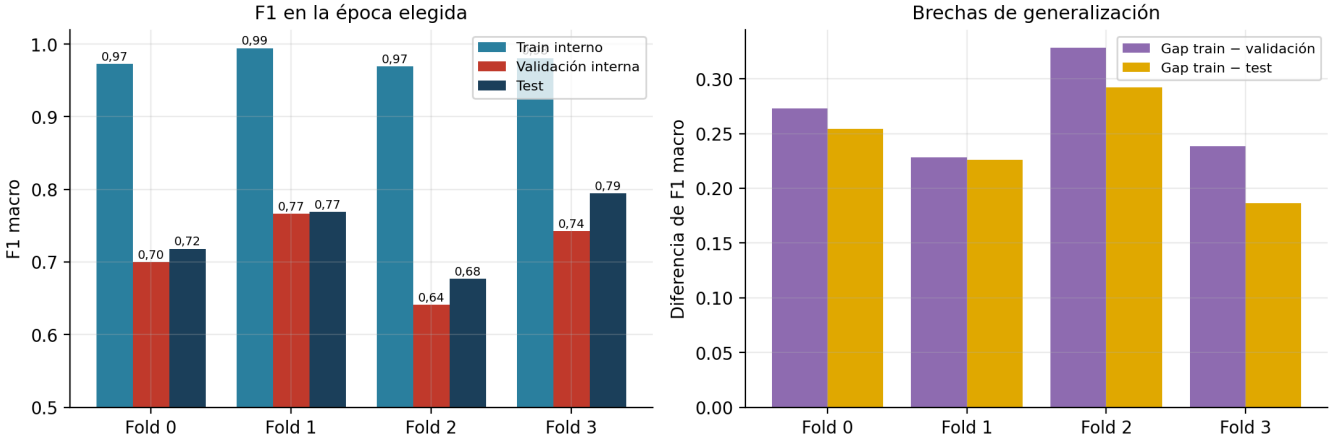


Figura 5.1. F1 macro de train interno, validación interna y test en la época elegida (izquierda) y brechas (derecha).

6. Fuga de información (*data leakage*)

6.1 Qué variable agrupa y por qué

- **Variable de grupo:** `id_caballo`, el prefijo numérico del nombre de archivo (`equinos.catalogo.obtener_id_caballo`), usada en `particion.construir` (folds externos), `particion.dividir_por_ejemplar` (corte interno) y `clasificacion.folds_por_ejemplar`.
- **Por qué evita memorizar individuos.** Los clips de un caballo son visualmente casi idénticos entre sí (misma cabeza, mismo fondo, misma luz), y **el caballo predice la etiqueta**: 104 de 133 caballos (78,2 %) aparecen en una sola clase. Un modelo que reconoce al individuo «acierta» sin mirar la expresión. Medido por esta auditoría con el conjunto vigente (`scripts/a19_identidad.py`): un predictor que usa **únicamente el id del caballo** obtiene **F1 macro 0,613** con una partición ingenua por clip (≈ 80 % de los clips de test pertenecen a caballos vistos en entrenamiento) y **0,183** con la partición por caballo (= mayoritaria): la fuga que el protocolo elimina vale ≈ +0,43 de F1 macro espurio.
- **Caballos en varias clases:** 29 (22 en dos clases y 7 en las tres; 145 clips). Se agrupa por caballo y **no** por el par caballo-clase: con el par, un mismo animal quedaría de ambos lados del corte.

6.2 Verificaciones ejecutadas (con aserciones)

`scripts/a03_balance_folds_leakage.py` falla si alguna de estas condiciones no se cumple:

Comprobación	Resultado
Caballos en más de un fold	**0** de 133
Videos de origen en más de un fold	**0** de 244
Clips en más de un fold	**0** de 359
Intersección caballo / video / clip entre `train_val` y test, en cada uno de los 4 folds	**0** (12 aserciones)
Intersección de caballos entre train interno, validación interna y test, en cada fold	**0**
`train_interno + validación + test` = 359 clips, sin repetidos	Sí
Las 359 predicciones vigentes corresponden exactamente a los folds persistidos	Sí (`particion_clips.json` se reescribió a las 15:50, 7 min después de la evaluación de las 15:43; el contenido es consistente)

El código tiene, además, aserciones propias que abortan la ejecución: `particion.verificar`, `dividir_por_ejemplar` y `entrenar_mil_multimodal` (`assert not cruce` para train interno–test y validación–test).

6.3 Estadísticas de normalización, selección de épocas e hiperparámetros

Punto	Estado	Evidencia
¿Se ajustan estadísticas de normalización con el test?	**No**	El canal visual no se estandariza (características crudas del backbone); el canal geométrico se normaliza **dentro de cada frame** con la distancia ojo–hocico del mismo frame (sin estadísticas globales); la ResNet-18 usa las constantes fijas de ImageNet. En los baselines lineales el `StandardScaler` va dentro de un `Pipeline` y se ajusta con `fit(X[entrena])` de cada fold
¿Se calculan los pesos de clase con datos de test?	No	`pesos_de_clase` sobre el train interno
¿La época se elige con el test?	**No**	Prueba empírica: se re-entrenaron los 4 folds **con las etiquetas del test permutadas al azar**; la mejor época, las curvas de validación y **los pesos finales resultaron idénticos** a los originales en los 4 folds (`datos/early_stopping_sobreajuste.json`). El test sólo se predice después de cargar el mejor estado
¿Los hiperparámetros se eligen con el test?	**No directamente**	Dropout 0,3 y pesos `raiz` se eligieron con el F1 de validación interna (`docs/informe_mejora_pipeline_mil.md` §2.6)
Duplicación de frames	No	§3.5: 0 recortes idénticos entre clips; 0 frames repetidos dentro de un clip
Archivos derivados	Sin etiquetas	`pose_seleccionada_v2.csv` y `caracteristicas_backbone_v2.npz` se derivan de los frames; la huella de las características coincide con la registrada en el modelo de producción (`806a6f478408ab0b`)

6.4 Riesgos residuales (no detectados como fuga, pero a declarar)

1. **Selección de hiperparámetros y de arquitectura no anidada.** Las variantes (≥ 12 evaluaciones sobre los mismos 359 clips y los mismos folds; `docs/registro_de_experimentos.md`) se compararon contra los mismos tests. La validación interna de un fold está formada por caballos que son *test* en otros folds, de modo que la elección de dropout/pesos con la media de las validaciones internas incorpora, de forma indirecta, información de los tests de los otros folds. Con tres valores de dropout indistinguibles (0,687 / 0,690 / 0,707 de F1 de validación) el efecto es despreciable; la elección de *arquitectura* (MIL en lugar de un frame con voto o GRU) sí se hizo mirando el F1 de CV. El 0,740 puede tener un sesgo optimista pequeño que no se puede cuantificar con estos datos. **Contrapeso:** el modelo vigente no es el de mayor F1 entre los medidos (la CV anidada dio 0,784 y no se adoptó).
2. **Sesión y lugar.** El grupo es el caballo, no la sesión. Caballos distintos de la misma sesión (misma fecha, mismo box) pueden caer en folds distintos y compartir fondo, luz y dispositivo. Sin mirar la cara, la **fecha de sesión inferida del nombre** logra F1 0,535, los metadatos técnicos 0,556 y ambos 0,605 (§10.3). La partición actual no controla este efecto.
3. **Identidad por nombre de archivo.** Un mismo caballo con dos identificadores atraviesa el control (caso `123/169`, §3.5; no verificable).
4. **Videos con varios animales** (`Seleccionar cabeza?`, 33 videos): la identidad del animal enfocado puede no coincidir con el id del archivo.

6.5 Veredicto

No se observan evidencias de fuga de información por individuo, video, clip ni frame. El protocolo de separación es sólido y está verificado por código. Persiste riesgo de **confusión de contexto** (sesión, lugar, dispositivo), que no es fuga de identidad pero actúa de forma análoga, y un sesgo optimista pequeño por selección no anidada de arquitectura.

7. Validación cruzada, validación interna y *early stopping*

7.1 Protocolo

Elemento	Valor	Fuente
Validación cruzada externa	4 folds agrupados por caballo (≈ 33 caballos de test por fold)	`particion.FOLDS = 4`, `particion_clips.json`
Por qué 4 y no 5	Con 5 folds hay folds con ~2 clips de `Disgustado` en test (comentario de `particion.py`; no se re-verificó)	`equinos/particion.py`
Validación interna	25 % de los clips del `train_val`, por caballo (7 caballos), determinista	`particion.dividir_por_ejemplar`
Métrica de selección	**F1 macro de la validación interna** (`clasificacion.f1_macro`)	`entrenar_mil_multimodal`
Criterio de mejora	estricto (`f1_val > mejor`); un empate no reemplaza al checkpoint	ídem
Paciencia / máximo de épocas	**10 / 100** (valores por defecto: `evaluar_v2.py` no los pasa)	ídem
Checkpoint	copia del `state_dict` de la mejor época en memoria; se restaura antes de predecir el test	ídem
Optimizador	Adam, lr 1e-3, `weight_decay` 1e-4, batch 32; sin *scheduler*	ídem
Pérdida	entropía cruzada con pesos de clase `raiz` (raíz de la frecuencia inversa, calculada sobre el train interno)	ídem
Test	se predice **una sola vez**, tras cargar el mejor estado	ídem (verificado por inspección del código)
Épocas del modelo de producción	`ceil(media de la mejor época)` = 29, sin validación (usa los 359 clips)	`evaluar_v2.py`, `mil_multimodal_produccion.json`

7.2 Resultado por fold

Fold	Mejor época	Épocas ejecutadas	Métrica validación (F1 macro)	Métrica test (F1 macro)	F1 train interno
0	28	38	0,700	0,718	0,973
1	26	36	0,766	0,769	0,994
2	20	30	0,641	0,677	0,969
3	40	50	0,742	0,795	0,981
Media	28,5	38,5	0,712	0,740	0,979

- El máximo de 100 épocas **nunca se alcanzó**: la ejecución se detiene exactamente 10 épocas después de la mejor (paciencia agotada).
- **La época se elige con la validación y no con el test**, y esto está verificado de tres maneras: (1) inspección del código (el único `predecir(dl_pru)` ocurre después de `load_state_dict(mejor)`); (2) la prueba del test alterado de §6.3 (pesos idénticos aun con las etiquetas de test permutadas); (3) la re-ejecución con la semilla 42 reproduce las curvas de validación.
- **La mejor época varía de 20 a 40 entre folds** (media 28,5, DE 8,4) con la misma semilla; entre semillas el rango sube a 13–50 (§14). El F1 de validación de la mejor época es un *máximo sobre una serie ruidosa* (7 caballos): el F1 de validación medio en la ventana de ±3 épocas alrededor de la mejor es 0,03–0,04 más bajo que el máximo en los 4 folds (`datos/early_stopping_tabla.csv`), de modo que **la métrica de validación de la mejor época es optimista por selección**; la métrica de test, no.
- El test es **mayor o igual que la validación en los 4 folds** (diferencia media de +0,027). Es la comprobación empírica de que la estimación de test no está inflada por la selección; la dirección opuesta (test > validación) es coherente con una validación interna más difícil o más ruidosa que el test (§5.3), no con una fuga.

7.3 Qué no se puede afirmar

- Que la época 28,5 sea «la» correcta: la curva de F1 de validación es una meseta ruidosa y las alternativas probadas (CV anidada con curva promediada) no la estabilizaron (`docs/registro_de_experimentos.md`).
- Que el *early stopping* reduzca la memorización: la detiene antes de que *empeore* el F1 de validación, pero el F1 de train ya es 0,97–0,99 en la época elegida (capítulo 8).

8. Sobreajuste

8.1 Evidencia disponible

Los historiales por época **existen en el artefacto vigente**: `objetivo3_evaluacion_v2.json`, `por_fold[*].curva`, con `loss_train`, `loss_train_eval` (train interno sin dropout, comparable con la pérdida de validación), `f1_train`, `acc_train`, `loss_val`, `f1_val`, `acc_val`. No fue necesario re-entrenar para obtenerlos; sí se re-entrenó para comprobar que el código vigente reproduce esas curvas (idénticas con la semilla 42) y para medir la variabilidad entre semillas (§14).

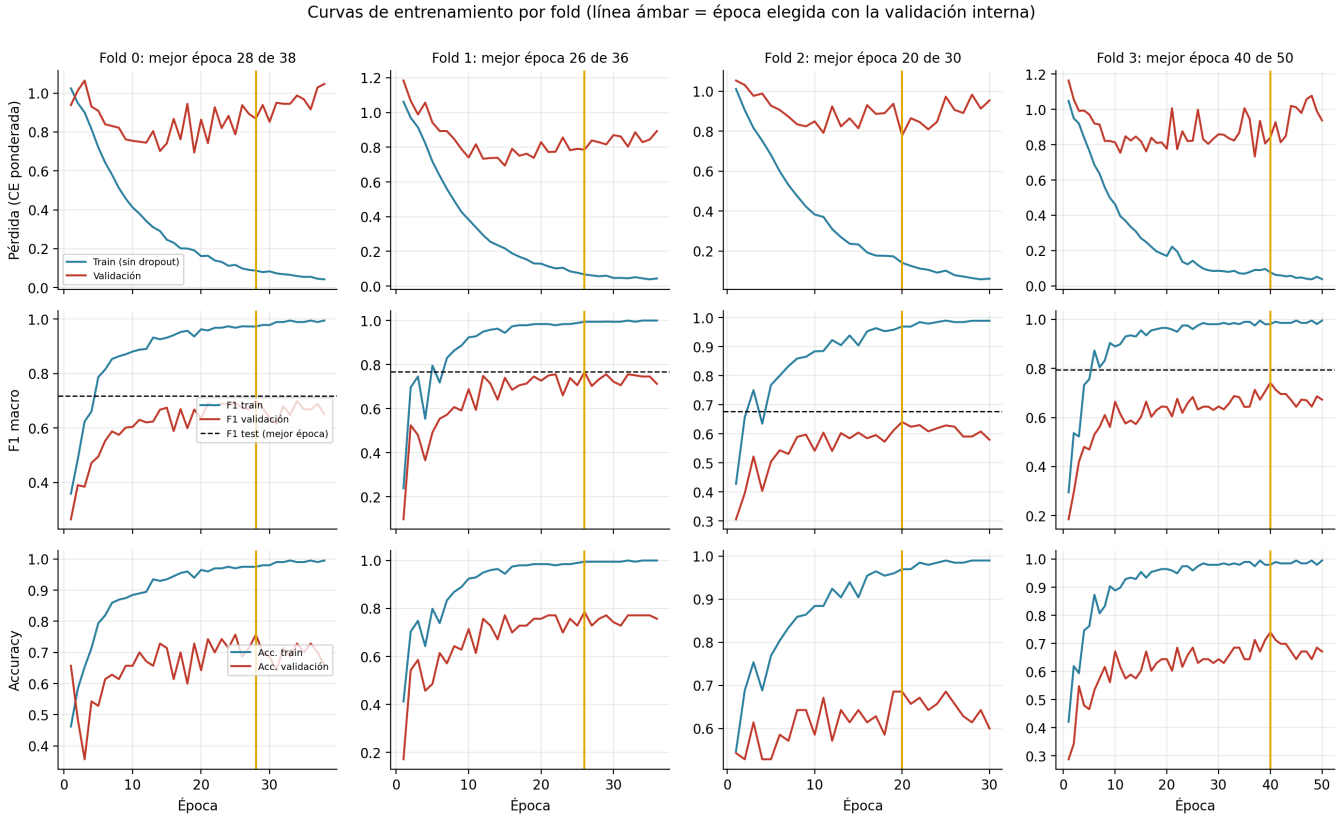


Figura 8.1. Pérdida, F1 macro y accuracy de train (interno, sin dropout) y validación por época, para cada fold. La línea ámbar es la época elegida con la validación; la línea punteada negra es el F1 de test en esa época.

8.2 Brechas

Fold	F1 train	F1 val	F1 test	Gap train−val	Gap train−test	Val−test	Acc. train	Acc. val
0	0,973	0,700	0,718	0,273	0,254	-0,018	0,975	0,757
1	0,994	0,766	0,769	0,228	0,226	-0,002	0,995	0,786
2	0,969	0,641	0,677	0,329	0,292	-0,036	0,970	0,686
3	0,981	0,742	0,795	0,238	0,186	-0,052	0,980	0,740
Media	0,979	0,712	0,740	0,267	0,240	-0,027	0,980	0,742

Fold	Época de mínima pérdida val.	Mejor época (F1)	Pérdida val. mínima	Pérdida val. en la mejor época	Pérdida val. al final	F1 val medio (mejor ±3 épocas)	F1 val al final	Δ F1 val (final − mejor)
0	19	28	0,695	0,869	1,047	0,666	0,650	-0,050
1	15	26	0,694	0,786	0,893	0,723	0,713	-0,054
2	20	20	0,778	0,778	0,953	0,612	0,579	-0,061
3	37	40	0,733	0,841	0,938	0,706	0,673	-0,069

Lectura de los números:

- **El modelo memoriza el train interno en los 4 folds**: F1 train 0,97–0,99 (accuracy 0,97–1,00) contra 0,64–0,77 en validación. El gap train−validación es 0,267 en promedio (0,228–0,329) y train−test 0,240 (0,186–0,292); ambos son varias veces mayores que la dispersión entre folds del F1 (DE 0,052) y que el ruido de las semillas (DE 0,015).
- **La pérdida de validación ya está subiendo cuando se elige la época.** Su mínimo se alcanza 3–11 épocas antes que el máximo de F1 en 3 de los 4 folds y en la misma época en el fold 2 (épocas 19, 15, 20, 37 frente a 28, 26, 20, 40), y al final de la ejecución es 0,18–0,35 mayor que en su mínimo: el modelo gana aciertos mientras pierde calibración. Confirmado con las probabilidades de test: confianza media **0,824** frente a acierto **0,744** (ECE 0,081); el 44,6 % de los clips recibe confianza > 0,9 y acierta el 89,4 % de ellos (§11.4).
- **El F1 de validación cae 0,05–0,07 en las 10 épocas posteriores a la mejor** (parte de la caída es regresión a la media tras elegir un máximo ruidoso).
- **La estimación de test no está inflada**: test ≥ validación en 4/4 folds.
- **La memorización no es exclusiva de la cabeza profunda.** El baseline lineal sobre la media de los 16 frames también alcanza **F1 train 1,000** en los 4 folds (brecha train−test 0,259, equivalente a la del MIL: 0,240) y generaliza igual. La brecha es en buena medida consecuencia de la dimensionalidad (512 características por frame; ≈ 199 clips y ≈ 93 caballos de entrenamiento), no de la complejidad temporal.

8.3 Clasificación

Escala (declarada antes de aplicarla, sin umbrales numéricos arbitrarios): se clasifica por *consecuencias observables*, no por el tamaño de un gap.

Categoría	Condición observable
SIN EVIDENCIA	Train y validación no se separan por más que el ruido entre folds/semillas
LEVE	Hay separación, pero la métrica de validación no se degrada con más entrenamiento y las probabilidades están calibradas
MODERADO	Hay separación clara en todos los folds, la **estimación de test no está sesgada** (la parada temprana la contiene) y aparecen señales de pérdida de calidad *distintas del F1* (calibración, pérdida de validación creciente)
IMPORTANTE	La métrica de validación o de test se degrada materialmente con el entrenamiento, la mejor época es de las primeras, o un modelo de menor capacidad rinde claramente más
INSUFICIENTE	No hay historial o validación independiente con que juzgarlo

Resultado: MODERADO.

- Contra «SIN EVIDENCIA» y «LEVE»: la separación (0,27) es 5 veces el desvío entre folds y está en 4/4 folds; la pérdida de validación sube y la confianza excede el acierto.
- Contra «IMPORTANTE»: el test acompaña a la validación (≥ en 4/4), la mejor época no es temprana (20–40), y un modelo lineal con la misma brecha rinde lo mismo (0,741), de modo que **no hay evidencia de que un modelo de menor capacidad generalice mejor** en este conjunto.
- **Evidencia contradictoria que debe mostrarse:** (a) un gap train−test de 0,24 es grande en términos absolutos y, por convención de muchos autores, se llamaría *importante*; la clasificación MODERADO depende de que el efecto sobre la estimación de test es nulo gracias a la parada temprana. (b) El F1 de validación cae después de la mejor época. (c) La interfaz muestra probabilidades sobreconfiadas.
- **No debe afirmarse que no hay sobreajuste.** La redacción correcta: *«el modelo sobreajusta el conjunto de entrenamiento; la parada temprana sobre una validación separada por caballo mantiene la estimación de test estable y consistente con la validación; las probabilidades emitidas están sobreconfiadas»*.

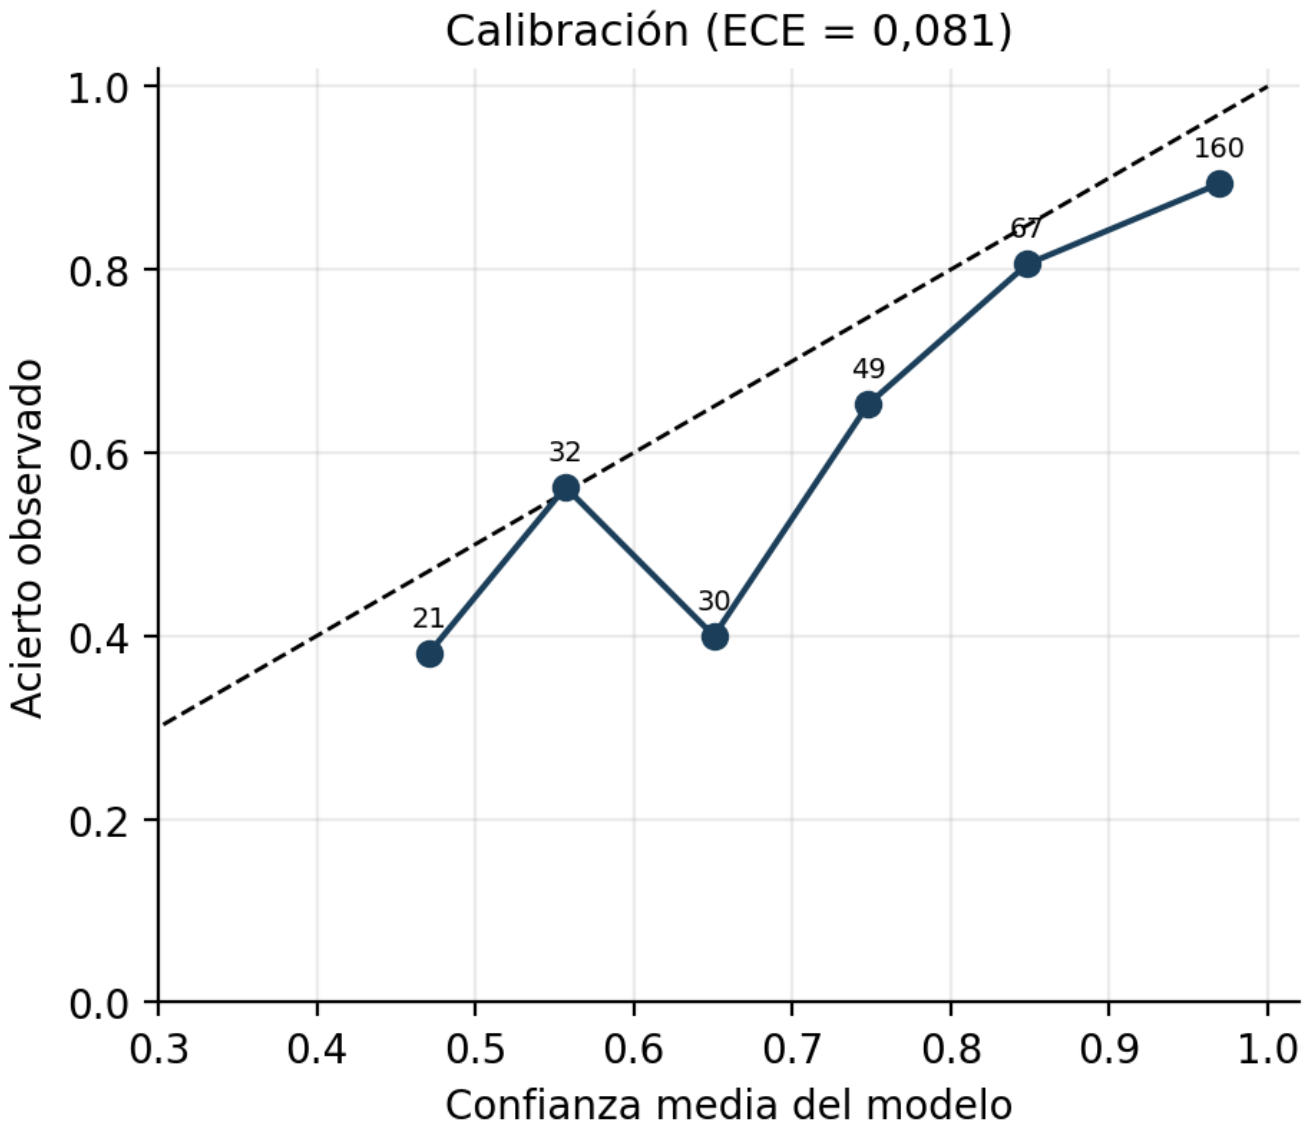


Figura 8.2. Calibración de las probabilidades del modelo de cada fold sobre su test (fuera de muestra); los números son clips por intervalo.

9. Rendimiento: métricas, estabilidad entre folds, confusiones y cifras históricas

9.1 El valor vigente (único)

Archivo que constituye la evaluación vigente: `datos_equinos/resultados/objetivo3_evaluacion_v2.json` (generado por `scripts/evaluar_v2.py`; re-ejecutado el 25/09/2026 con resultado idéntico). Es también el archivo del que lee la interfaz (`clasificacion.ARCHIVO_EVALUACION`).

Métrica (fuera de muestra, 359 clips, 133 caballos)	Valor
F1 macro (media de los 4 folds ± DE muestral)	**0,740 ± 0,052**
IC 95 % del F1 macro (bootstrap por caballo, 2 000 réplicas, F1 agrupado)	[0,677; 0,797]
F1 macro agrupado (las 359 predicciones juntas)	0,742
Accuracy	0,744 (267/359)
Balanced accuracy	0,742
F1 ponderado agrupado	0,743

Verificación de la métrica. `clasificacion.f1_macro` es una implementación propia de la media **no ponderada** del F1 por clase (cada clase pesa igual). Se comprobó contra `sklearn.metrics.f1_score(average="macro", labels=CLASES)` en los 4 folds con tolerancia 10^{-12}: coinciden. Hay **dos formas de «F1 macro»** que no deben mezclarse: la **media de los F1 macro por fold (0,740)**, que es la que informa el proyecto, y el F1 macro de las predicciones agrupadas (0,742). La desviación estándar usa $n-1$ (0,0524); con n sería 0,0454. Con sólo 4 folds, es una estimación gruesa de la variabilidad.

9.2 Estabilidad entre folds

Fold	n	F1 macro	Accuracy	Balanced acc.	F1 Disgustado	F1 Interesado	F1 Sereno
0	90	0,718	0,722	0,720	0,754	0,721	0,680
1	90	0,769	0,767	0,782	0,769	0,800	0,737
2	90	0,677	0,678	0,677	0,643	0,721	0,667
3	89	0,795	0,809	0,782	0,686	0,889	0,809
Media ± DE	359	**0,740 ± 0,052**	0,744 ± 0,057				

Medida	Valor
F1 macro media entre folds	0,740
Desvío estándar (n−1)	0,052
Desvío estándar poblacional (n)	0,045
Mínimo (fold 2)	0,677
Máximo (fold 3)	0,795
Rango	0,118
Coeficiente de variación	7,1 %

El fold 2 es el peor (0,677) y el fold 3 el mejor (0,795): una diferencia de 0,118, dentro de lo que cabe esperar con ≈ 33 caballos por fold y composiciones de clase distintas (capítulo 4). **No hay folds colapsados**, pero la dispersión es 2,6 veces la del baseline lineal (DE 0,020).

9.3 Precision, recall y F1 por clase

Clase	Precision	Recall	F1	Soporte
Disgustado	0,740	0,689	0,714	103
Interesado	0,764	0,797	0,780	118
Sereno	0,729	0,739	0,734	138
Macro	0,744	0,742	0,742	359

Métricas calculadas sobre las 359 predicciones fuera de muestra agrupadas; la media de F1 por fold (0,740) difiere de la agrupada (0,742) por el promedio.

Fold	Clase	Precision	Recall	F1	Soporte
0	Disgustado	0,788	0,722	0,754	36
0	Interesado	0,688	0,759	0,721	29
0	Sereno	0,680	0,680	0,680	25
1	Disgustado	0,789	0,750	0,769	20
1	Interesado	0,703	0,929	0,800	28
1	Sereno	0,824	0,667	0,737	42
2	Disgustado	0,667	0,621	0,643	29
2	Interesado	0,733	0,710	0,721	31
2	Sereno	0,636	0,700	0,667	30
3	Disgustado	0,706	0,667	0,686	18
3	Interesado	1,000	0,800	0,889	30
3	Sereno	0,750	0,878	0,809	41

9.4 Matrices de confusión

Global (agregada sobre los 4 folds; filas = clase real):

	Pred. Disgustado	Pred. Interesado	Pred. Sereno	Total
Real Disgustado	71	13	19	103
Real Interesado	5	94	19	118
Real Sereno	20	16	102	138
Total predicho	96	123	140	359

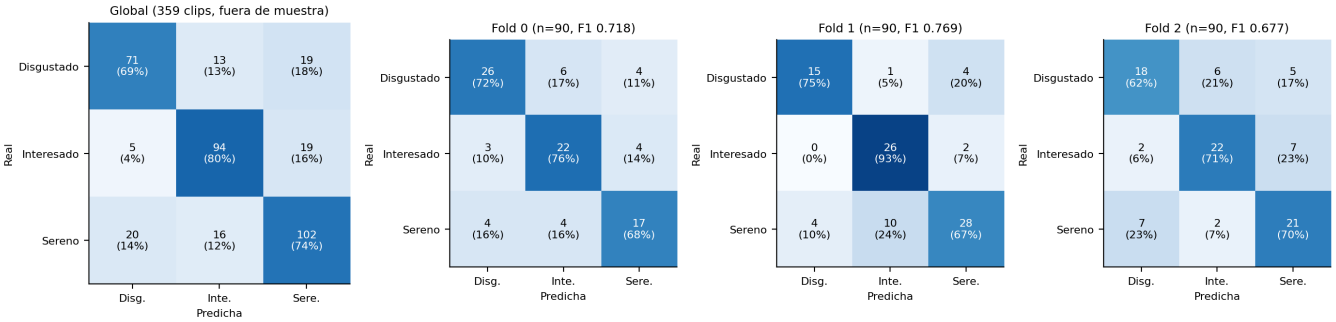


Figura 9.1. Matriz de confusión global (izquierda) y de los folds 0 a 2; la del fold 3 está en la tabla de abajo. Porcentajes por fila.

Por fold:

Fold 0 (n = 90, F1 macro 0,718)

	Pred. Disgustado	Pred. Interesado	Pred. Sereno	Total
Real Disgustado	26	6	4	36
Real Interesado	3	22	4	29
Real Sereno	4	4	17	25
Total predicho	33	32	25	90

Fold 1 (n = 90, F1 macro 0,769)

	Pred. Disgustado	Pred. Interesado	Pred. Sereno	Total
Real Disgustado	15	1	4	20
Real Interesado	0	26	2	28
Real Sereno	4	10	28	42
Total predicho	19	37	34	90

Fold 2 (n = 90, F1 macro 0,677)

	Pred. Disgustado	Pred. Interesado	Pred. Sereno	Total
Real Disgustado	18	6	5	29
Real Interesado	2	22	7	31
Real Sereno	7	2	21	30
Total predicho	27	30	33	90

Fold 3 (n = 89, F1 macro 0,795)

	Pred. Disgustado	Pred. Interesado	Pred. Sereno	Total
Real Disgustado	12	0	6	18
Real Interesado	0	24	6	30
Real Sereno	5	0	36	41
Total predicho	17	24	48	89

- Los errores se reparten sin una dirección dominante clara: `Sereno → Disgustado` (20), `Disgustado → Sereno` (19), `Interesado → Sereno` (19) y `Sereno → Interesado` (16). La confusión entre extremos conceptuales (`Interesado` ↔ `Disgustado`: 13 + 5) es la menor.
- **Los errores se concentran en pocos caballos**: 55 de 133 caballos tienen al menos un error y los 10 peores acumulan el 40,2 % de los 92 errores (`906`: 6/13; `013`: 5/5; `037`: 5/14; `053`: 4/4; `044`, `251`, `916`: 3/3). 9 caballos con ≥ 2 clips fallan en el 100 % de sus clips. Es un hallazgo del conjunto de datos (candidatos a revisión de etiqueta o de identidad), no sólo del modelo.

9.5 Cifras históricas y su estatus

Ninguna de estas cifras es comparable con 0,740: cambian el conjunto de clips y, en las primeras, el protocolo de selección de época.

Cifra	Modelo	Dataset	Fecha	Commit / origen	Artefacto	¿Vigente?
0,626 ± 0,065	Un frame + voto (LogReg)	141 clips / 73 caballos	2026-08-28	6f50a59 (línea de base) / 425c592 (evaluación final)	no (objetivo3_evaluacion.json lo sobrescribió; se cita en project.md)	No
0,704 ± 0,044	Cabeza «promedio» (MLP sobre media de frames)	153 clips / 83 caballos	2026-09-15	archivo objetivo3_evaluacion.json (mtime 15/09)	sí: objetivo3_evaluacion.json	No
0,754	MIL multimodal (otra corrida)	257 clips / 113 caballos (según docs)	2026-09-15	6b66044 (primera aparición, escrito a mano en clasificacion.py); retirado en 5e41c63 (18/09)	NO: sin artefacto que lo respalde	No (no citar)

Cifra	Modelo	Dataset	Fecha	Commit / origen	Artefacto	¿Vigente?
0,618	MIL con validación interna	153 clips / 83 caballos	2026-09-18	docs/ informe_mejora_pipeline_mil.md §6	no (cifra en el informe)	No
0,740 ± 0,052	MIL multimodal (MILFusionModel)	359 clips / 133 caballos	2026-09-18 (re-ejecutado 25/09)	4e51800 (protocolo), cf23ded (selección de frames); archivo objetivo3_evaluacion_v2.json	sí: objetivo3_evaluacion_v2.json	SÍ (única cifra vigente)
0,741 ± 0,020	Estática: media de 16 frames + LogReg	359 / 133	2026-09-25	e75f13a	sí: objetivo3_lineas_de_base.json	Línea de base vigente
0,618 ± 0,034	Solo metadatos de filmación (LogReg)	359 / 133	2026-09-25	e75f13a	sí: objetivo3_lineas_de_base.json	Línea de base vigente
0,686	MIL visual puro (sin geometría)	359 / 133	2026-09-18	docs/ informe_mejora_pipeline_mil.md §7	no (cifra en el informe)	No (variante)
0,747 ± 0,057	MIL con fine-tuning del backbone	359 / 133	2026-09-22	rama feat/finetuning-visual (c6d6f80, 544d323)	sí: objetivo3_finetuning_evaluacion.json	No (no adoptado)
0,698 ± 0,103	MIL con canal geométrico enriquecido	359 / 133	2026-09-22	rama feat/enriquecer-canal-geometrico	sí	No (no adoptado)
0,755 ± 0,022	MIL reentrenado sobre 100 % del train_val	359 / 133	2026-09-23	rama feat/validacion-cruzada-anidada-NestedCV (23d4b25)	sí	No (no adoptado)
0,784 ± 0,036	MIL con CV anidada (época promedio)	359 / 133	2026-09-23	rama feat/validacion-cruzada-anidada-NestedCV	sí	No (no adoptado; optimista)

Regla de uso: citar sólo `objetivo3_evaluacion_v2.json` como resultado del modelo vigente, siempre acompañado de `objetivo3_lineas_de_base.json`. La cifra **0,754** no tiene artefacto que la respalde (apareció escrita a mano en `clasificacion.py` el 15/09, en el commit `6b66044`, y se retiró el 18/09) y no debe citarse.

10. Baselines y valor agregado del modelo

10.1 Baselines que existen en el repositorio

Baseline	Dónde	Estado
Clase mayoritaria, azar estratificado	`equinos/lineas_de_base.py`, `scripts/evaluar_lineas_de_base.py`	Vigente; mismos folds que el modelo
Solo `id_caballo` (identidad)	`clasificacion.predecir_por_identidad`	Vigente (mide el efecto del confusor de individuo; §6.1)
Duración, metadatos de filmación, geometría sola, un frame, media de 16 frames	`lineas_de_base.py`	Vigente, `objetivo3_lineas_de_base.json`
Un frame con voto (0,626 en 141 clips), cabeza promedio (0,704 en 153), GRU, atención, ≥ 18 configuraciones	`openspec/changes/archive/2026-08-28-clasificacion-orientada-a-video/`	Histórico (otro conjunto de clips)
Variantes del MIL (canal geométrico, CV anidada, *fine-tuning*)	ramas `feat/enriquecer-canal-geometrico`, `feat/validacion-cruzada-anidada-NestedCV`, `feat/finetuning-visual`	No adoptadas; documentadas en `docs/registro_de_experimentos.md`

10.2 El modelo frente a cada línea de base (mismos 4 folds)

Modelo / línea de base	F1 macro (media ± DE entre folds)	Nota	Accuracy
Azar uniforme (1/3 por clase), esperanza	0,327	P95 sim. 0,367	≈ 0,333
Azar estratificado (proporciones del train), esperanza	0,326	P95 sim. 0,366	—
Clase mayoritaria (Sereno en los 4 folds)	0,183 ± 0,033		0,384
Solo duración del clip (LogReg)	0,544 ± 0,035		0,532
Metadatos de filmación (LogReg)	0,618 ± 0,034		0,635
Geometría sola, media y desvío (LogReg)	0,607 ± 0,033		0,618
Un frame central (LogReg)	0,679 ± 0,024		0,688
Media de los 16 frames (LogReg)	**0,741 ± 0,020**		0,749
MIL multimodal (vigente)	**0,740 ± 0,052**		0,744

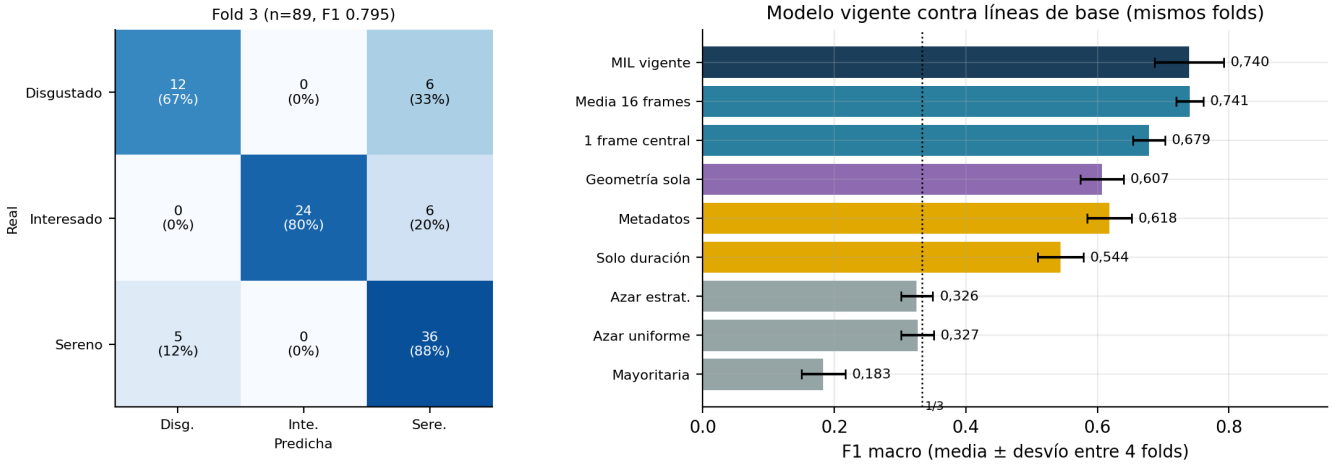


Figura 10.1. Matriz de confusión del fold 3 (izquierda) y F1 macro de las líneas de base y del modelo vigente con su desvío entre folds (derecha).

IC 95 % de las diferencias (bootstrap por caballo, 2 000 réplicas, diferencias pareadas por réplica). Recalculado de forma independiente por esta auditoría; coincide con `objetivo3_lineas_de_base.json` hasta la última cifra:

Modelo	IC95 % del F1 macro	Diferencia MIL − modelo	IC95 % de la diferencia	¿Incluye 0?
MIL multimodal (vigente)	[0,677; 0,797]	—	—	—
Estática: media 16 frames (LogReg)	[0,685; 0,798]	-0,005	[-0,068; +0,058]	sí
Un frame central (LogReg)	[0,626; 0,737]	+0,059	[+0,001; +0,116]	no
Metadatos de filmación (LogReg)	[0,538; 0,699]	+0,121	[+0,031; +0,211]	no
Geometría sola (LogReg)	[0,555; 0,669]	+0,128	[+0,053; +0,199]	no

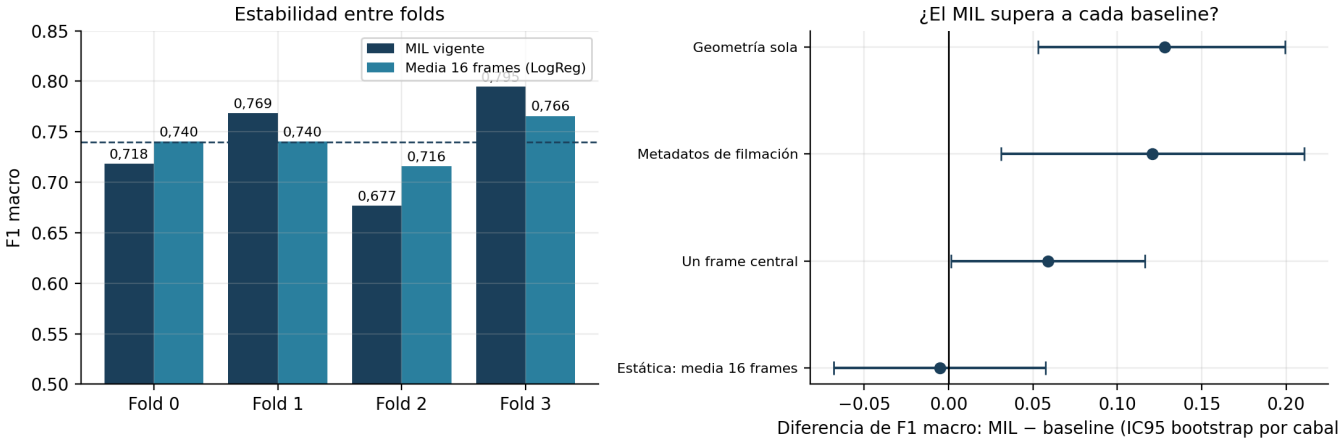


Figura 10.2. F1 macro por fold del MIL y de la media de 16 frames (izquierda) y diferencias MIL − baseline con su IC 95 % (derecha).

Lectura.

1. El modelo supera con holgura al azar, a la mayoritaria, a los metadatos de filmación (+0,121; IC [+0,031; +0,211]), a la geometría sola (+0,128; IC [+0,053; +0,199]) y a **un frame central** (+0,059; IC [+0,001; +0,116], el límite inferior roza el cero).
2. **No supera a la regresión logística sobre la media de los 16 frames**: diferencia −0,005, IC 95 % [−0,068; +0,058]. En los 4 folds el signo alterna (−0,022; +0,029; −0,039; +0,029). Con la partición vigente, **la arquitectura (atención, canal geométrico, MIL) no demuestra valor agregado sobre un promedio lineal**. El baseline, además, es mucho más estable entre folds (DE 0,020 contra 0,052).
3. **Evidencia contraria (sensibilidad a la partición).** En 4 asignaciones alternativas de caballos a folds (mismo código de entrenamiento, `scripts/a15_particiones_alternativas.py`) el MIL supera a la media estática por +0,003 a +0,021 (media +0,015) y 4 de 4 veces es mayor:

Partición (semilla de asignación)	MIL F1	MIL DE	Media 16 frames F1	Estática DE	Dif. MIL − estática
101	0,756	0,026	0,736	0,017	+0,020
102	0,744	0,040	0,726	0,034	+0,017
103	0,758	0,033	0,737	0,059	+0,021
104	0,744	0,044	0,740	0,018	+0,003

La ventaja media (~+0,015) es un orden de magnitud menor que el IC de una sola partición (±0,06) y proviene de los mismos 133 caballos, de modo que **no hay evidencia suficiente para afirmar ni para descartar una ventaja pequeña del MIL**; sí la hay para afirmar que no es grande.

10.3 Confusores de filmación: lo que se puede predecir sin mirar la cara

Información usada (sin mirar la cara)	F1 macro (media ± DE)	Accuracy
solo_rotacion_declarada	0,384 ± 0,071	0,482
tecnicos (códec, contenedor, pix_fmt, tasa de bits, tamaño, rotación)	0,556 ± 0,030	0,588
solo_año_de_la_sesión (por nombre de archivo)	0,395 ± 0,065	0,515
solo_mes_de_la_sesión	0,536 ± 0,050	0,591
solo_fecha_exacta_de_la_sesión	0,535 ± 0,064	0,571
técnicos + fecha exacta	0,605 ± 0,089	0,618

Clase	Videos	Con rotación declarada (90°)	%
Disgustado	110	1	0,9 %
Interesado	71	21	29,6 %
Sereno	93	47	50,5 %

- **Con metadatos (duración, fps, resolución, ventana) el F1 es 0,618**; con otros metadatos técnicos (códec, contenedor, tasa de bits, rotación) **0,556**, y con la **fecha de sesión** (del nombre de archivo) **0,535**; combinando técnicos y fecha, **0,605**. Ninguno alcanza 0,740, pero **todos están muy por encima del azar (0,327)**: el contexto de captura contiene una parte sustancial de la señal que el modelo podría usar si la lee del fondo, del encuadre o de la propia ventana temporal.
- **La rotación declarada está asociada a la clase**: 1 de 110 videos de `Disgustado` frente a 21 de 71 de `Interesado` y 47 de 93 de `Sereno`; el 35,4 % de los clips válidos proviene de videos rotados. No es un predictor fuerte por sí sola (F1 0,384), pero es un indicio de que el dispositivo o la forma de grabar difiere por clase.
- **Control del propio proyecto** (`objetivo3_lineas_de_base.json`, predicciones ya existentes, sin re-entrenar): en el subconjunto 1080×1920 y ≥ 5 s (236 clips: 28 `Disgustado`, 80 `Interesado`, 128 `Sereno`) el MIL obtiene **F1 0,705** (accuracy 0,746) y la media estática 0,671. Es la mejor estimación del rendimiento donde la filmación no delata la clase, aunque con muy pocos `Disgustado`.
- **Lectura prudente.** La caída de 0,740 a 0,705 (−0,035) es menor que el desvío entre folds; sugiere que el modelo **no depende principalmente** de la duración y la resolución, pero no puede descartar que dependa de otros rasgos de contexto (fondo, sesión, iluminación) que las ventanas del recorte facial conservan. Es una limitación que debe declararse, no una refutación.

11. Arquitectura, dimensionalidad, regularización y *data augmentation*

11.1 Arquitectura vigente (instanciada y contada por la auditoría)

`clasificacion.MILFusionModel` (aprendizaje de múltiples instancias, con cada frame como instancia y el clip como bolsa):

```
frame_i:  v_vis(512, ResNet-18 congelada) ──────────────┐
          v_geom(9: 3 puntos × (x, y, válido)) → MLP 9→64→128 ┘ concat (640)
atención: Linear(640→128) · tanh · Linear(128→1)  →  softmax sobre los frames (con máscara)
bolsa:    Σ_i  a_i · [v_vis ‖ geom_embed]_i   (640)
clasificador: Dropout(0,3) · Linear(640→64) · ReLU · Dropout(0,3) · Linear(64→3)
```

Elemento	Valor
MIL multimodal: parámetros totales	132 355
MIL multimodal: parámetros entrenables	132 355
· geom_mlp (9 → 64 → 128)	8 960
· atención (640 → 128 → 1)	82 176 (62,1 %)
· clasificador (640 → 64 → 3)	41 219
ResNet-18 sin capa final: parámetros	11 176 512 (todos congelados)
Entrenables tras congelar la ResNet-18	0
Pipeline completo: totales / entrenables	11 308 867 / 132 355
¿Coincide con la guía (132 355 entrenables)?	sí

- **Verificado:** el modelo tiene **132 355 parámetros entrenables**, la cifra de la guía del proyecto. El 62 % están en la cabeza de atención.
- **ResNet-18 congelada**: `models.resnet18(weights=IMAGENET1K_V1)` sin la capa final, con `requires_grad = False`, en modo `eval`; se aplica una única vez a cada frame y las características (512 por frame) se cachean (`caracteristicas_backbone_v2.npz`). Las 11 176 512 parámetros de la red no se entrenan.
- **Es un MLP con atención, no un modelo temporal**: no hay codificación de posición ni recurrencia; la salida es una suma ponderada por softmax de instancias independientes. Permutar los frames no cambia la salida (0/359 predicciones, diferencia máxima de logits $3{,}8 \cdot 10^{-6}$; barajado e invertido).
- El **canal geométrico** (puntos de ojo, hocico y oreja normalizados por frame con la distancia ojo–hocico, más tres indicadores de validez) aporta dentro del MIL (el MIL visual puro rinde 0,686 y un canal de ruido de 9 dimensiones 0,680; `docs/registro_de_experimentos.md`), pero **un promedio lineal sin canal geométrico ni atención rinde lo mismo que el MIL completo** (capítulo 10).

11.2 Dimensionalidad frente a muestras

Medida	Valor
Entrada por clip	16 frames × (512 visuales + 9 geométricas) = 8 336 valores
Clips de entrenamiento por fold (train interno / train+val)	≈ 199 / ≈ 269
Caballos de entrenamiento por fold (train interno)	≈ 93
Parámetros entrenables por clip de train interno	665
Parámetros entrenables por caballo de train interno	1423
Valores de entrada por clip / clips de train interno	41,9

La entrada por clip es **8 336 valores** (16 × 521) para entrenar ≈ 199 clips de ≈ 93 caballos por fold con 132 355 parámetros entrenables (≈ 665 por clip, ≈ 1 423 por caballo). Es un régimen de alta dimensión con pocas muestras independientes: la memorización del train (F1 0,98; capítulo 8) es esperable y la elección de congelar el backbone es la correcta (el propio código documenta que descongelarlo llevaría los entrenables al orden de 10^7). Con **133 caballos** como tamaño muestral efectivo (capítulo 13), ni siquiera un modelo de 10^5 parámetros

puede estimarse con precisión; el único modelo con capacidad claramente proporcional a los datos es el lineal sobre una media.

11.3 Regularización implementada de verdad

Técnica	¿Está?	Detalle y evidencia
Backbone preentrenado y congelado	**Sí**	`caracteristicas._cargar_backbone`
Dropout	**Sí, 0,3**	Dos capas `Dropout(0,3)` en el clasificador de la bolsa; **no** sobre las instancias (decisión de diseño documentada). Elegido por F1 de validación interna entre 0,0 / 0,2 / 0,3 (indistinguibles: 0,687 / 0,690 / 0,707)
Weight decay	**Sí, 1e-4**	`Adam(weight_decay=1e-4)` (L2 acoplado, no AdamW)
Early stopping	**Sí**	Paciencia 10 sobre F1 de validación interna (capítulo 7)
Pesos de clase	**Sí**	Raíz de la frecuencia inversa (no es regularización en sentido estricto)
Label smoothing, *batch norm*, *scheduler*, recorte de gradiente	No	No hay en el código
Reducción de capacidad de la cabeza	No	Sugerida en `docs/analisis_sobreajuste.md`; no probada
Calibración posterior	No	La interfaz muestra la probabilidad softmax cruda (sobreconfiada, §11.4)

11.4 Calibración de lo que se muestra al usuario

Con los modelos de fold sobre su test (359 predicciones fuera de muestra; coinciden con la evaluación vigente en 359/359):

Rango de confianza	Clips	Confianza media	Acierto observado
(0.4,0.5]	21	0,471	0,381
(0.5,0.6]	32	0,557	0,562
(0.6,0.7]	30	0,651	0,400
(0.7,0.8]	49	0,748	0,653
(0.8,0.9]	67	0,848	0,806
(0.9,1.0]	160	0,969	0,894

Confianza media 0,824, acierto 0,744, ECE 0,081, NLL 0,776 (frente a 1,099 del azar uniforme), Brier 0,373. La interfaz acompaña cada predicción con la **precisión medida de esa clase** (p. ej., «cuando el modelo predijo `Disgustado`, acertó 71 de 96 veces»), que es una corrección apropiada, pero la barra de probabilidad por clase sigue siendo optimista en el rango 0,6–0,8.

11.5 *Data augmentation*

- **En el modelo vigente: ninguna.** El entrenamiento consume las características del backbone **precalculadas** de los frames originales (`caracteristicas_backbone_v2.npz`), y no hay transformaciones de imagen ni de característica en `entrenar_mil_multimodal`. Por lo tanto **tampoco hay riesgo de que se aplique al test**.
- **Existe pero no se usa en el vigente:** `caracteristicas.extraer_aumentadas` genera vistas con espejo horizontal ($p = 0{,}5$), rotación ±10°, brillo y contraste ±15 %, con sorteo **por clip** (coherente entre sus 16 frames), pre-calculadas y cacheadas. Se probó en la etapa anterior (20 vistas por clip) y **no movió el F1** (−0,005 a 0,000; `openspec/project.md`).
- **Advertencia técnica:** el espejo horizontal es una transformación dudosa para expresiones asimétricas (un oído «hacia atrás» no cambia de significado, pero el canal geométrico incluye coordenadas x con signo); si se reutilizara debería aplicarse también al canal geométrico, cosa que el código actual no hace (sólo transforma píxeles).

11.6 Hallazgo: el canal geométrico del MIL es casi vacío

Medido sobre los 5 744 frames (`experimentos/simba/resultados/inventario_anatomico.json`, `comparacion_con_9_vigentes`; detalle en §17.4): las cuatro columnas de ojo y hocico llevan **un solo grado de libertad** (la inclinación de la cabeza en el plano de la imagen) porque están centradas y escaladas con la distancia ojo–hocico del mismo frame; las **tres máscaras de validez valen 1 en el 100 % de los frames** porque se calculan con `confianza > 0` y no con el umbral `≥ 0,50` del resto del pipeline; y las coordenadas de «oreja» son las de un único punto, en ejes de imagen. Consecuencia: la contribución del canal geométrico dentro del MIL (el MIL visual puro rinde 0,686) corresponde esencialmente a la inclinación de la cabeza y a un punto de oreja. Corrección sugerida: máscaras con el umbral del pipeline, rotación al eje de la cabeza y más puntos (orejas, boca).

12. Preprocesamiento, selección de frames y coherencia entrenamiento–inferencia

12.1 Cadena de preprocesamiento

Etapa	Implementación	Evidencia
Inventario	OpenCV (fps, frames, resolución)	`inventario_videos.csv` (274)
Segmentación en clips de 5–7 s	`cv2.VideoWriter` **`mp4v`** (recodificación con pérdida), con `CAP_PROP_ORIENTATION_AUTO = 1`; videos más cortos que 5 s entran enteros con un piso de 1 s	notebook 01 (celdas del Paso 10)
Pose	DeepLabCut 3.0.1 `video_inference_superanimal`, **`superanimal_quadruped`**, detector `fasterrcnn_resnet50_fpn_v2`, red `hrnet_w32`, sobre **todos** los frames de cada clip (39 *bodyparts*)	`equinos/reproceso.py` (l. 195), `equinos/inferencia.py` (l. 311), `pose_todos_los_frames.csv`
Frame válido	Par ojo–hocico con confianza ≥ 0,50 (`CONF_MINIMA_KEYPOINT`)	`02_roi_y_normalizacion.ipynb` (parámetros), `secuencia.frames_validos`
Selección de 16 frames	Ver §12.2	`equinos/secuencia.py`
Alineado	Transformada de similitud a una pose canónica (ojo y hocico fijos) con encuadre 224×343 que incluye las orejas; `borderMode = BORDER_REPLICATE`	`equinos/alineado.py`, `equinos/encuadre.py`
Recorte → JPEG (calidad 95) → lectura	El backbone ve la imagen **después** del viaje por JPEG	`equinos/dataset.py` (`CALIDAD_JPEG`)
Características	ResNet-18 congelada, normalización de ImageNet, 512 por frame	`equinos/caracteristicas.py`
Geometría	3 puntos normalizados + 3 indicadores de validez por frame	`clasificacion.MultimodalEquineDataset`

Sobre el uso de DeepLabCut (devolución docente, §1.5 punto 4). *No* se usa un modelo específico de caballos ni se ajustó (*fine-tuning*) con datos propios: se aplica tal cual el modelo preentrenado generalista **SuperAnimal-Quadruped**. El repositorio no contiene ninguna referencia a un subconjunto o *benchmark* de caballos (búsqueda de «Horse-10» / «Horse-30» sobre código, notebooks y documentos: sin resultados). **No pudo verificarse con los archivos disponibles** si entre los datos con que se entrenó SuperAnimal-Quadruped hay material de caballos (corresponde citar a Ye et al., 2024). La calidad de los keypoints propios no se midió contra anotación humana en el conjunto vigente: sólo hay 14 puntos anotados a mano (`keypoints_manuales.csv`), que el conjunto vigente ya no usa (los 5 744 frames provienen de detección propia).

12.2 Selección de los 16 frames

Método (`secuencia.elegir_frames`, documentado en el docstring del módulo): **no es muestreo uniforme sobre el clip, ni consecutivo, ni aleatorio**. Se busca la **ventana temporal contigua más larga** (≤ 7 s) que tenga ≥ 16 frames con par ojo–hocico válido y ningún tramo sin medición mayor a 0,5 s; dentro de ella se reparten 16 posiciones equiespaciadas y cada una se **ancla al frame medido más cercano** (tolerancia 0,1 s, eligiendo el de mayor confianza). Los 16 frames salen siempre de mediciones reales (no se interpola).

Clase	Ventana P25 (s)	Mediana (s)	P75 (s)	Separación mediana entre frames (s)	Clips con ventana < 2 s
Disgustado	1,80	2,87	3,98	0,19	31
Interesado	5,00	5,91	6,44	0,39	2
Sereno	5,53	5,93	6,83	0,40	2

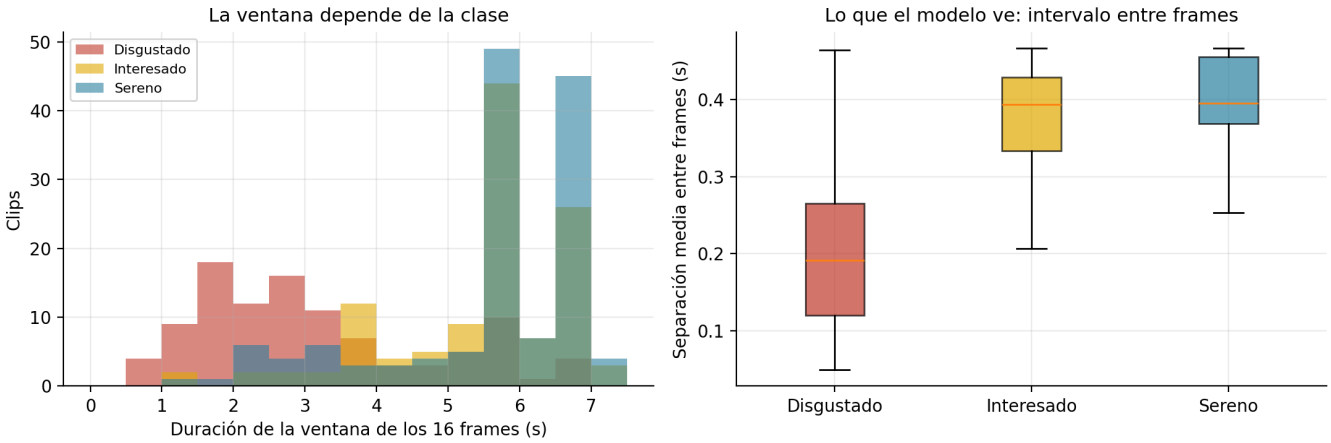


Figura 12.1. Duración de la ventana de los 16 frames por clase (izquierda) y separación entre frames consecutivos (derecha).

Posible sesgo (evidencia): la ventana abarca el 96–98 % del clip, así que su duración depende de la duración del clip, y esta depende de la clase. El intervalo entre frames es **la mitad en `Disgustado` (mediana 0,19 s) que en `Interesado` y `Sereno` (0,39 s)**; un criterio de dos a uno en la forma de muestrear el tiempo está asociado a la clase (Kruskal–Wallis sobre la ventana, $p \approx 2 \cdot 10^{-26}$; el AUC de la ventana para separar `Disgustado` del resto es 0,87). Como el modelo es invariante al orden, esto no actúa como «velocidad» sino como **diferencia en la diversidad de poses** que aparecen entre los 16 frames. Es el mecanismo por el cual la duración del clip (F1 0,544 sola) puede entrar al modelo aunque no se le dé como variable. El aprovechamiento por clase (§3.1) también es desigual: 31 de los 35 clips con ventana < 2 s son `Disgustado`.

12.3 ¿Entrenamiento e inferencia ven la misma entrada?

La función que decide qué frames entran y cómo se alinean es **la misma** (`alineado.preparar_secuencia`), con los mismos parámetros leídos del notebook 02; también el extractor (`caracteristicas._cargar_backbone`), el viaje por JPEG (calidad 95) y la geometría (`MultimodalEquineDataset`). `tests/test_equivalencia.py` (15/15 pruebas del repositorio pasan) verifica que dataset e inferencia eligen los mismos frames y producen los mismos recortes. Diferencias, ordenadas por relevancia:

Elemento	Entrenamiento	Inferencia (`app_inferencia.py`)	Diferencia / efecto
Origen de los píxeles	**Clips recodificados** `mp4v` (segmentación del notebook 01)	**Video original** del usuario	**Diferencia no cubierta por** `test_equivalencia` (que compara clip contra clip). Medido sobre 28 clips comparables: diferencia de píxel media 4,1/255; diferencia relativa de características 12 % (máx. 35 %); coseno 0,990; **la predicción cambia en 2 de 28 clips (7,1 %)**, con cambio máximo de probabilidad de 0,66 en un caso (`datos/entrenamiento_vs_inferencia.json`)
Orientación del video	Se aplica `CAP_PROP_ORIENTATION_AUTO = 1` al crear los clips (los clips quedan en orientación de visualización)	`inferencia.py` **no** la activa (0 apariciones); `cv2.VideoCapture` entrega los frames como están almacenados	69 de 274 videos (25,2 %) declaran rotación de 90°; originan el 35,4 % de los clips válidos. Ver §12.5
Unidad de entrada	Clip ≤ 7 s ya cortado	Video de hasta 15 s completo (`DURACION_MAXIMA_SEG`); se elige la mejor ventana ≤ 7 s	La ventana elegida puede no ser el tramo etiquetado; el modelo se midió sólo con clips ≤ 7 s
Lectura de frames	Frames de un archivo `.mp4` recodificado	`captura.set(POS_FRAMES)` + `read()` sobre el original (`.mp4`, `.mkv`, `.avi`)	La búsqueda por fotograma es inexacta en algunos contenedores; ver la negativa por «15 de 16 fotogramas» en §12.5
Pose	DeepLabCut sobre el clip recodificado	DeepLabCut sobre el video original	Mismo modelo y parámetros; **el efecto de la recodificación sobre la pose no pudo verificarse** (requiere re-ejecutar DeepLabCut, ≈ horas de GPU)
Checkpoint	4 modelos de fold (CV)	`mil_multimodal_produccion.pt` (359 clips, 29 épocas, sin validación)	Esperable; el rendimiento del modelo desplegado se **infiere** de la CV, no se midió directamente
Arquitectura, 16 frames, normalización, extracción	Iguales	Iguales (`MILFusionModel`, 16 exactos, constantes ImageNet, JPEG 95)	Sin diferencia
Detector	`fasterrcnn_resnet50_fpn_v2` de DeepLabCut	Ídem (YOLO ya no participa)	Sin diferencia

Evaluación. Las diferencias de origen de píxeles y de orientación son **debilidades reales** del eslabón entrenamiento–inferencia que el proyecto no medía. Su efecto agregado no se puede acotar con estos datos más que con las pruebas de esta auditoría; la confiabilidad que muestra la interfaz (74 % de acierto, precisión por clase) corresponde a clips de entrenamiento y **no necesariamente aplica a videos nuevos subidos por un usuario**.

12.4 Documentación desactualizada que contradice al código (menor)

- `equinos/inferencia.py` (docstring del módulo): afirma que «sobre el dataset propio sólo 141 de 368 clips (38 %) lo fueron» íntegros; hoy son 359 de 393 (91,3 %). Y el comentario de `DURACION_MAXIMA_SEG` dice que los 16 frames «se muestrean repartidos por todo el video», lo cual ya no es cierto (ventana ≤ 7 s).
- `app_inferencia.py` (docstring): «cuando el modelo dice `Disgustado`, acierta una de cada tres veces»; el valor vigente es 71 de 96 (74 %).
- `openspec/project.md` conserva una tabla «Estado actual» con `249 videos → 368 clips → 5888 frames` y secciones de riesgos con 234 videos / 342 clips; las cifras vigentes son 274 / 393 / 359.

12.5 Prueba de la interfaz sobre videos del propio dataset

Se ejecutó `inferencia.clasificar_video` (la misma cadena que usa la aplicación) sobre videos del dataset, con y sin rotación declarada (copias en un directorio temporal; DeepLabCut en GPU):

Video (del dataset)	Clase real	Rotación	Resultado de `clasificar_video`	Tiempo
217_20260818_144806.mp4	Sereno	90°	PREDICCION: Disgustado	46 s
207_20260818_151913.mp4	Sereno	90°	PREDICCION: Sereno	38 s
217_20260818_144548.mp4	Sereno	90°	PREDICCION: Disgustado	45 s
154_20260811_123118.mp4	Interesado	90°	PREDICCION: Interesado	45 s

Video (del dataset)	Clase real	Rotación	Resultado de `clasificar_video`	Tiempo
230_20260818_120401.mp4	Sereno	90°	PREDICCION: Disgustado	45 s
912_20260702_142421.mp4	Interesado	90°	PREDICCION: Sereno	41 s
218_20260818_143428.mp4	Sereno	90°	PREDICCION: Disgustado	20 s
218_20260818_144743.mp4	Sereno	90°	PREDICCION: Sereno	40 s
914_20260702-141211_NZFZ0IuM.mp4	Sereno	0°	PREDICCION: Sereno	30 s
124_bajado-5-s3_iKQVsdsn.mp4	Sereno	0°	PREDICCION: Sereno	49 s
706_2026-08-26-15-26-24_0LGlb5JC.m	Disgustado	0°	PREDICCION: Disgustado	31 s
200_20260818-154550_XbCo4YG4.mp4	Sereno	0°	PREDICCION: Disgustado	19 s
908_20260702-141427_ngER7GIe.mp4	Disgustado	0°	PREDICCION: Sereno	25 s
231_20260818-121656_YEVak6no.mp4	Sereno	0°	PREDICCION: Sereno	24 s
500_27v1_MqeH8hYv.avi	Interesado	0°	PREDICCION: Disgustado	16 s
217_20260818-144422_akI0bRyV.mp4	Sereno	0°	PREDICCION: Sereno	40 s

Grupo	Videos	Predicciones	Negativas	Errores	Motivos de negativa	Tiempo medio
Con rotación declarada (90°)	8	8	0	0	—	40 s
Sin rotación	8	8	0	0	—	29 s
Total	16	16	0	0	—	35 s

Cómo leerlo. La cadena funciona de punta a punta (16 de 16 videos dieron predicción, 0 negativas, 0 errores; ≈ 35 s por video). **Pero la predicción coincide con la etiqueta en sólo 8 de 16 videos (3 de 8 con rotación, 5 de 8 sin rotación)**, y el modelo de producción **se entrenó con los clips de estos mismos videos**: debería acertar muy por encima del 74 % de la validación cruzada. Una coincidencia del 50 % es una **señal de alarma sobre el eslabón entrenamiento–inferencia** (recodificación `mp4v`, orientación, ventana elegida sobre el video completo en lugar del clip etiquetado, lectura por búsqueda de fotograma). Es una muestra de 16, no una estimación; no se aisló qué diferencia pesa más. Se la reporta como evidencia contradictoria con la confiabilidad que muestra la interfaz. La interfaz arranca sin excepciones (`datos/app_streamlit.json`) y cita sus métricas del JSON vigente.

13. Independencia de las muestras, generalización y calidad de las etiquetas

13.1 Independencia

Los 359 clips **no son 359 observaciones independientes** (`datos/independencia.json`, `datos/dataset.json`):

- 244 videos de origen: 175 aportan un solo clip, 69 aportan dos o más (hasta 7). **El 51,3 % de los clips pertenece a videos con más de un clip.**
- 133 caballos: 2,70 clips por caballo en promedio (mediana 2); 58 caballos tienen un único clip y los 10 con más clips reúnen el 27,6 %.
- **Correlación intra-caballo del acierto**: ICC (ANOVA de una vía sobre el indicador de acierto) = 0,31; efecto de diseño ≈ 1,52. El tamaño efectivo para estimar la accuracy está **entre ≈ 236 clips (corrección por diseño) y 133 (caballos)**; la estimación del ICC con muchos caballos de un clip es ruidosa, por lo que se usa el rango.
- Consecuencia sobre la incertidumbre: el IC 95 % de la accuracy es **[0,679; 0,801] con bootstrap por caballo** frente a [0,696; 0,786] con el intervalo de Wilson ingenuo por clip (ancho 0,122 frente a 0,090: el ingenuo subestima la incertidumbre en ≈ 26 %). Los JSON de evaluación informan el desvío entre 4 folds; el IC por caballo existe desde el 25/09 en `objetivo3_lineas_de_base.json` y coincide con el recalculado aquí.
- Los clips de un mismo video son contiguos y sin solape; entre videos de la misma sesión (misma fecha) hay dependencia de contexto (§6.4).

13.2 Generalización a caballos no vistos (interna)

El protocolo mide exactamente esto: cada clip se predice con un modelo que **nunca vio a su caballo**. El F1 macro 0,740 (IC 95 % [0,677; 0,797]) estima el rendimiento sobre **caballos nuevos de la misma población**, con la salvedad de dependencia de sesión de §6.4. Los 133 caballos son muy pocos para caracterizar subpoblaciones: el rendimiento por caballo es heterogéneo (55 caballos con algún error; 9 con ≥ 2 clips fallados en el 100 % de los casos).

13.3 Generalización externa

No evaluada y, con los datos disponibles, no evaluable. Todo el material lo filmó una sola persona, con dispositivos móviles, en establecimientos de la provincia de Buenos Aires (hipódromos de Tandil y Azul, haras, quintas y campus; `docs/protocolo_de_etiquetado.md` §3). No pudo verificarse con los archivos disponibles: la **raza** de los caballos (no hay metadato; el material proviene mayormente de haras de Sangre Pura de Carrera según el formulario), la **cámara/dispositivo** por video (sólo se pueden inferir contenedor, códec y rotación), ni la **iluminación**. Hay tres clases fuertemente asociadas al tipo de establecimiento y situación (el formulario lo confirma): `Interesado` en box de hipódromo, `Disgustado` en interacciones de manada en cría extensiva, `Sereno` en descanso. **El modelo no se probó en otro centro, otra cámara ni otro observador**, de modo que su rendimiento fuera de este conjunto es una incógnita.

13.4 Calidad de las etiquetas

Aspecto	Hallazgo	Fuente
Quién etiquetó	Una sola persona, veterinaria **codificadora certificada de EquiFACS**, que además filmó y observó el contexto (**no ciega**)	`docs/protocolo_de_etiquetado.md` §3
Criterio	Escrito por clase, con unidades de acción de EquiFACS y etogramas publicados; usa **contexto, comportamiento y postura**, no sólo la cara. Las unidades de acción son «pueden estar presentes», no obligatorias	ídem
Acuerdo entre observadores	**Kappa de Fleiss 0,9877 sólo en un piloto con imágenes y otros observadores**; sobre los videos del dataset **no se midió** (decisión del 07/10/2026)	ídem §3, §5
Etiqueta por video, heredada a los clips	Supone que la expresión dura toda la toma; sostenido por el recorte de tramos de la etiquetadora	ídem §1, §4
Clases excluidas por falta de acuerdo en el piloto	Miedo, intensidad elevada, conductas repetitivas, caballos atados	ídem §3
Consistencia de nombres de clase	Idéntica en todos los artefactos; el prefijo del archivo coincide con `id_caballo` en 393/393 clips	`datos/dataset.json`
Posible ruido de etiqueta	9 caballos con ≥ 2 clips son fallados en el 100 % de sus clips por el modelo (`013`, `053`, `044`, `251`, `916`, `224`, `920`, `215`, `905`): candidatos a revisión de etiqueta o de identidad	`datos/independencia.json`
Confusores de contexto	Box de hipódromo → `Interesado`; manada → `Disgustado`; rotación, contenedor y fecha asociados a la clase (§10.3)	ídem; formulario

Lo que cambió respecto del 25/09: el protocolo existe y está documentado (antes «sin protocolo»), por lo que R14 pasa de NO CUMPLIDO a CUMPLIDO PARCIALMENTE. **Lo que no cambió:** un único observador no ciego, sin acuerdo medido sobre el dataset, y por lo tanto **techo de rendimiento desconocido**: no se puede separar cuánto del 0,740 es error del modelo y cuánto ambigüedad de la etiqueta.

14. Reproducibilidad y trazabilidad

(Respuesta a la pregunta de la devolución docente: «¿cómo está la repetibilidad?»)

14.1 Se reproduce lo publicado

Con el código vigente y la semilla 42 (`scripts/a04_reentrenar.py`, GPU RTX 3070 Laptop, torch 2.5.1+cu121):

Verificación con el código vigente y semilla 42	Resultado
Predicciones fuera de muestra idénticas a las guardadas	359/359
Curvas de F1 de validación idénticas (4 folds)	sí
Curvas de F1 de train idénticas (4 folds)	sí
Pesos idénticos bit a bit (folds 0–3)	sí, sí, sí, sí
Tiempo de re-entrenamiento (4 folds, GPU)	145 s

La re-ejecución de esta auditoría reprodujo, **bit a bit**, las predicciones, las curvas y los pesos de los 4 folds. (Nota: el código **no** activa `cudnn.deterministic` ni `use_deterministic_algorithms`; la igualdad exacta se observa en esta máquina, sin garantía en otro hardware o versión de CUDA.)

14.2 Repetibilidad con otras semillas y otras particiones

Semilla	F1 macro (media de 4 folds)	DE entre folds	Accuracy	Mejor época por fold (0–3)
42	0,740	0,052	0,744	28, 26, 20, 40
43	0,751	0,049	0,760	44, 28, 21, 27
44	0,730	0,065	0,738	18, 23, 16, 22
45	0,726	0,068	0,733	50, 24, 14, 19
46	0,763	0,074	0,766	13, 15, 18, 22
47	0,727	0,055	0,733	24, 30, 21, 21
Media ± DE entre semillas	**0,739 ± 0,015**	0,061		rango 13–50

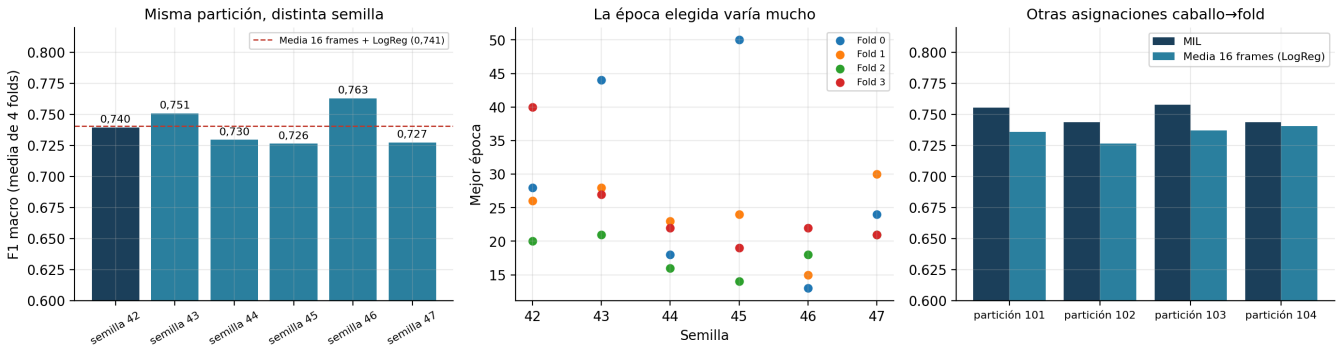


Figura 14.1. F1 macro del MIL con 6 semillas sobre la misma partición (izquierda), mejor época por semilla y fold (centro) y MIL frente a la media de 16 frames en 4 asignaciones alternativas de caballos a folds (derecha).

- Con la partición vigente, **la semilla mueve el F1 macro en un rango de 0,036** (de 0,726 a 0,763; DE entre semillas 0,015). La semilla 42 es representativa (media de 6 semillas 0,739) y no fue elegida por su valor: la semilla ya figuraba en el código.
- **La mejor época es mucho más variable que el F1**: de 13 a 50 entre semillas y folds. Es el síntoma de una validación interna pequeña y ruidosa (§5.3).
- Con **otras asignaciones de caballos a folds** (4 particiones, semilla 42) el MIL da 0,744–0,758 (§10.2), lo que sitúa el 0,740 de la partición vigente en el extremo bajo del rango posible. La variabilidad debida a la partición y a la semilla (≈ ±0,015) es del mismo orden que la diferencia con el baseline estático, de modo que **no deben interpretarse diferencias de F1 menores a ≈ 0,03 entre variantes**.
- Una repetición del protocolo completo con varias particiones (p. ej., 5 × 4 folds) es la forma correcta de estimar la variabilidad; el proyecto reporta una sola.

14.3 Entorno, semillas y configuración

Elemento	Estado	Evidencia
Dependencias fijadas	`requirements-local.txt` con versiones exactas (torch 2.5.1+cu121, numpy 1.26.4, scikit-learn 1.7.2, deeplabcut 3.0.1…). Las versiones instaladas coinciden salvo `tensorboard` (fijado pero no instalado y no usado)	`datos/reproducibilidad.json`
Semillas	`SEMILLA = 42`; `torch`, `random`, `numpy`, `cuda` y generador del `DataLoader` fijados; el bootstrap usa semilla 1; la partición no usa azar	`clasificacion.py`, `lineas_de_base.py`, `particion.py`
Configuración	Hiperparámetros **escritos en los scripts** (`DROPOUT = 0.3`, `PESOS = "raiz"` en `evaluar_v2.py`; `paciencia=10`, `max_epocas=100` como valores por defecto), sin archivo de configuración	`scripts/evaluar_v2.py`
Scripts del modelo vigente	En `main`: `scripts/evaluar_v2.py`, `scripts/evaluar_lineas_de_base.py`; pruebas: 15 archivos `tests/test_*.py`, **15/15 pasan** (`test_equivalencia.py` vuelve a pasar tras restituir `CONF_MINIMA_KEYPOINT = 0,50`)	ejecución de esta auditoría
Checkpoints	`mil_v2_fold{0..3}.pt` y `mil_multimodal_produccion.pt` con su procedencia; la **huella de las características** registrada (`806a6f478408ab0b`) **coincide** con la de la caché vigente (error de la auditoría anterior, corregido)	`datos/reproducibilidad.json`
Pipeline completo desde los videos	Documentado (`docs/informe_mejora_pipeline_mil.md` §8): ≈ 3 h de GPU de pose + minutos para el resto; depende de que `~/videos_de_prueba` exista	**No se re-ejecutó** la pasada de pose (horas de GPU)

14.4 Trazabilidad de experimentos

- **Resuelta en gran parte desde el 25/09**: `docs/registro_de_experimentos.md` indica para cada JSON de `resultados/` su código, rama, commit y comando, y separa el modelo vigente de las variantes no adoptadas. Las tres ramas con los scripts de variantes (`feat/enriquecer-canal-geometrico`, `feat/validacion-cruzada-anidada-NestedCV`, `feat/finetuning-visual`) existen y contienen los scripts mencionados (verificado con `git ls-tree`); **siguen sin fusionarse**, por lo que esos resultados sólo se reproducen cambiando de rama, con código incompatible entre sí.
- **Fragilidad de la caché de características**: `caracteristicas.huella` incluye la fecha de modificación (`st_mtime`) del CSV del dataset. Copiar o tocar ese archivo invalida la caché y obliga a re-extraer y a **escribir** en la raíz de datos; no cambia los resultados (el backbone es determinista) pero rompe el control por huella. Para sus lecturas esta auditoría leyó el `.npz` directamente.
- **Documentación desactualizada** (§12.4): cifras viejas en `openspec/project.md`, `inferencia.py` y `app_inferencia.py`.
- **Cifras históricas**: ver §9.5; sólo `objetivo3_evaluacion_v2.json` es vigente.

15. Buenas prácticas y condiciones de un buen modelo de clasificación

15.1 Checklist de buenas prácticas para datasets pequeños

Práctica	Estado	Evidencia
Separar por la unidad de dependencia (individuo), no por muestra	**Cumple**	133 caballos; 0 cruces; aserciones en `particion.py` y `clasificacion.py` (§6)
Validación cruzada con predicciones fuera de muestra para todo el conjunto	**Cumple**	359/359 predicciones fuera de muestra
Validación interna independiente para decidir época e hiperparámetros	**Cumple, con debilidad**	Por caballo y sin test; pero es 7 caballos prolíficos, desbalanceada (§5.3)
Test usado una sola vez	**Cumple**	Verificado por inspección y por la prueba del test alterado (§6.3)
Métrica adecuada al desbalance (F1 macro, no sólo accuracy)	**Cumple**	`clasificacion.f1_macro`; equivalente a sklearn
Baselines triviales y baselines fuertes sobre los mismos folds	**Cumple** (desde el 25/09)	`objetivo3_lineas_de_base.json`
Intervalos de confianza que respeten la dependencia	**Cumple**	Bootstrap por caballo, 2 000 réplicas
Reportar dispersión entre folds	**Cumple**	0,740 ± 0,052
Reportar y controlar confusores de captura	**Parcial**	Subconjunto 1080×1920 y ≥ 5 s (0,705); no se controló sesión, rotación ni contenedor (§10.3)
Congelar el extractor con pocos datos	**Cumple**	ResNet-18 congelada; 132 355 entrenables
Registrar curvas de train y validación y el gap	**Cumple** (desde el 25/09)	`curva` por época; `docs/analisis_sobreajuste.md`
Declarar el criterio de éxito antes de medir	**Cumple, con una reserva**	Criterio 0,691 declarado antes (28/08); re-declarado después de medir como 0,761 y así consta
Evitar selección de modelos sobre el test (CV anidada)	**Parcial**	Selección de variantes con los mismos folds; la CV anidada se probó y no se adoptó
Comparar contra un baseline simple y adoptarlo si empata (parsimonia)	**Parcial**	Se detectó el empate (0,740 frente a 0,741); se conservó el MIL por decisión de los autores del 25/09 («revisable»)
Repetir la CV con distintas particiones/ semillas	**No** (hasta esta auditoría)	Una sola partición y una semilla en el proyecto; §14.2
Validación externa (otro centro/cámara/ observador)	**No**	Un único observador, un único establecimiento regional (§13.3)
Segundo observador / acuerdo sobre el dataset	**No**	Decisión del 07/10 de trabajar con un observador
Calibración de las probabilidades mostradas	**No**	Probabilidades softmax crudas, sobreconfiadas
Control de versiones y trazabilidad de resultados	**Parcial**	Registro de experimentos; ramas laterales sin fusionar
Entorno fijado y semillas	**Cumple**	`requirements-local.txt`, `SEMILLA`
Pruebas automáticas	**Cumple**	15/15 archivos de prueba pasan
Documentación coherente con el código	**Parcial**	Cifras viejas en 3 archivos (§12.4)

Resumen: de 22 prácticas, **11 cumplen**, **7 cumplen parcialmente o con reserva** y **4 no se cumplen** (repetición de CV, validación externa, segundo observador, calibración).

15.2 Condiciones de un buen modelo de clasificación

Condición	Estado	Evidencia
Datos suficientes para la complejidad del modelo	**Parcial**	359 clips / 133 caballos frente a 132 355 parámetros entrenables; un modelo lineal rinde igual (§11.2)
Clases bien definidas y etiquetas fiables	**Parcial**	Criterio EquiFACS y etogramas; un observador no ciego; sin acuerdo medido sobre el dataset

Condición	Estado	Evidencia
Balance de clases razonable	**Cumple**	IR 1,34 (clips) / 1,15 (caballos); folds variables (§4)
Sin fuga de información	**Cumple**	0 cruces; test no interviene (§6)
Muestras independientes o con dependencia tratada	**Cumple**	Agrupación por caballo; bootstrap por caballo; el tamaño efectivo es ≈ 133–236 (§13.1)
Preprocesamiento coherente entrenamiento–inferencia	**Parcial**	Misma función; difieren origen de píxeles y orientación (§12.3)
Superar baselines relevantes	**Parcial**	Supera azar, mayoritaria, metadatos y un frame; **no** la media lineal
Rendimiento estable entre particiones	**Parcial**	DE 0,052 entre folds (2,6 × la del baseline); ±0,015 entre semillas
Generalización a individuos nuevos	**Cumple**	Evaluación por caballo
Generalización externa	**No evaluada**	§13.3
Sobreajuste controlado	**Parcial**	Parada temprana contiene el efecto sobre el test; memoriza el train; probabilidades sobreconfiadas
Métricas completas (global, por clase, matriz, dispersión, IC)	**Cumple**	Capítulo 9
Reproducible	**Cumple**	359/359 bit a bit con semilla 42; ±0,015 entre semillas
Trazable	**Parcial**	Registro de experimentos; ramas sin fusionar; fragilidad de la huella
Interpretable / explicable	**Parcial**	Atención por frame en la interfaz; sin análisis de qué rasgos usa (la señal del contexto no se descarta)
Utilidad real validada con el usuario	**No evaluada**	Sin validación con veterinarios

Resumen: de 16 condiciones, **6 cumplen**, **8 son parciales** y **2 no están evaluadas** (generalización externa y utilidad con el usuario).

16. Confiabilidad, puntos fuertes y débiles, mejoras y veredicto

16.1 Confiabilidad por dimensión

Dimensión	Nivel	Justificación
Metodológica	**ALTA**	Separación por caballo en la validación cruzada y en la interna, con aserciones; test usado una sola vez (verificado con test alterado); métrica adecuada y verificada contra sklearn; líneas de base sobre los mismos folds. Resta: validación interna de 7 caballos prolíficos y desbalanceada; selección de variantes no anidada
Estadística	**MEDIA**	IC 95 % del F1 macro de ±0,06 (0,677–0,797) con bootstrap por caballo; 4 folds; tamaño efectivo ≈ 133–236; diferencias menores a ≈ 0,03 entre variantes no son interpretables. Suficiente para afirmar «muy por encima del azar y de los metadatos»; insuficiente para distinguir arquitecturas
Generalización	**MEDIA** (a caballos nuevos de la misma población) / **NO EVALUADA** (externa)	Un solo observador, una sola filmadora, una región; contexto de captura asociado a la clase (hasta 0,605 de F1 sin mirar la cara); diferencias entre entrenamiento e inferencia (recodificación, orientación)
Reproducibilidad	**ALTA** (modelo vigente) / **MEDIA** (variantes)	359/359 predicciones y pesos idénticos bit a bit; ±0,015 entre semillas; entorno fijado; las variantes dependen de ramas sin fusionar
Consistencia entre folds	**MEDIA**	F1 0,677–0,795, sin folds colapsados; DE 0,052 (2,6 × la del baseline lineal); la mejor época varía 20–40 entre folds y 13–50 entre semillas

16.2 Puntos fuertes

1. **Separación por caballo verificada por código** y cuantificada: sin agrupar, la identidad sola daría F1 0,613; agrupando, 0,183 (+0,43 de F1 espurio que el protocolo elimina).
2. **Test intacto**: la prueba del test alterado muestra que época, curvas y pesos no dependen de las etiquetas de test.
3. **Reproducibilidad exacta** del modelo vigente (predicciones, curvas y pesos), con 6 semillas medidas y entorno fijado.
4. **Rigor de reporte**: F1 macro verificado, métricas por clase, matrices de confusión, IC por caballo, líneas de base sobre los mismos folds y registro de los resultados negativos (hipótesis temporal no sostenida, *fine-tuning* y CV anidada no adoptados, criterio declarado antes de medir).
5. **Backbone congelado y extractor preentrenado**, apropiado para 359 clips; el pipeline de pose y de alineado es el mismo código para entrenamiento e inferencia.
6. **Etiquetado con criterio documentado** por una especialista (EquiFACS), con clases excluidas por falta de acuerdo en el piloto.
7. **Honestidad de la interfaz**: declara que no es un diagnóstico, cita las métricas del JSON vigente (no escritas a mano) y devuelve negativas explicadas.

16.3 Puntos débiles

1. **Sin valor agregado demostrado del MIL multimodal** frente a la media lineal de 16 frames (0,740 frente a 0,741; IC de la diferencia [−0,068; +0,058]); el único respaldo a una ventaja pequeña (+0,015 en 4 particiones alternativas) es débil.
2. **No es un modelo espacio-temporal**: invariante al orden (R7); la hipótesis dinámica del plan no se sostiene con los datos.
3. **Confusores de captura**: duración, contenedor, rotación y fecha de sesión predicen la clase sin mirar la cara (0,535–0,618); la **ventana de 16 frames depende de la duración y por lo tanto de la clase**.
4. **Etiquetas de un único observador no ciego**, con criterio que usa contexto; acuerdo no medido sobre el dataset; techo de rendimiento desconocido.
5. **Validación interna defectuosa**: 7 caballos con más clips (≈ 10 clips c/u frente a 2,1 en el train interno), desbalanceada (hasta 4,18:1); elección de época ruidosa.
6. **Eslabón entrenamiento–inferencia**: clips recodificados `mp4v` contra video original (cambia 7 % de las predicciones en la muestra medida) y orientación de video no tratada en la inferencia; la confiabilidad

mostrada no necesariamente aplica a videos nuevos: en la prueba de extremo a extremo la interfaz coincidió con la etiqueta en 8 de 16 videos del propio dataset, con el modelo ya entrenado sobre ellos.

7. **Sobreajuste moderado**: F1 train 0,98; probabilidades sobreconfiadas (ECE 0,081; confianza 0,824 frente a acierto 0,744).
8. **Sin validación externa ni con usuarios**; un solo establecimiento regional; 133 caballos.
9. **El canal geométrico del MIL es casi vacío**: las 9 variables llevan un solo grado de libertad (inclinación de la cabeza) y sus máscaras de validez valen 1 siempre (se calculan con confianza > 0 y no ≥ 0,50) (§17.4).
10. **Deuda de trazabilidad y documentación**: ramas sin fusionar, huella dependiente de `mtime`, tres archivos con cifras viejas, configuración escrita en los scripts, partición descrita como «réplica de `GroupKFold`» sin serlo exactamente.

16.4 Mejoras recomendadas

Prioridad ALTA (antes de dar el modelo y el informe por cerrados)

#	Mejora	Esfuerzo	Por qué
A1	**Redactar la contribución con precisión**: el rendimiento proviene de un extractor preentrenado y de la agregación de varios frames; ni la atención ni el orden temporal están demostrados; quitar «espacio-temporal» donde describe al modelo; evaluar adoptar la media lineal por parsimonia si el criterio de los autores lo permite	Texto	Respuesta directa a la devolución docente y al empate 0,740/0,741
A2	**Investigar y corregir el eslabón entrenamiento–inferencia** (coincidencia de 8/16 en la prueba de la interfaz): activar `CAP_PROP_ORIENTATION_AUTO` en `inferencia.preparar_clip` y verificar que DeepLabCut lea con la misma orientación; medir (o eliminar) el efecto de la recodificación `mp4v`; extender `test_equivalencia.py` a video original	Bajo–medio	Una interfaz que acepta videos del usuario sin esta garantía puede informar una confiabilidad que no aplica
A3	**Controlar los confusores de sesión/contexto**: reportar rendimiento por estratos de sesión (fecha), con partición *leave-one-session-out* o agrupada por sesión, y/o restringir a un subconjunto homogéneo de captura	Medio	Es la mayor amenaza a la validez que el protocolo actual no controla
A4	**Repetir la validación cruzada** con ≥ 5 particiones y semillas y reportar la media de repeticiones con IC (`scripts/a15_particiones_alternativas.py` ya lo hace)	Bajo	La variabilidad por partición/semilla (±0,015) es del orden de las diferencias que se discuten
A5	**Reemplazar la validación interna** por una muestra aleatoria de caballos estratificada por clase, o por una CV interna, y comprobar la época y el F1	Medio	Hoy son los 7 caballos con más clips
A6	**Declarar en el informe las limitaciones de etiquetado** (un observador no ciego, criterio contextual, techo desconocido) y las de captura (un establecimiento regional, un filmador)	Texto	El protocolo ya las documenta; falta que lleguen al informe
A7	**Incorporar SimBA-RF como modelo complementario** (liviano, sin GPU salvo DLC, interpretable) y como línea de base geométrica fuerte; no sustituir al MIL ni presentar su ventaja como definitiva	Bajo	0,841 ± 0,003 frente a 0,740; limpio no concluyente (cap. 17)
A8	**Controlar sesión y filmación** en ambos modelos (residualizar duración/resolución, estratificar, partición por sesión) y reportar el piso deconfundido (0,777 para SimBA-RF)	Medio	Las features codifican duración (R^2 0,53) y resolución (AUC 0,73); el MIL comparte el confusor
A9	**Arreglar la validez de las 9 geométricas**: máscaras con `confianza ≥ 0,50`, rotar al eje de la cabeza, ampliar a orejas/boca (o reemplazarlas por las features del cap. 17)	Bajo	Hoy llevan un solo grado de libertad y máscaras constantes

Prioridad MEDIA

1. Calibrar las probabilidades (*temperature scaling* sobre validación) o mostrar sólo la precisión medida por clase.
2. Reducir la capacidad de la cabeza (62 % de los parámetros está en la atención) y compararla bajo el mismo protocolo.
3. Revisar candidatos a error de etiqueta o de identidad: los 9 caballos con fallos del 100 %, y el par `123`/`169`.
4. Pasar los hiperparámetros a un archivo de configuración y fijar `cudnn.deterministic`.
5. Reemplazar la huella por `mtime` por una huella de contenido; actualizar las cifras viejas de `inferencia.py`, `app_inferencia.py` y `openspec/project.md`.
6. Fusionar o archivar con etiqueta las tres ramas de variantes, o dejar en `main` un índice con sus *hashes*.

Prioridad BAJA (trabajo futuro)

1. Validación externa: otro establecimiento, otra cámara, otro observador.

2. Segunda anotación ciega de una muestra (≈ 60 clips, kappa de Cohen) para estimar el techo de las etiquetas.
3. Evaluación de utilidad con veterinarios (R15, R16).
4. Modelos temporales (unidades de acción, flujo óptico) sólo si un experimento controlado muestra un aporte del orden.

16.5 Veredicto cuantificado

Afirmación	Veredicto	Cifra
El sistema clasifica expresiones en caballos no vistos mejor que el azar	**Sustentada**	F1 macro 0,740 (IC 95 % 0,677–0,797) frente a 0,327
Lo hace mejor que usar sólo la forma de filmar (metadatos)	**Sustentada**	+0,121 (IC 95 % +0,031; +0,211); la señal del contexto sola llega a 0,605
Lo hace mejor que un modelo lineal sobre las características de los frames	**No sustentada**	−0,005 (IC 95 % −0,068; +0,058)
Modela la dinámica temporal	**No**	0 de 359 predicciones cambian al permutar los frames
Es útil para expertos	**No verificable**	Sin validación con veterinarios; precisión por clase 0,73–0,76
El resultado es repetible	**Sí** (con semilla 42, bit a bit); **±0,015** entre semillas	6 semillas: 0,726–0,763
Rendimiento esperable donde la filmación no delata la clase	≈ 0,70	0,705 en 236 clips (28 de `Disgustado`)

Indicador de calidad	Resultado
Requisitos del plan	10 cumplidos, 6 parciales, 2 no verificables, 0 no cumplidos (de 18)
Buenas prácticas	11 cumplen, 7 parciales, 4 no (de 22)
Condiciones de un buen modelo	6 cumplen, 8 parciales, 2 no evaluadas (de 16)
Sobreajuste	MODERADO
Balance	RAZONABLEMENTE BALANCEADO (clips 1,34:1) / BALANCEADO (caballos 1,15:1)
Fuga de información	No se observan evidencias (0 cruces de caballo, video, clip ni frame); riesgo residual de sesión y de selección no anidada

Conclusión. El proyecto construyó un clasificador de tres clases con una metodología de separación por individuo sólida, verificada y reproducible. La estimación 0,74 de F1 macro es **creíble para caballos nuevos de esta población y este tipo de captura**, con un tope de incertidumbre de ±0,06 (IC) y ±0,015 (semillas). No está demostrado que la arquitectura profunda, la atención, el canal geométrico o el orden temporal aporten sobre un promedio lineal de las características de varios frames; el contexto de captura contiene una parte de la señal; y la utilidad para expertos, la validez externa y el techo impuesto por las etiquetas siguen sin conocerse.

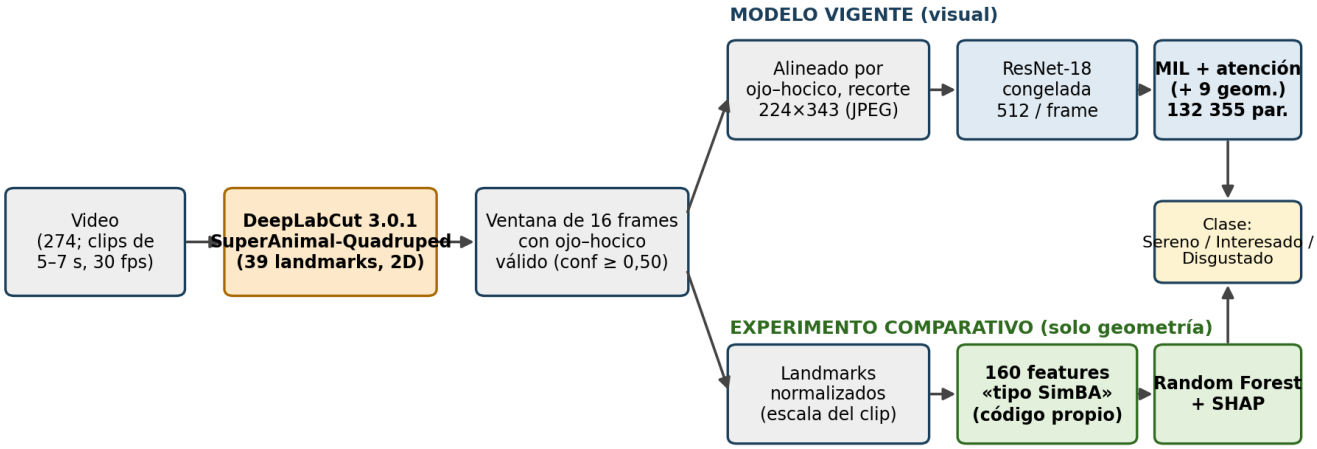
Efecto del experimento SimBA sobre el veredicto. Un Random Forest sobre 160 features de pose «tipo SimBA» (código propio) obtiene 0,841 ± 0,003 frente al 0,740 del MIL, y 0,750 frente a 0,705 en el subconjunto limpio (no concluyente). El resultado **matiza** la conclusión anterior: la señal discriminativa está en la geometría facial (cara 0,848, orejas 0,784, cuello 0,461) y no depende de una red visual profunda; pero **comparte el confusor de filmación** (R^2 0,53 con la log-duración; piso deconfundido 0,777), de modo que ni el 0,74 ni el 0,84 son estimaciones libres de contexto. La confiabilidad estadística y la de generalización siguen en los niveles indicados.

17. Experimento comparativo con features de pose «tipo SimBA»

Fuentes: `experimentos/simba/` (README, `resultados/*.json|csv|png`) y la **revisión adversarial** `experimentos/simba/verificacion/` (README y `verificacion.json`). **Donde la verificación y el resumen original difieren, vale la verificación.** El experimento es adicional y aislado: no modifica `equinos/` ni el MIL vigente, y no vuelve a ejecutar DeepLabCut.

> **Nombres.** El conjunto principal son **«features tipo SimBA calculadas con código propio»** (`features_simba.py`); **no es SimBA**. SimBA real (`simba-uw-tf-dev 5.6.1`) se instaló y ejecutó sobre los 359 clips, pero para un solo animal sólo entrega *movimiento* por landmark (conjunto B2). En todo el documento «SimBA-RF» designa al Random Forest sobre las features propias.

17.1 Roles: DeepLabCut y SimBA



DLC: video → landmarks. SimBA (real): landmarks → features → clasificador. Ninguno cumple ambos roles.

Figura 17.1. Pipeline video → DeepLabCut → features → clasificador. Arriba, el modelo vigente; abajo, el experimento comparativo con la misma pose y los mismos 16 frames.

Herramienta	Rol	Entrada → salida
DeepLabCut (SuperAnimal-Quadruped)	Estimador de pose	video → 39 landmarks 2D por frame, con *likelihood*
SimBA (real)	Features y clasificador de conducta	landmarks → features → clasificador. Para un animal, el extractor sólo calcula movimiento por *bodypart*, su resumen y ventanas móviles (59 columnas por frame; 174 por clip tras agregar)
Código propio del experimento	Reemplaza el rol «features»	landmarks → 160 features faciales y cefálicas → Random Forest

Ninguna de las dos herramientas cumple ambos roles; DeepLabCut sigue siendo imprescindible en cualquiera de los enfoques.

17.2 Compatibilidad e importación DLC → SimBA

(`resultados/compatibilidad_dlc_simba.json`) La pose del proyecto está en **formato largo** (`clip, orden, bodypart, x, y, confianza`), en **píxeles del cuadro original** (hasta 1981 × 1942 px), **sin normalizar ni alinear**; resoluciones de origen de 640×480 a 2560×1440. **La importación directa a SimBA no es posible**: SimBA espera formato ancho (`<bp>_x, <bp>_y, <bp>_p`) o el CSV/H5 multiíndice de DLC, un proyecto con `project_config.ini`, definición de los 39 *body-parts*, `video_info.csv` (fps, resolución, px/mm) y series de frames **consecutivos** a fps constante, mientras aquí son 16 frames separados 0,1–0,5 s (mediana 0,33 s). Se necesitó

una **conversión** (`simba_real_intento.py` escribe los 359 clips en formato ancho y crea el proyecto); los px/mm no se calibraron (1,0), de modo que las distancias de SimBA quedan en píxeles dependientes de la resolución. Para importar el paquete hizo falta un *stub* vacío de `tkinter` (no instalado; sólo afecta a la interfaz gráfica).

17.3 Inventario anatómico: qué se puede y qué no se puede observar

Con 39 landmarks 2D (la disponibilidad se mide sobre los 5 744 frames seleccionados, **sesgados** hacia ojo y hocico por la forma de seleccionar la ventana):

Landmark	% de frames con confianza ≥ 0,50	% de clips con algún frame ≥ 0,50
nose	100,0 %	100,0 %
upper_jaw	87,6 %	99,4 %
lower_jaw	79,1 %	99,7 %
mouth_end_right	44,8 %	68,8 %
mouth_end_left	41,6 %	68,8 %
right_eye	96,6 %	100,0 %
left_eye	94,1 %	100,0 %
right_earbase	64,7 %	94,7 %
right_earend	58,3 %	90,8 %
left_earbase	67,1 %	95,0 %
left_earend	59,3 %	94,2 %
neck_base	24,9 %	66,9 %
neck_end	36,2 %	81,3 %

Aspecto facial	Clasificación	Motivo
angulo de orejas respecto del eje de la cabeza	aproximada	earbase/earend de cada oreja; proyección 2D, depende del punto de vista
largo/posición de orejas, asimetría L-R, separación entre puntas	aproximada	2D con escorzo; 'izquierda/derecha' es del animal, no de la imagen
apertura del ojo	imposible	un solo keypoint por ojo; no hay párpados superior/inferior
parpadeo	imposible	no hay apertura de ojo; además se muestrean 16 frames separados 0,2-0,5 s (un parpadeo dura ~0,1-0,4 s)
distancia interocular / ojo-hocico	directamente observable (en 2D)	ambos ojos y nariz
labios (tensión, comisuras)	aproximada	solo comisuras (mouth_end_*) y mandíbulas (upper/lower_jaw), no labios; comisuras visibles en poco frames
apertura de mandíbula/boca	aproximada	upper_jaw-lower_jaw
fosas nasales, tensión muscular, surcos faciales	imposible	no existen landmarks para esas estructuras
orientación/inclinación de cabeza en el plano de la imagen	directamente observable	eje ojo(s)->hocico
pitch/yaw/roll 3D de la cabeza	imposible (solo proxy)	pose 2D monocular; el cociente largo ojo-hocico / mediana del clip es un proxy de escorzo, no de ángulo
ángulo cabeza-cuello	aproximada	neck_base/neck_end con confianza >=0,50 en 25-36 % de los frames; semántica exacta de neck_* no verificada
velocidades (cabeza, orejas, mandíbula)	aproximada	diferencias entre los 16 frames del clip (separados 0,2-0,5 s); la velocidad de cabeza incluye movimiento de cámara y de cuerpo (no hay marco fijo)
aceleraciones	aproximada (más ruidosa)	segunda diferencia sobre muestreo grueso y jitter de keypoints
simetría L-R	aproximada	depende del punto de vista (vistas de perfil ocultan un lado)
antler_base/antler_end	no usadas	puntos del esquema SuperAnimal-Quadruped pensados para cuernas; su correspondencia anatómica en el caballo No pudo verificarse con los archivos dispon

Conclusiones del inventario: no existe **apertura del ojo ni parpadeo** (hay un único landmark por ojo; además el muestreo de 0,1–0,5 s no resuelve un parpadeo de 0,1–0,4 s); tampoco fosas nasales, tensión muscular ni surcos faciales. Las orejas, la apertura de mandíbula y la inclinación de la cabeza son observables en 2D con las reservas del punto de vista; los labios sólo por comisuras visibles en menos de la mitad de los frames. Los landmarks `antler_*` no se usaron (semántica en el caballo no verificable; `antler_end` casi nunca supera 0,50). Los ángulos 3D (*pitch, yaw, roll*) son imposibles con pose 2D monocular.

17.4 Comparación con las 9 variables geométricas vigentes (hallazgo de esta auditoría)

El inventario (`inventario_anatomico.json`, `comparacion_con_9_vigentes`) midió sobre los 5 744 frames lo que realmente contienen las 9 columnas del canal geométrico del MIL (`MultimodalEquineDataset`):

- Centradas en el punto medio ojo–hocico y divididas por la distancia ojo–hocico **del propio frame**, las cuatro columnas de ojo y hocico valen ±0,5 por el versor ojo→hocico: **llevan un solo grado de libertad, la inclinación de la cabeza en el plano de la imagen** (la suma de las coordenadas de ojo y hocico es exactamente 0 y la norma mediana del hocico es 0,5).
- **Las tres máscaras de validez valen 1 en el 100 % de los frames**: se calculan con `confianza > 0` y no con el umbral `≥ 0,50` del resto del pipeline, de modo que no informan nada.
- x/y de «oreja» es la posición de **un** punto (el más confiable de entre base y punta de ambas orejas), en ejes de imagen sin rotar al eje de la cabeza: mezcla posición con orientación y puede cambiar de punto entre frames.

En consecuencia, el canal geométrico actual aporta esencialmente la inclinación de la cabeza y un punto de oreja. Lo que el experimento agrega y las 9 no tienen: largo, ángulo y asimetría de orejas relativos al eje de la cabeza, boca y mandíbula, distancia interocular y escorzo, dinámica (velocidades y aceleraciones) y disponibilidad. Es coherente con que las 9 geométricas solas den 0,607 (LogReg) / 0,694 (RF) y las 160 tipo SimBA, 0,84.

17.5 Dataset tabular y trazabilidad

`resultados/dataset_tabular_simba.csv`: **359 filas (clips) × 171 columnas** (identificadores `clip_id, video, caballo, clase, fold`, 6 metadatos de filmación y **160 features**); `columnas.json` lista cada feature con su grupo y su trazabilidad. Composición: 26 series estáticas × 5 agregados (media, desvío, mín., máx., rango) = 130; 7 series dinámicas × 3 (media, desvío, máx.) = 21; 9 de disponibilidad. Se construyen desde `pose_seleccionada_v2.csv` (los **mismos 16 frames** que ve el MIL), con el umbral de confianza 0,50 (por debajo = ausente), escala = mediana del clip de la distancia ojo–hocico (sin estadística global) e imputación por mediana **ajustada sólo con el train de cada fold**; el 14,2 % de los valores es ausente. Las predicciones fuera de muestra de cada variante están en `oof_predicciones.csv`, y la verificación de folds se hace con aserciones en `evaluar.py`. El conjunto B2 (SimBA real) tiene 174 columnas por clip (`dataset_tabular_simba_real.csv`).

17.6 Mismos folds, mismos clips, mismo denominador

`evaluar.py` verifica con aserciones: fold = `particion.construir`; tamaños de test 90/90/90/89 y caballos de test 33/33/34/33 **idénticos** a los de `objetivo3_evaluacion_v2.json`; clase y caballo de cada clip idénticos a los de las predicciones del MIL; ningún caballo en train y test; el baseline recalculado coincide con el del repositorio (predicciones idénticas). La verificación adversarial re-ejecutó estas aserciones y recomputó el MIL con la misma función (0,7396). El F1 macro se informa como en el pipeline (media ± DE de 4 folds); en el bootstrap por caballo se usa el F1 agrupado por réplica. **Asimetrías declaradas:** el MIL tiene *early stopping* con validación interna; el RF y la LogReg no tuvieron búsqueda de hiperparámetros.

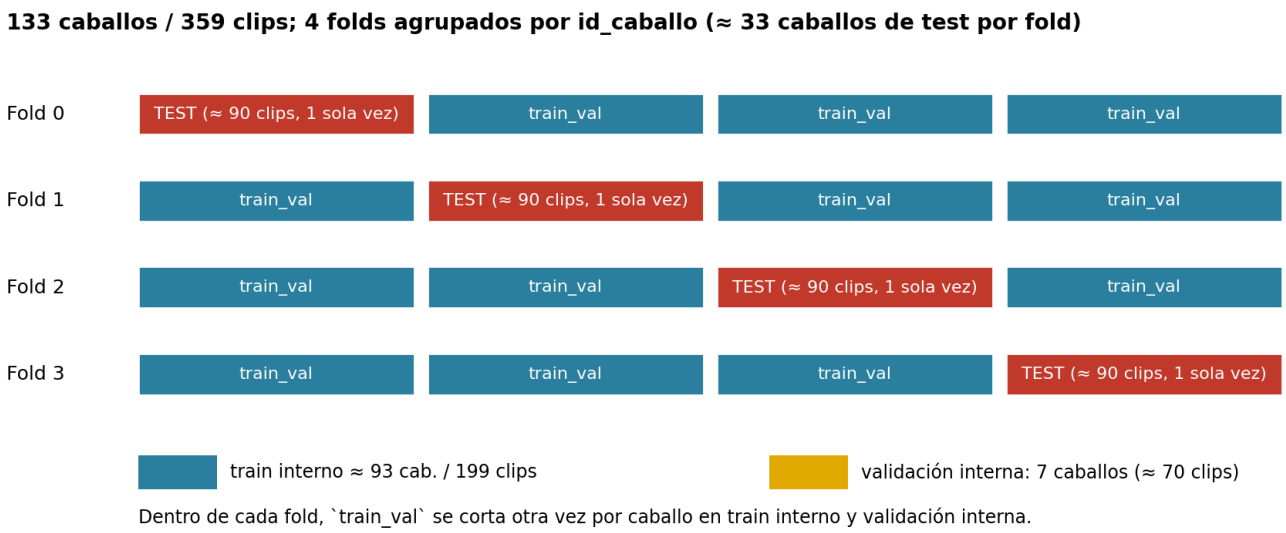


Figura 17.2. Esquema de folds: 4 particiones por caballo; el mismo corte externo e interno se usa para el MIL, el baseline y SimBA-RF.

17.7 Tres enfoques, por fold y por clase

Modelo	Información que usa	Complejidad	Interpretabilidad	F1 macro ± desvío
MIL multimodal (vigente)	Imagen (ResNet-18 congelada, 512/frame) + 9 variables geométricas, 16 frames	132 355 parámetros entrenables (+ 11,2 M congelados); GPU para extraer características	Baja: atención por frame, sin significado de rasgo	0,740 ± 0,052
Baseline estático (LogReg)	Media de las 512 características de los 16 frames	1 539 parámetros; requiere la ResNet-18	Media: coeficientes sobre características visuales sin nombre	0,741 ± 0,020
Random Forest sobre 160 features «tipo SimBA» (código propio)	Solo landmarks de DLC: orejas, ojos, boca, cabeza-cuello; estáticas (130), dinámicas (21) y disponibilidad (9)	500 árboles (≈ 26 000 nodos); 3,3 s de ajuste en total, sin GPU (además de DLC)	Media-alta: cada feature tiene nombre geométrico; SHAP	**0,841 ± 0,003** (media de 5 semillas; DE entre semillas). Semilla 0: 0,851 ± 0,050 (DE entre folds)

Cifra titular de SimBA-RF: 0,841 ± 0,003 (media de las semillas 1–5: 0,839 / 0,842 / 0,836 / 0,842 / 0,844). La cifra de 0,851 del resumen original corresponde a la semilla 0, la más alta, y no se usa como titular. Con la semilla 0 el desvío entre folds es 0,050.

Fold	SimBA-RF (semilla 0)	MIL vigente	Baseline estático
0	0,777	0,718	0,740
1	0,865	0,769	0,740
2	0,878	0,677	0,716
3	0,882	0,795	0,766
Media ± DE	0,851 ± 0,050	0,740 ± 0,052	0,741 ± 0,020
Accuracy	0,852	0,744	0,749

Clase	RF P	RF R	RF F1	MIL P	MIL R	MIL F1	Soporte
Disgustado	0,840	0,864	0,852	0,740	0,689	0,714	103
Interesado	0,857	0,814	0,835	0,764	0,797	0,780	118
Sereno	0,858	0,877	0,867	0,729	0,739	0,734	138

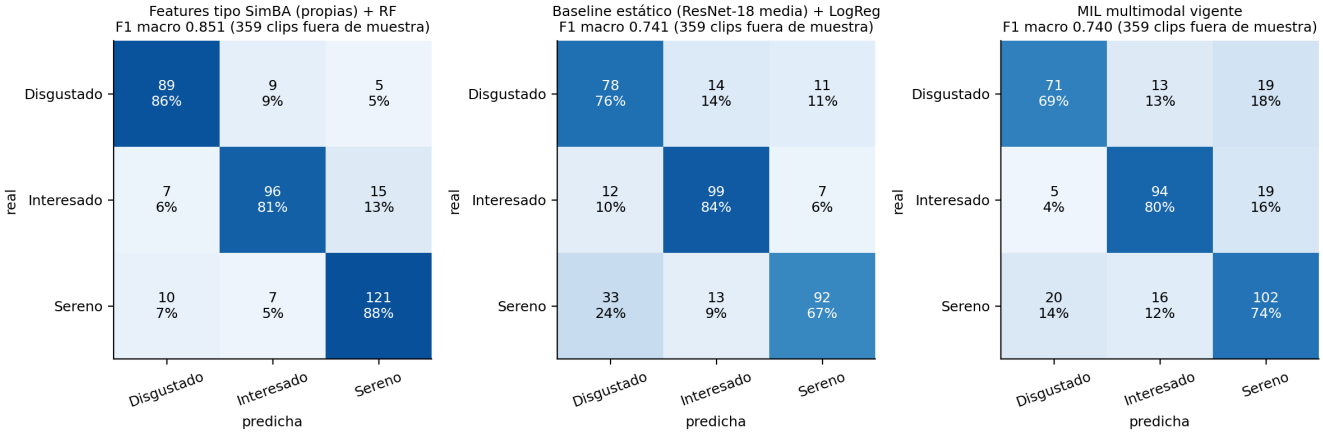


Figura 17.3. Matrices de confusión fuera de muestra de SimBA-RF, el baseline y el MIL (resultados del experimento).

Por clase, SimBA-RF queda parejo (F1 0,85 / 0,83 / 0,87), contra 0,71 / 0,78 / 0,73 del MIL; la confusión más frecuente de SimBA-RF es `Interesado → Sereno`.

17.8 Ablación (variantes A–F)

Variante	Features	F1 macro original (media ± DE)	Limpio: media de folds	Limpio: agrupado
K1 Control de filmación (7 variables: duración, fps, resolución, ventana, escala, dt) — post hoc	7	0,619 ± 0,008	0,403	0,392
A. 9 geométricas vigentes (RF)	18	0,694 ± 0,044	0,550	0,603
A. 9 geométricas vigentes (LogReg)	18	0,607 ± 0,033	0,552	0,580
B. 160 features tipo SimBA propias (RF)	160	0,851 ± 0,050	0,723	0,750
B. ídem (LogReg)	160	0,832 ± 0,037	0,747	0,769
B-a. Solo estáticas (130)	130	0,826 ± 0,070	0,685	0,723
B-b. Solo dinámicas (21)	21	0,726 ± 0,036	0,606	0,624
B-c. Sin dinámica de cabeza (151) — post hoc	151	0,848 ± 0,057	0,703	0,726
B-d. Sin disponibilidad (151)	151	0,848 ± 0,058	0,725	0,753
B2. SimBA real, solo movimiento (174; LogReg)	174	0,720 ± 0,066	0,656	0,679
C. Baseline estático (LogReg)	512	0,741 ± 0,020	0,630	0,671
D. Visual + 9 geométricas (LogReg)	530	0,747 ± 0,025	0,640	0,673
E. MIL vigente	—	0,740 ± 0,052	0,670	0,705
F. SimBA propio + visual (RF)	672	0,844 ± 0,071	0,729	0,751

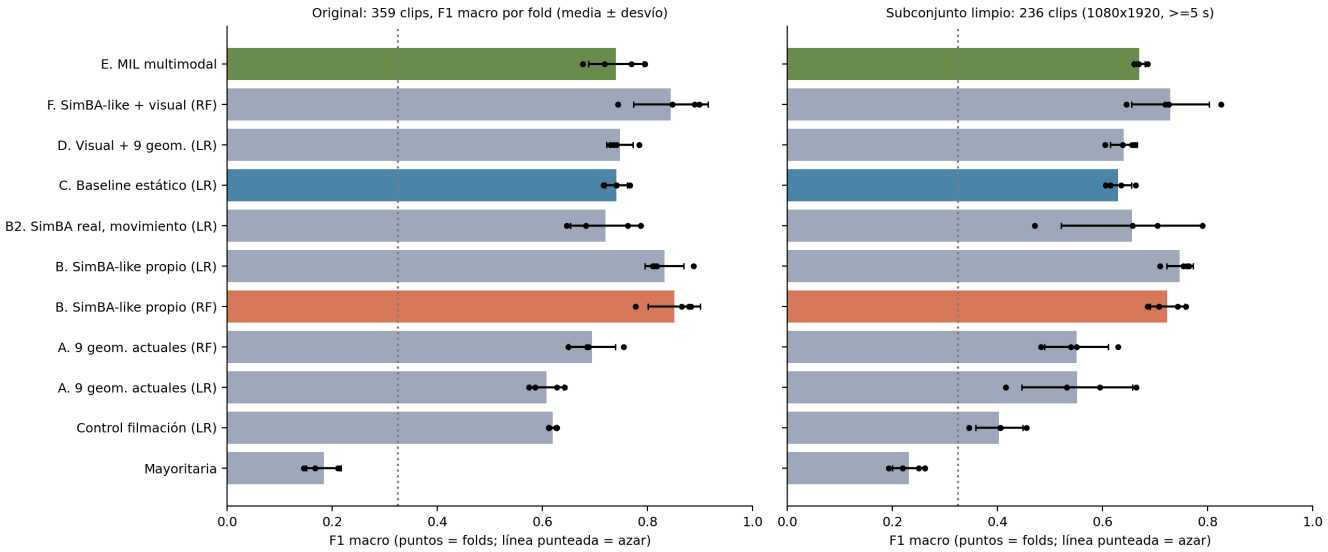


Figura 17.4. Comparación de modelos en el conjunto original (359 clips) y en el subconjunto limpio (236 clips: 1080×1920 y ≥ 5 s); puntos = folds.

Lecturas: (i) las 160 features dan 0,84–0,85 mientras las 9 geométricas vigentes dan 0,61–0,69; (ii) las **estáticas solas** (130) llegan a 0,826 y las **dinámicas solas** (21) a 0,726; quitar la dinámica de cabeza o la disponibilidad casi no cambia el resultado (0,848): la ventaja **no** depende de la velocidad de cabeza ni de la disponibilidad (que sola da 0,490); (iii) añadir la imagen (F) **no mejora** a SimBA solo (0,844); (iv) **SimBA real (B2, sólo movimiento) obtiene 0,720** (LogReg), por debajo del baseline visual; (v) el control de filmación (K1) da 0,58–0,62; (vi) K1 y «sin dinámica de cabeza» se agregaron **después** de ver el SHAP (post hoc); el resto de la ablación estaba planificado. Además, en la verificación: **sólo cara** (orejas, ojos, boca; 122 features) 0,848; sólo orejas 0,784; boca sola 0,648; **cuello solo 0,461** (la señal está en la cara, no en el cuello).

17.9 Original frente a limpio (el confusor de filmación)

Modelo	Original (359 clips)	Limpio: media de folds (236 clips)	Limpio: agrupado	Entrenado y evaluado solo en limpio (agrupado)
Baseline estático (LogReg)	0,741 ± 0,020	0,630	0,671	0,606
SimBA-RF propio (semilla 0)	0,851 ± 0,050	0,723	0,750	0,678
MIL vigente	0,740 ± 0,052	0,670	0,705	no reentrenado

Control sobre SimBA-RF (verificación adversarial)	F1 macro
Media de 5 semillas (1–5)	0,841 ± 0,003
Residualizando las features por duración, fps, resolución y proporción (por fold)	0,777
Clips de duración < 5 s (95 clips; 71 son `Disgustado`)	0,877
Clips de duración ≥ 5 s (264 clips)	0,765
Solo metadatos de filmación (verificación)	0,574
Features + metadatos	0,842
Solo disponibilidad de keypoints	0,490
Etiquetas permutadas (control negativo, 3 repeticiones)	0,29 / 0,32 / 0,32
Predecir log-duración desde las 160 features (R^2)	0,53
Predecir resolución 1080×1920 desde las 160 features (AUC)	0,73

Conjunto	Diferencia (F1 agrupado, semilla 0)	Media	IC 95 % (bootstrap por caballo)	¿Incluye 0?
Original	SimBA-RF − MIL	+0,110	[+0,042; +0,181]	no
Original	SimBA-RF − Baseline	+0,106	[+0,037; +0,179]	no
Limpio	SimBA-RF − MIL	+0,048	[-0,056; +0,169]	sí (no concluyente)
Limpio	SimBA-RF − Baseline	+0,083	[-0,018; +0,202]	sí (no concluyente)

Verificación independiente (sklearn, 133 caballos): +0,111 [0,045; 0,186].

- **Piso deconfundido:** residualizando las features por duración, fps, resolución y proporción dentro de cada fold, SimBA-RF baja de 0,841 a **0,777** (es un *piso*, porque la residualización puede quitar señal legítima: la duración correlaciona con la clase).
- **Subconjunto limpio (1080×1920 y ≥ 5 s):** SimBA-RF **0,750** (agrupado) frente al MIL **0,705** y al baseline 0,671; **el IC de la diferencia incluye 0** (no concluyente). **Entrenado y evaluado sólo en limpio** (≈ 236 clips, 28 `Disgustado`): SimBA-RF 0,678 y baseline 0,606; con tan pocos clips la estimación es muy ruidosa y el MIL no se re-entrenó.
- **Por estrato de duración:** clips < 5 s, **0,877** (71 de 95 son `Disgustado`); clips ≥ 5 s, 0,765.
- **ALERTA de confusor de filmación:** desde las 160 features se predice la **log-duración con R^2 = 0,53** y la **resolución 1080×1920 con AUC = 0,73** (sólo las estáticas: R^2 0,08, AUC 0,75). Las features son razones, ángulos y velocidades normalizadas, sin píxeles absolutos, y aun así codifican la filmación. **El MIL comparte el mismo confusor**, de modo que la comparación es justa pero **ambos resultados están inflados** por el contexto de captura (§10.3 y §12.2).
- En el SHAP, las velocidades de cabeza lideran y correlacionan con la duración del clip (Spearman −0,53: el *jitter* de los landmarks dividido por un intervalo corto infla la velocidad), pero la ablación muestra que el resultado no depende de ellas; aun en el subconjunto limpio `Disgustado` tiene mayor velocidad de cabeza mediana (0,82 frente a 0,17–0,29), que puede ser movimiento real, movimiento de cámara o punto de vista: **no se puede separar con estos datos**.

17.10 Sobreajuste frente al MIL

Modelo	F1 train	F1 validación interna	Gap train−validación	Gap train−test
SimBA-RF	0,993	0,659	0,337	0,143
SimBA LogReg	0,979	0,729	0,268	0,148
9 geométricas (RF)	0,992	0,584	0,402	0,298
Baseline estático (LogReg)	1,000	0,634	0,366	0,259
MIL vigente	0,979	0,712	0,267	0,240

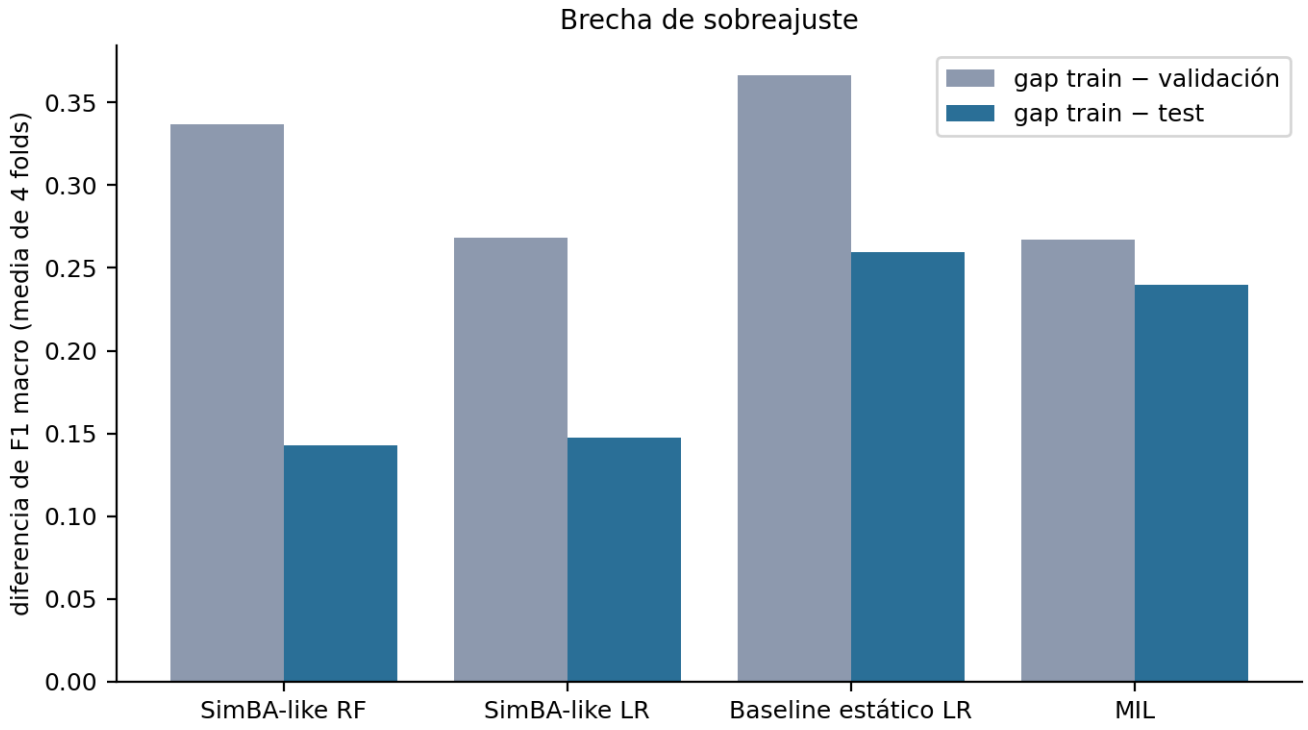


Figura 17.5. Brechas de sobreajuste por modelo (resultados del experimento).

El RF memoriza el train (F1 ≈ 0,99). Su gap train−test (0,14) es menor que el del MIL (0,24) y el del baseline (0,26), pero su gap train−validación interna (0,34, sobre ~7 caballos) **no es menor** que el del MIL (0,27). Lo que sostiene la comparación es el test fuera de muestra, no el gap. Respuesta: *parcial* (§17.15, pregunta 10).

17.11 SHAP (SimBA-RF)

Qué se explica. `TreeExplainer` *out-of-fold*: cada fold explica su test con el RF entrenado con los otros 3 folds (un RF distinto por fold; las importancias son un agregado de 4 modelos). Cada valor SHAP es la **contribución de una feature a la probabilidad de una clase respecto del valor base**, que es la salida media del modelo (≈ 0,333 por clase en los 4 folds: el RF balanceado parte del reparto uniforme). Se agregan los valores absolutos por clip y por clase.

#	Feature (agregado por clip)	Media del valor absoluto de SHAP (prob.)	Grupo
1	`cabeza_velocidad__media`	0,0306	dinamica
2	`cabeza_aceleracion__media`	0,0199	dinamica
3	`cabeza_velocidad__desvio`	0,0187	dinamica
4	`cabeza_velocidad__max`	0,0186	dinamica
5	`cabeza_velocidad_angular__media`	0,0160	dinamica
6	`oreja_asimetria_largo__media`	0,0158	estatica
7	`cabeza_aceleracion__desvio`	0,0128	dinamica
8	`cabeza_aceleracion__max`	0,0126	dinamica
9	`ojos_distancia__desvio`	0,0125	estatica
10	`oreja_separacion_puntas_sobre_bases__min`	0,0123	estatica
11	`ojos_distancia__rango`	0,0108	estatica
12	`oreja_asimetria_largo__min`	0,0106	estatica
13	`ojos_distancia__max`	0,0104	estatica
14	`cabeza_inclinacion_sobre_horizontal__desvio`	0,0097	estatica
15	`cabeza_largo_ojo_hocico_rel__rango`	0,0095	estatica
16	`oreja_separacion_puntas_sobre_bases__media`	0,0092	estatica
17	`cabeza_largo_ojo_hocico_rel__desvio`	0,0084	estatica
18	`cabeza_velocidad_angular__desvio`	0,0082	dinamica
19	`cabeza_inclinacion_sobre_horizontal__rango`	0,0081	estatica
20	`cabeza_velocidad_angular__max`	0,0075	dinamica

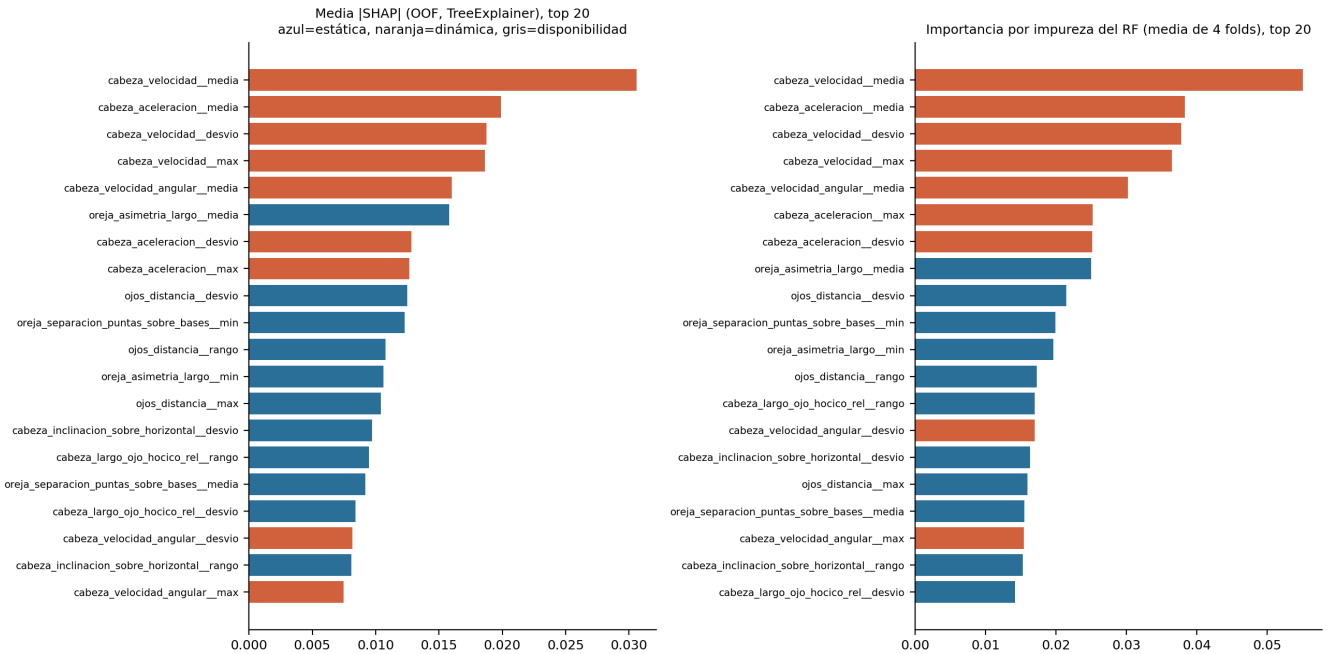


Figura 17.6. Importancias de las features (SHAP global e importancia por impureza).

Clase	Top 5 por media del valor absoluto de SHAP (entre paréntesis, Spearman valor-SHAP: el signo indica la dirección)
Disgustado	`cabeza_velocidad__media` (0,74); `cabeza_aceleracion__media` (0,81); `cabeza_velocidad__max` (0,86); `cabeza_velocidad__desvio` (0,89); `cabeza_velocidad_angular__media` (0,70)
Interesado	`oreja_asimetria_largo__media` (-0,88); `cabeza_velocidad__media` (-0,29); `oreja_separacion_puntas_sobre_bases__min` (-0,90); `oreja_asimetria_largo__min` (-0,90); `cabeza_aceleracion__media` (-0,52)
Sereno	`cabeza_velocidad__media` (-0,93); `ojos_distancia__desvio` (-0,88); `cabeza_velocidad__desvio` (-0,94); `cabeza_velocidad__max` (-0,93); `ojos_distancia__rango` (-0,87)

Familia anatómica	Fracción del valor absoluto de SHAP total
Cabeza (orientación/dinámica)	40,2 %
Orejas	38,5 %
Boca/mandíbula	9,7 %
Ojos	7,4 %
Disponibilidad de keypoints	2,3 %
Cabeza-cuello	2,0 %

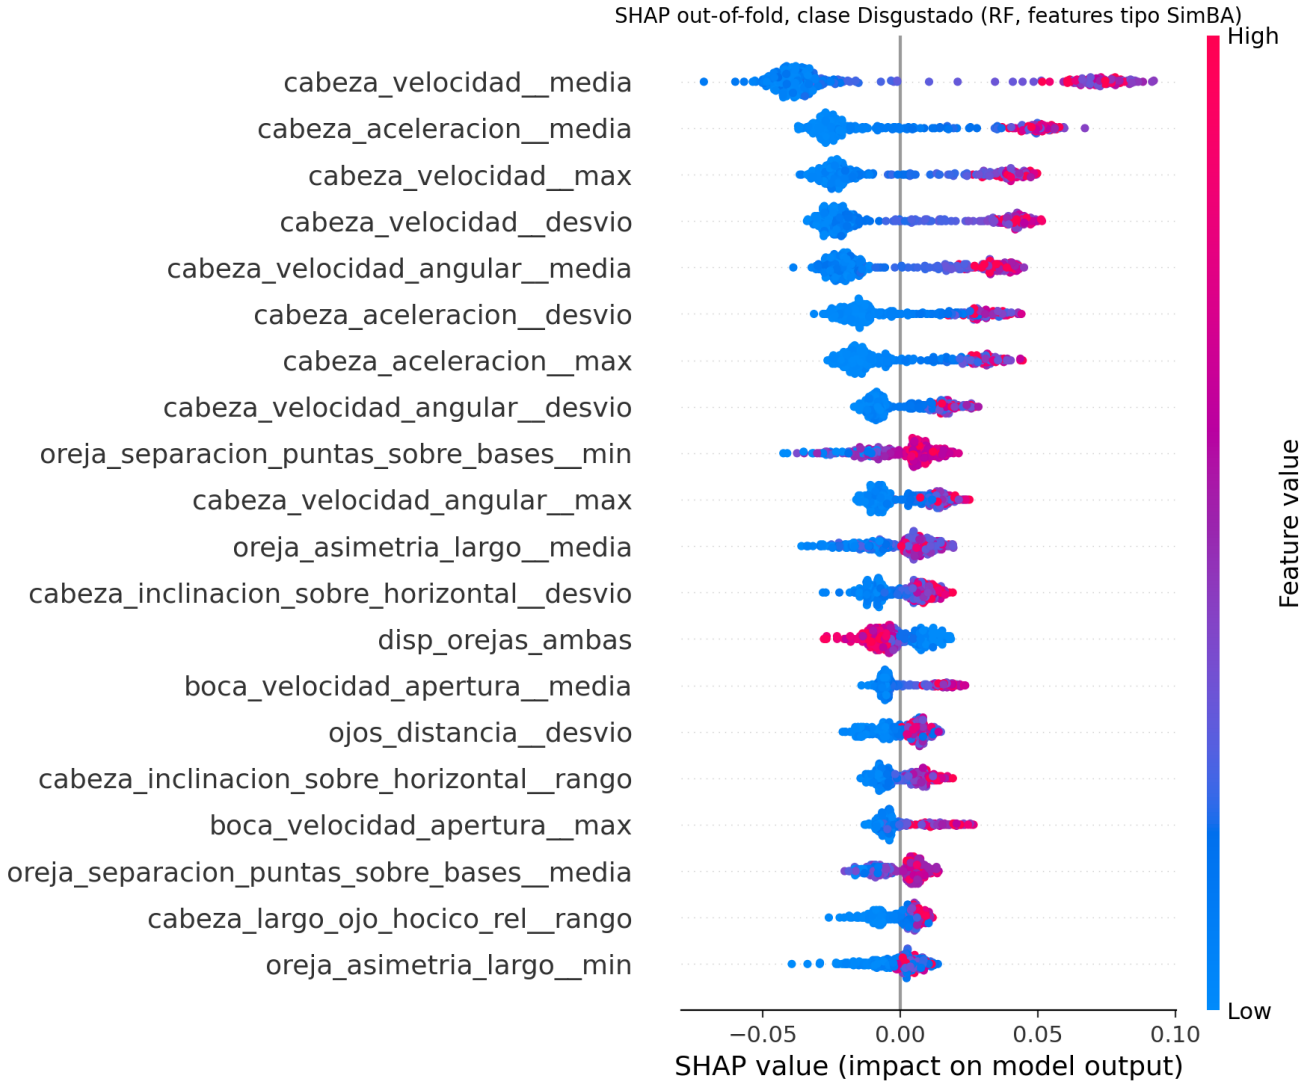


Figura 17.7. Gráfico de resumen (summary plot*) de SHAP para la clase Disgustado.*

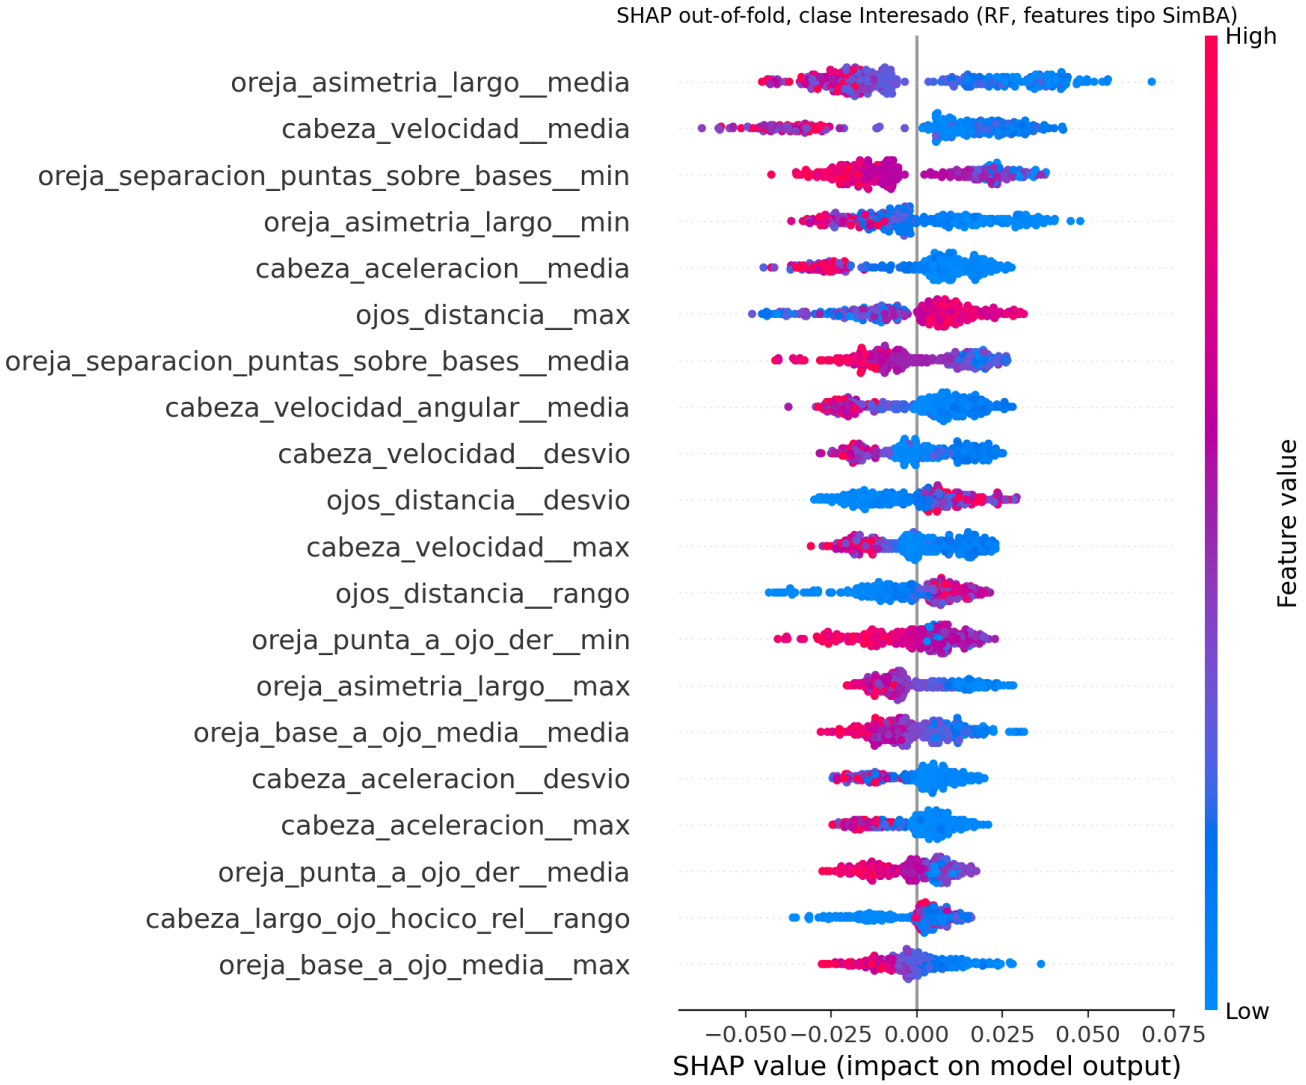


Figura 17.8. Gráfico de resumen de SHAP para la clase Interesado.

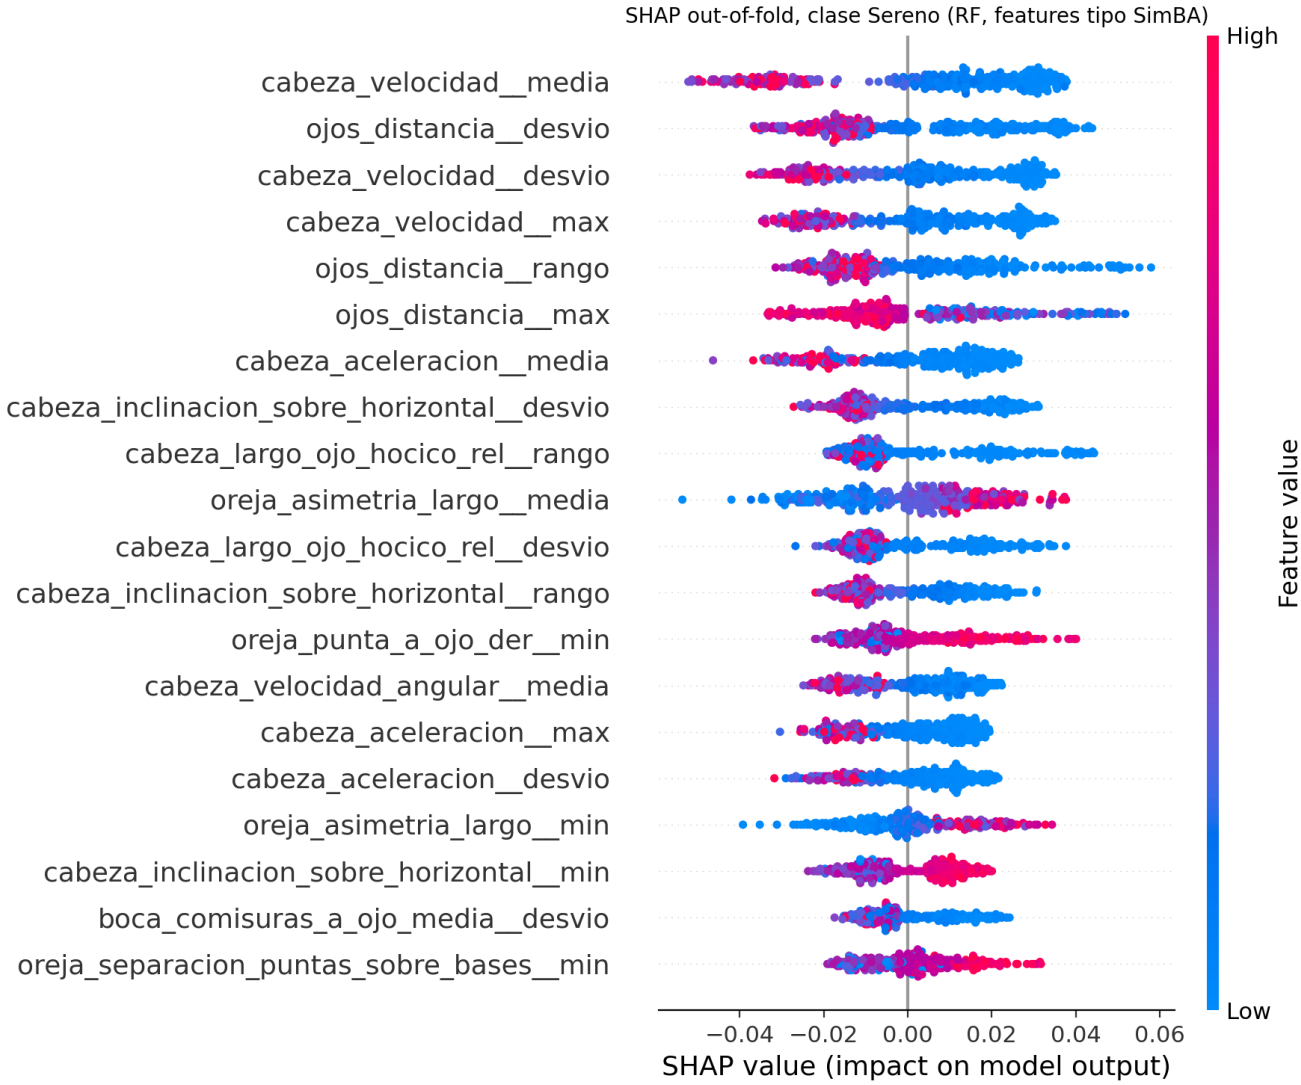


Figura 17.9. Gráfico de resumen de SHAP para la clase Sereno.

Lectura etológica (solo asociativa; requiere validación experta). *Por familia,* ***cabeza (orientación y dinámica) 40,2 %*** *y* ***orejas 38,5 %*** *del |SHAP| total, boca/mandíbula 9,7 %, ojos 7,4 %, disponibilidad 2,3 %, cabeza-cuello 2,0 %. Para* `Disgustado`*, valores altos de velocidad y aceleración de cabeza se asocian a mayor probabilidad (Spearman valor–SHAP 0,70–0,89), junto con valores altos de la separación mínima entre las puntas de las orejas (0,72). Para* `Interesado`*, valores* ***bajos*** *de asimetría de largo de las orejas (Spearman −0,88) y de separación mínima entre puntas (−0,90) se asocian a mayor probabilidad, y valores altos de distancia interocular máxima (+0,81). Para* `Sereno`*,* ***menor*** *velocidad de cabeza (Spearman −0,93) y menor variación de la distancia interocular (−0,88). Esto es* ***coherente con el criterio de etiquetado*** *(orejas hacia caudal y movimientos amenazantes de cabeza en* `Disgustado`*; orejas hacia craneal en* `Interesado`*; cabeza quieta en* `Sereno`*;* `docs/protocolo_de_etiquetado.md` *§3),* ***pero*** *es una asociación, no causalidad; hay features muy correlacionadas (el SHAP reparte el crédito); la pose es 2D y depende del punto de vista; las velocidades de cabeza pueden reflejar movimiento de cámara y duración del clip; y el etiquetado usa contexto y postura, de modo que la cinemática de cabeza puede ser tanto señal como atajo.*

17.12 Lo que SimBA no resuelve

El experimento ***no*** *resuelve: (a)* ***EquiFACS****: no hay codificación de unidades de acción por video ni equivalencia entre los landmarks y las AU; (b) la* ***calidad de las etiquetas*** *(un único observador no ciego); (c) el* ***acuerdo interobservador*** *(no medido sobre el dataset); (d) la* ***validación veterinaria*** *ni la utilidad para expertos; (e) la* ***validación externa*** *(un filmador, una región); (f) el* ***punto de vista*** *y el establecimiento, que no se pueden descartar como fuente de señal. Una feature con nombre geométrico es interpretable, no validada clínicamente.*

17.13 Matriz de parsimonia

Modelo	Tamaño	Entrenamiento	Inferencia por clip	¿Necesita red visual?	Interpretabilidad
MIL vigente	*132 355 entrenables (+ 11 176 512 congelados)*	*28 s (fold 0, GPU, desde características cacheadas, 1 corrida)*	*0,20 ms (CPU, sin extraer ResNet)*	*Sí (extracción de características)*	*Baja*
Baseline estático (LogReg)	*1 539*	*0,06 s (4 folds, total)*	*0,007 ms*	*Sí (ResNet-18)*	*Media*
SimBA-RF (160 features)	*500 árboles; ≈ 25 578 nodos*	*3,3 s (4 folds, total)*	*0,76 ms*	*No (solo DeepLabCut)*	*Media-alta*
SimBA LogReg	*483*	*0,03 s*	*0,006 ms*	*No (solo DeepLabCut)*	*Alta*

No medido: el costo de DeepLabCut (≈ 1 h para todo el dataset según `equinos/pose.py`), común a ambos enfoques, ni el de la ResNet-18.

Criterio	MIL	Baseline estático	SimBA-RF
F1 macro (original)	*0,740*	*0,741*	*0,841 (5 sem.)*
F1 macro (limpio, agrupado)	*0,705*	*0,671*	*0,750 (no concluyente frente al MIL)*
Necesita GPU para entrenar/inferir	*Sí (extracción visual)*	*Sí (ResNet-18)*	*No (sólo DLC, común a todos)*
Interpretabilidad	*Baja*	*Media*	*Media-alta (rasgos con nombre, SHAP)*
Riesgo de confusor de filmación	*Sí*	*Sí*	*Sí (R^2 0,53 en log-duración)*
Parsimonia (rendimiento por complejidad)	*Peor*	*Intermedia*	***Mejor en el original; empate no demostrado en el limpio***

17.14 Revisión adversarial del F1 0,851

(`experimentos/simba/verificacion/`, re-ejecutable con `verificar.py`.)

#	Punto	Veredicto	Evidencia resumida
1	*Partición*	*OK*	*Aserciones re-ejecutadas; ningún caballo ni video en train y test. No se puede probar que un mismo animal no tenga dos IDs (límite no resuelto)*
2	*Preprocesamiento*	*OK*	*Sin estadística global; imputación por pipeline; sin selección de features ni de hiperparámetros; **etiquetas permutadas: F1 0,29–0,32** (control negativo correcto)*
3	*Filmación*	***ALERTA***	*Las features predicen log-duración (R^2 0,53) y resolución (AUC 0,73); residualizando: **0,777**; por estrato: < 5 s 0,877 / ≥ 5 s 0,765; limpio 0,750; sólo limpio 0,678*
4	*Contexto*	*OK con matiz*	*Sólo cara 0,848; orejas 0,784; boca 0,648; cuello solo 0,461; la inclinación de cabeza aporta (0,71); punto de vista/establecimiento no descartables*
5	*Comparabilidad*	*OK*	*Mismos clips, etiquetas y caballos; MIL recomputado 0,7396; por clase RF 0,85/0,83/0,87 frente a MIL 0,71/0,78/0,73*
6	*Semillas*	*ALERTA leve*	*Semillas 1–5: 0,839–0,844; **0,841 ± 0,003**; la semilla 0 (0,851) es la más alta*
7	*Bootstrap*	*OK*	*Reimplementación independiente: +0,111 [0,045; 0,186]; el bootstrap por clip daría un IC similar*

***Conclusión de la revisión:** el 0,851 **no es un artefacto de fuga**, se sostiene **con reservas**: cifra robusta a semilla 0,841; una parte de la ventaja se apoya en la filmación/duración (piso 0,777, aún sobre el MIL 0,740 pero sin concluir); en limpio la diferencia no es concluyente; el MIL comparte el confusor; quedan sin resolver la identidad real de los animales, el punto de vista y el establecimiento.*

17.15 Las 12 preguntas del experimento (con las cifras corregidas)

#	Pregunta	Respuesta
1	¿Se reutilizaron los landmarks de DLC?	Sí, sin re-ejecutar DLC (`pose_seleccionada_v2.csv`). Importar a SimBA exige **convertir** (formato ancho + proyecto + `video_info`); la importación directa no es posible
2	¿Qué features se usaron?	Principal: **«features tipo SimBA» con código propio** (no es SimBA): orejas, ojos/cabeza, boca/mandíbula, cabeza-cuello, dinámica, disponibilidad. Secundario (B2): features **reales** de SimBA, que para un animal sólo describen movimiento
3	¿Cuántas features quedaron?	160 en el principal (130 estáticas, 21 dinámicas, 9 de disponibilidad); 174 en B2
4	¿F1 macro?	SimBA-RF **0,841 ± 0,003** (5 semillas; semilla 0: 0,851 ± 0,050 entre folds; accuracy 0,852). Baseline 0,741; MIL 0,740. Limpio (agrupado): SimBA-RF 0,750, baseline 0,671, MIL 0,705
5	¿Desvío entre folds?	SimBA-RF 0,050 (semilla 0); baseline 0,020; MIL 0,052
6	¿Qué clases se reconocen mejor?	SimBA-RF parejo: `Sereno` 0,87 > `Disgustado` 0,85 > `Interesado` 0,83; la confusión más común es `Interesado → Sereno`
7	¿Features más importantes (SHAP)?	Velocidad/aceleración de cabeza, asimetría de largo de orejas, variación de la distancia interocular, separación entre puntas de orejas (tabla 17.11). Familias: cabeza 40 %, orejas 39 %
8	¿Supera al baseline estático?	**Original: sí** (+0,106; IC 95 % [0,037; 0,179]). **Limpio: no concluyente** (+0,083 [−0,018; 0,202])
9	¿Supera al MIL?	**Original: sí** (+0,110 [0,042; 0,181]; verificado +0,111 [0,045; 0,186]). **Limpio: no concluyente** (+0,048 [−0,056; 0,169]); piso deconfundido 0,777
10	¿Menor sobreajuste?	**Parcial**: gap train−test 0,14 frente a 0,24 (MIL), pero el RF memoriza (train ≈ 0,99) y su gap train−validación (0,34) no es menor que el del MIL (0,27)
11	¿Más interpretable?	Sí en el sentido de que cada feature tiene nombre y significado geométrico y SHAP las ordena; con reservas (correlación entre features, asociación y no causalidad, 2D dependiente del punto de vista, velocidades afectadas por la cámara y la duración). Requiere validación experta
12	¿Conviene incorporarlo?	**Como modelo complementario** (liviano, sin GPU salvo DLC, interpretable) y como línea de base geométrica fuerte; **no** para sustituir al MIL ni para reportar la ventaja como definitiva (limpio no concluyente; filmación; punto de vista; un solo observador; 133 caballos). Siguiente paso: validar con punto de vista controlado y revisión de un etólogo

17.16 Efecto del experimento sobre esta auditoría

- ***R9 (arquitectura óptima): sigue CUMPLIDO PARCIALMENTE**, pero ahora con evidencia adicional de que el MIL **no** es la mejor opción dentro del proyecto: una alternativa sin red visual rinde 0,841 frente a 0,740 (IC de la diferencia que excluye 0 en el original) y 0,750 frente a 0,705 en el limpio (no concluyente). Por eso la formulación correcta es «no hay una arquitectura demostrada óptima; los datos favorecen a las features de pose, con reserva por la filmación».*
- ***R7 (espacio-temporal)** no cambia: SimBA-RF usa resúmenes de la dinámica (velocidades y aceleraciones sobre frames separados 0,1–0,5 s), no un modelo temporal; sin las dinámicas el RF rinde 0,826 (estáticas solas).*
- ***R14 (EquiFACS)**, **R15** y **R16** no cambian: SimBA no aporta codificación de unidades de acción, acuerdo interobservador ni validación veterinaria (§17.12).*
- *No existe en el plan un requisito de «interpretabilidad»; la mayor interpretabilidad de SimBA-RF se registra como fortaleza del experimento y no altera ningún conteo. **Conteo final sin cambios: 10 cumplidos, 6 parciales, 2 no verificables, 0 no cumplidos (de 18).***

18. Anexo: archivos analizados y producidos

18.1 Documentos de entrada

- `docs/plan_de_trabajo_corregido.pdf` (leído completo).
- `material para presentar/2da entrega/Devolucion_Juan_resumen_de_condiciones_cumplidas_o_no .pdf` (con las observaciones del docente) y `condiciones_cumplidas_2026-09-25.pdf` (auditoría anterior; comparadas por diferencia de texto).
- `openspec/project.md`, `openspec/specs/`, `openspec/changes/archive/2026-10-07-mejoras-prioridad-alta/`, `openspec/changes/experimento-comparativo-simba/`.
- `docs/registro_de_experimentos.md`, `docs/protocolo_de_etiquetado.md`, `docs/analisis_sobreajuste.md`, `docs/informe_mejora_pipeline_mil.md`.
- `material para presentar/informe/informe_final_tesina_equinos.tex` y `referencias.bib` (borrador; sólo lectura).

18.2 Código revisado (rama `main` @ `caf5564`)

`equinos/`: `particion.py`, `clasificacion.py`, `caracteristicas.py`, `secuencia.py`, `alineado.py`, `dataset.py`, `inferencia.py`, `lineas_de_base.py`, `reproceso.py`, `pose.py`, `encuadre.py`, `rutas.py`; `scripts/evaluar_v2.py`, `scripts/evaluar_lineas_de_base.py`; `app_inferencia.py`; `requirements-local.txt`; notebooks `01_preparar_dataset_equinos.ipynb` y `02_roi_y_normalizacion.ipynb` (parámetros y clips); los 15 archivos de `tests/`, ejecutados (15/15 pasan).

Ramas laterales consultadas con `git ls-tree` y `git log`: `feat/enriquecer-canal-geometrico`, `feat/validacion-cruzada-anidada-NestedCV`, `feat/finetuning-visual`.

18.3 Experimento SimBA (rama `feat/auditoria-y-experimento-simba`, sólo lectura)

`experimentos/simba/`: `README.md`, `features_simba.py`, `construir_dataset.py`, `evaluar.py`, `shap_rf.py`, `inventario.py`, `parsimonia_mil.py`, `simba_real_intento.py`, `figuras_y_resumen.py`, `test_features_simba.py`, `correr_todo.sh`; `resultados/` (`resumen.json`, `evaluacion.json`, `shap.json`, `inventario_anatomico.json`, `compatibilidad_dlc_simba.json`, `parsimonia_mil.json`, `simba_real_intento.json`, `columnas.json`, `dataset_tabular_simba.csv`, `dataset_tabular_simba_real.csv`, `oof_predicciones.csv`, `shap_top20_global.csv`, `shap_valores_oof.npz`, figuras `comparacion_modelos`, `matrices_confusion`, `gaps_sobreajuste`, `importancias`, `shap_resumen_*`); `verificacion/` (`README.md`, `verificacion.json`, `verificar.py`).

18.4 Artefactos de datos leídos (solo lectura, `datos_equinos/`)

`resultados/`: `inventario_videos.csv`, `inventario_clips.csv`, `dataset_frames_alineados_v2.csv`, `dataset_rechazos_v2.json`, `pose_seleccionada_v2.csv`, `pose_todos_los_frames.csv`, `particion_clips.json`, `caracteristicas_backbone_v2.{json,npz}`, `objetivo3_evaluacion_v2.json`, `objetivo3_lineas_de_base.json`, `objetivo3_evaluacion.json`, `objetivo3_{canal,nested,finetuning}_*.json`, `keypoints_manuales.csv`; `modelos/objetivo3_v2/mil_v2_fold{0..3}.pt`, `mil_multimodal_produccion.{pt,json}`; `trabajo/frames_alineados_v2/` (5 744 recortes); `clips/` (clips recodificados); y los videos fuente de `~/videos_de_prueba` (274 archivos).

18.5 Scripts de la auditoría (`auditoria/scripts/`)

Script	Qué produce
`comun.py`	Rutas (solo lectura sobre el repositorio principal) y utilidades

Script	Qué produce
`a01_dataset.py`	Embudo, clips y caballos por clase, folds, duración, consistencia de nombres, figuras 3.x
`a02_duplicados.py`	SHA-256 de videos, firma perceptual de video, dHash/MD5 de recortes, solapamientos
`a03_balance_folds_leakage.py`	Balance con criterio declarado, composición de test/train interno/validación, aserciones de fuga, comparación con `GroupKFold`
`a04_reentrenar.py`	Re-entrenamiento con el código vigente: reproducción bit a bit y 6 semillas
`a05_modelo.py`	Conteo de parámetros, dimensionalidad, invariancia al orden
`a06_metricas.py`	Métricas, estabilidad, matrices, baselines, bootstrap, independencia, cifras históricas
`a07_early_stopping_overfitting.py`	Tabla de épocas, brechas, test alterado, gap del baseline lineal, curvas
`a08_entrenamiento_vs_inferencia.py`	Efecto de recodificar clips en las características y predicciones
`a09_orientacion_inferencia.py`, `a09b_resumen.py`	Rotación declarada en el dataset; `clasificar_video` sobre videos del dataset
`a10_reproducibilidad.py`	Dependencias, semillas, ramas laterales, huellas
`a11_identidades.py`	Cribado de posibles identificadores duplicados
`a12_app_streamlit.py`	La interfaz arranca (sin navegador) y cita las métricas vigentes
`a13_seleccion_frames.py`	Ventana de 16 frames por clase
`a14_repetibilidad.py`, `a15_particiones_alternativas.py`	Variabilidad por semilla y por partición
`a17_confusores.py`	Rotación, contenedor, códec y fecha como predictores sin mirar la cara
`a18_calibracion.py`, `a19_identidad.py`, `a20_validacion_interna.py`	Calibración, efecto de agrupar por caballo, composición de la validación interna
`a21_diagramas.py`	Diagramas del pipeline y de los folds
`a16_ensamblar.py`	Genera los capítulos con tablas desde los JSON (incluye las de `experimentos/simba/`)
`a22_pdf.py`	Convierte los capítulos en `auditoria/condiciones_cumplidas.pdf` (WeasyPrint, venv `~/.venvs/pdf-auditoria`)
`correr_todo.py`	Reproduce todo, en orden

Los números del texto salen de `auditoria/datos/*.json|csv`; las figuras (PNG, 200 dpi) están en `auditoria/figuras/`.

18.6 Limitaciones de esta auditoría

- *No se re-ejecutó DeepLabCut sobre los videos (horas de GPU): la pose de las pruebas de §12 es la persistida.*
- *No se re-extrajeron las características desde las imágenes (se leyó el `.npz` vigente).*
- *La muestra de la prueba de extremo a extremo de la interfaz es pequeña (indicativa).*
- *La fecha de sesión se infiere del nombre de archivo; no hay metadato de establecimiento ni de cámara por video.*
- *No pudo verificarse con los archivos disponibles: identidad real de los caballos, raza, dispositivo, iluminación, composición del entrenamiento de SuperAnimal-Quadruped.*